ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN

NGUYỄN TƯỜNG HUY - TRƯƠNG TRUNG KIÊN

TIỀN XỬ LÝ VĂN BẢN VÀ PHOBERT-SVM CHO NHẬN DIỆN TIN GIẢ TIẾNG VIỆT TRÊN MẠNG XÃ HỘI

ĐỒ ÁN CHUYÊN NGÀNH
NGÀNH: CÔNG NGHỆ THÔNG TIN

Thành phố Hồ Chí Minh, năm 2026

ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN

NGUYỄN TƯỜNG HUY - TRƯƠNG TRUNG KIÊN

TIỀN XỬ LÝ VĂN BẢN VÀ PHOBERT-SVM CHO NHẬN DIỆN TIN GIẢ TIẾNG VIỆT TRÊN MẠNG XÃ HỘI

ĐỒ ÁN CHUYÊN NGÀNH
NGÀNH: CÔNG NGHỆ THÔNG TIN

GIẢNG VIÊN HƯỚNG DẪN: TS. PHAN TẤN QUỐC

Thành phố Hồ Chí Minh, năm 2026

LỜI CAM ĐOAN

Chúng em gồm Nguyễn Tường Huy và Trương Trung Kiên, cam đoan rằng: Đề tài "Tiền xử lý văn bản và PhoBERT-SVM cho nhận diện tin giả tiếng Việt trên mạng xã hội" là công trình nghiên cứu do chúng tôi thực hiện dưới sự hướng dẫn của **TS. Phan Tấn Quốc** - giảng viên trực tiếp hướng dẫn đồ án. Những kết quả nghiên cứu của các tác giả khác và các số liệu được sử dụng trong Đồ án chuyên ngành đều được trích dẫn đầy đủ. Những kết quả nghiên cứu chung có sự tham gia của các thành viên trong nhóm đều có sự đồng ý của các đồng tác giả. Chúng em xin chịu trách nhiệm về tính trung thực của nội dung được trình bày trong đồ án.

TP. HCM, ngày ... tháng ... năm ...

Người cam đoan 1 **Người cam đoan 2**

(Ký và ghi rõ họ tên) *(Ký và ghi rõ họ tên)*

LỜI CẢM ƠN

Chúng em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến **TS. Phan Tấn Quốc** – giảng viên trực tiếp hướng dẫn đồ án. Thầy đã dành nhiều thời gian, tâm huyết định hướng khoa học, tận tình chỉ bảo và hỗ trợ chúng em trong suốt quá trình nghiên cứu và hoàn thành đề tài "Tiền xử lý văn bản và PhoBERT-SVM cho nhận diện tin giả tiếng Việt trên mạng xã hội". Những lời khuyên và đóng góp chuyên môn quý báu của Thầy là kim chỉ nam quan trọng giúp chúng em hoàn thành đồ án này.

Mặc dù đã có nhiều nỗ lực để thực hiện đề tài một cách chỉn chu nhất, song do kinh nghiệm nghiên cứu thực tế còn hạn chế, đồ án khó tránh khỏi những thiếu sót. Chúng em rất mong nhận được những ý kiến đóng góp và chỉ bảo từ Thầy để nghiên cứu của chúng em được hoàn thiện hơn.

Chúng em xin kính chúc Thầy luôn dồi dào sức khỏe, hạnh phúc và gặt hái được nhiều thành công hơn nữa trong sự nghiệp giảng dạy và nghiên cứu khoa học!

Thành phố Hồ Chí Minh, ngày ... tháng ... năm 2026

Sinh viên thực hiện 1 **Sinh viên thực hiện 2**

(Ký và ghi rõ họ tên) *(Ký và ghi rõ họ tên)*

MỤC LỤC

LỜI CAM ĐOAN ..... **i**

LỜI CẢM ƠN ..... **ii**

MỤC LỤC ..... **iii**

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT ..... **xi**

DANH MỤC CÁC BẢNG ..... **xiii**

DANH MỤC CÁC HÌNH VẼ ..... **xiv**

LỜI MỞ ĐẦU **1**

1. Lý do chọn đề tài **1**

2. Lịch sử nghiên cứu vấn đề / Tổng quan **2**

3. Mục đích và nhiệm vụ nghiên cứu **3**

3.1. Mục đích nghiên cứu 3

3.2. Nhiệm vụ nghiên cứu 4

4. Đối tượng và phạm vi nghiên cứu **5**

4.1. Đối tượng nghiên cứu 5

4.2. Phạm vi nghiên cứu 5

5. Phương pháp nghiên cứu **6**

5.3. Phương pháp thực nghiệm 7

5.4. Phương pháp đánh giá 7

6. Giả thuyết khoa học **8**

6.1. Cơ sở luận hình thành giả thuyết 8

6.2. Phát biểu các giả thuyết khoa học cụ thể 9

7. Những đóng góp mới **9**

7.1. Xây dựng quy trình tiền xử lý dữ liệu chuyên biệt cho văn bản tiếng Việt trên mạng xã hội 9

7.2. Ứng dụng PhoBERT để khai thác sâu đặc trưng ngữ nghĩa theo ngữ cảnh. 10

7.3. Đề xuất mô hình kết hợp giữa PhoBERT và Máy véc-tơ hỗ trợ (SVM)..... 10
7.4. Thực nghiệm toàn diện và đánh giá khách quan trên tập dữ liệu tiếng Việt.11
7.5. Phân tích chuyên sâu các trường hợp dự đoán sai..... 11
7.6. Đề xuất ứng dụng thực tế (Tiện ích mở rộng trên trình duyệt).....12
8. Cấu trúc của Đồ Án Chuyên Ngành: Ngoài phần mở đầu, kết luận, danh mục tài liệu tham khảo và phụ lục, Đồ Án Chuyên Ngành gồm có 3 chương:..12
CHƯƠNG 1. GIỚI THIỆU VỀ NHẬN DIỆN TIN GIẢ..... 14
1.1. TỔNG QUAN VỀ TIN GIẢ..... 14
1.1.1. Khái niệm và Bối cảnh phát sinh Tin giả.....14
1.1.1.1. Bối cảnh bùng nổ thông tin trên mạng xã hội tại Việt Nam..... 14
1.1.1.2. Định nghĩa khoa học về Tin giả (Fake News)..... 14
1.1.1.3. Phân biệt Fake News, Misinformation và Disinformation..... 15
1.1.1.4. Tác động tiêu cực của tin giả đối với xã hội và an ninh quốc gia... 15
1.1.2. PHÂN LOẠI TIN GIẢ TRÊN MẠNG XÃ HỘI.....16
1.1.2.1. Phân loại theo động cơ và mục đích phát tán..... 16
1.1.2.2. Phân loại theo hình thức biểu diễn dữ liệu (Data Modality)..... 17
1.1.2.3. Đặc điểm cấu trúc và phương thức lan truyền của tin giả trên mạng xã hội..... 18
1.2. CÁC PHƯƠNG PHÁP PHÁT HIỆN TIN GIẢ..... 19
1.2.1. Phương pháp kiểm chứng truyền thống (Fact-Checking thủ công)..... 19
1.2.1.1. Khái niệm và Bối cảnh áp dụng kiểm chứng thủ công.....19
1.2.1.2. Quy trình thực hiện kiểm chứng thông tin tiêu chuẩn.....19
1.2.1.3. Ưu điểm của phương pháp kiểm chứng truyền thống..... 20
1.2.1.4. Hạn chế và Rào cản quy mô (Scalability Bottleneck).....20
1.2.2. Phương pháp phát hiện tin giả tự động bằng Học máy và Xử lý ngôn ngữ tự nhiên (NLP)..... 21

1.2.2.1. Biểu diễn toán học bài toán dưới dạng phân loại văn bản nhị phân (Binary Text Classification).....21
1.2.2.2. Quy trình 4 bước tổng quát của hệ thống phát hiện tự động..... 22
1.2.2.3. Ưu điểm vượt trội của hướng tiếp cận tự động..... 23
1.3. KHẢO SÁT CÁC CÔNG TRÌNH LIÊN QUAN.....23
1.3.1. Các bộ dữ liệu tin giả tiếng Việt.....23
1.3.1.1. Bộ dữ liệu ReINTEL (Reliable Intelligence Identification).....23
1.3.1.2. Bộ dữ liệu VFND (Vietnamese Fake News Dataset)..... 24
1.3.1.3. Tập dữ liệu vào thực tế từ các nền tảng mạng xã hội và các trang tin tức trực tuyến.....24
1.3.2. Nhận diện tin giả bằng Học máy truyền thống và Học sâu chuỗi.....25
1.3.2.1. Hướng tiếp cận bằng các thuật toán Học máy truyền thống (Naive Bayes, KNN, SVM).....25
1.3.2.2. Hướng tiếp cận bằng các mô hình Mạng nơ-ron chuỗi (LSTM, Bi-LSTM, CNN-BiLSTM).....27
1.3.3. Nhận diện tin giả và phân loại văn bản tiếng Việt bằng các mô hình Pre-trained Language Models (BERT, PhoBERT).....28
1.3.3.1. Đột phá từ kiến trúc Transformer và mô hình PhoBERT.....28
1.3.3.2. Ứng dụng PhoBERT trong bài toán phân loại ý định Chatbot tiếng Việt..... 30
1.3.3.3. Ứng dụng PhoBERT trong bài toán gom cụm bài báo khoa học 31
1.3.3.4. Ứng dụng PhoBERT trong mô hình đa phương pháp nhận diện tin bài phản động..... 33
1.3.4. So sánh, đánh giá tổng hợp các mô hình đã khảo sát.....34
1.3.4.1. Bảng đối sánh kỹ thuật giữa các nhóm mô hình.....34
1.3.4.2. Tiêu chí đánh giá chất lượng các thuật toán phát hiện tin giả tự

động..... 36
1.3.4.3. Nhận xét và Khoảng trống nghiên cứu (Research Gap)..... 37
1.4. THÁCH THỨC TRONG NHẬN DIỆN TIN GIẢ TIẾNG VIỆT TRÊN MẠNG XÃ HỘI..... 38
1.4.1. Thách thức từ đặc thù ngôn ngữ Tiếng Việt và dữ liệu mạng xã hội... 38
1.4.1.1. Rào cản ranh giới từ trong ngôn ngữ đơn lập..... 38
1.4.1.2. Mật độ nhiễu ngôn ngữ cực lớn trên mạng xã hội (Social Media Noise)..... 38
1.4.1.3. Sự bùng nổ của biểu tượng cảm xúc (Emoji/Icon) và yếu tố phi văn bản..... 39
1.4.2. Thách thức từ sự biến đổi tinh vi của hành vi tạo và phát tán tin giả.. 39
1.4.2.1. Thủ thuật "Trộn lẫn sự thật" (Partial Truths) và giả mạo văn phong báo chí..... 39
1.4.2.2. Sự biến đổi theo thời gian thực và hiện tượng trôi lệch dữ liệu (Temporal Drift)..... 40
1.4.2.3. Sự thiếu hụt bộ dữ liệu gán nhãn chuẩn hóa và hiện tượng mất cân bằng lớp..... 40
1.4.3. Thách thức về mặt kỹ thuật và hạ tầng công nghệ..... 41
1.4.3.1. Hạn chế của các phương pháp trích xuất đặc trưng truyền thống... 41
1.4.3.2. Giới hạn tài nguyên tính toán khi triển khai mô hình Transformer. 42
1.5. MỘT SỐ THÁCH THỨC VÀ GIẢI PHÁP..... 43
1.5.1. Mô hình đề xuất PhoBERT - SVM cho nhận diện tin giả tiếng Việt... 43
1.5.1.1. Lý do lựa chọn sự kết hợp giữa PhoBERT và SVM..... 43
1.5.1.2. Cơ sở toán học của SVM và bài toán tối ưu lề Margin..... 44

1.5.2. Ý nghĩa khoa học và khả năng ứng dụng thực tế.....46
1.5.2.1. Đóng góp về mặt lý thuyết khoa học.....46
1.5.2.2. Đóng góp về mặt thực tiễn - Triển khai REST API và tiện ích Chrome Extension..... 47
1.6. TÓM TẮT CHƯƠNG 1..... 48
1.6.1. Tổng kết các nội dung lý thuyết và kết quả khảo sát trong Chương 1.48
1.6.2. Ý nghĩa lý luận, thực tiễn và định hướng sang Chương 2..... 49
CHƯƠNG 2: PHƯƠNG PHÁP NGHIÊN CỨU..... 51
2.1. TỔNG QUAN PHƯƠNG PHÁP PHOBERT VÀ SVM.....51
2.1.1. PhoBERT - Mô hình trích xuất đặc trưng ngữ nghĩa.....51
2.1.1.1. Kiến trúc mô hình PhoBERT.....51
2.1.1.2. Dữ liệu và phương pháp tiền huấn luyện.....54
2.1.1.3. Ví dụ chi tiết quy trình trích xuất véc-tơ ngữ nghĩa từ văn bản đầu vào..... 55
2.1.2. SVM - Thuật toán phân loại tin tức..... 57
2.1.2.1. Kiến trúc và cơ sở toán học của SVM trong không gian 768 chiều 57
2.1.2.2. Lựa chọn Kernel (Linear vs RBF) và tham số phạt C,.....59
2.1.2.3. Nguyên lý tối ưu lề Margin 2||w|| và ví dụ phân loại bằng siêu phẳng wTx+b=0..... 60
2.1.3. Lý do chọn và tính bổ trợ giữa PhoBERT và SVM..... 62
2.1.3.1. Ưu điểm của PhoBERT trong xử lý tiếng Việt.....62
2.1.3.2. Ưu điểm của SVM trong phân loại.....62
2.1.3.3. Sự kết hợp PhoBERT-SVM giúp tối ưu hiệu năng và tài nguyên tính toán..... 63
2.2. QUY TRÌNH THU THẬP VÀ XỬ LÝ DỮ LIỆU..... 64

2.2.1. Nguồn dữ liệu và đặc điểm tập dữ liệu..... 65
2.2.1.1. Mô tả các nguồn dữ liệu tin giả tiếng Việt..... 65
2.2.1.2. Cấu trúc tổ chức dữ liệu: Article_Contents và Social_Contents. 65
2.2.1.3. Thống kê đặc điểm và phân bố tỷ lệ nhãn tập dữ liệu..... 66
2.2.2. Quy trình tiền xử lý văn bản tiếng Việt..... 67
2.2.2.1. Tầm quan trọng của tiền xử lý đối với dữ liệu mạng xã hội..... 67
2.2.2.2. Quy trình tiền xử lý văn bản tiếng Việt 5 bước chi tiết..... 67
2.2.2.3. Minh họa các bước biến đổi văn bản..... 68
2.2.3. Phân chia tập huấn luyện và kiểm tra..... 69
2.2.3.1. Nguyên tắc lấy mẫu ngẫu nhiên phân tầng (Stratified Sampling)... 69
2.2.3.2. Thống kê chi tiết tỷ lệ phân chia tập dữ liệu..... 70
2.2.3.3. Vai trò của việc phân chia dữ liệu đối với khả năng chống Overfitting..... 72
2.3. TRÍCH XUẤT ĐẶC TRƯNG BẰNG PhoBERT..... 72
2.3.1. Quy trình mã hóa văn bản với tokenizer..... 72
2.3.1.1. Sử dụng BPE Tokenizer và ánh xạ mã định danh (Token IDs)... 73
2.3.1.2. Cố định độ dài chuỗi đầu vào (Padding và Truncation)..... 73
2.3.1.3. Chuyển đổi thành PyTorch Tensors và DataLoader..... 74
2.3.2. Lấy embedding từ PhoBERT..... 74
2.3.2.1. Nạp mô hình tiền huấn luyện và thiết lập thông số kỹ thuật..... 74
2.3.2.2. Trích xuất véc-tơ biểu diễn từ token đặc biệt [CLS]..... 75
2.3.3. Lưu trữ đặc trưng đầu ra..... 77
2.3.3.1. Xây dựng ma trận đặc trưng cho toàn bộ tập dữ liệu..... 77
2.3.3.2. Tối ưu hóa hiệu năng và lưu trữ tệp số liệu..... 77

2.4.1.2. Chuẩn hóa tập dữ liệu véc-tơ đặc trưng bằng StandardScaler.....81
2.4.1.3. Thiết lập tham số dự đoán xác suất (probability=True)..... 82
2.4.2. Lựa chọn Kernel và điều chỉnh siêu tham số..... 82
2.4.2.1. So sánh hiệu năng giữa Linear Kernel và RBF Kernel..... 82
2.4.1.2. Chuẩn hóa tập dữ liệu véc-tơ đặc trưng bằng StandardScaler.....81
2.4.1.3. Thiết lập tham số dự đoán xác suất (probability=True)..... 82
2.4.2. Lựa chọn Kernel và điều chỉnh siêu tham số..... 82
2.4.2.1. So sánh hiệu năng giữa Linear Kernel và RBF Kernel..... 82
2.4.2.2. Phân tích tính phân tách tuyến tính của véc-tơ ngữ nghĩa PhoBERT..... 83
2.4.2.3. Tinh chỉnh siêu tham số phạt lỗi C (Penalty Parameter)..... 84
2.4.3. Huấn luyện, dự đoán và đóng gói mô hình..... 84
2.4.3.1. Quá trình huấn luyện toán học.....84
2.4.3.2. Quy trình dự đoán nhãn và xác suất trên tập Kiểm thử.....85
2.4.3.3. Đóng gói và lưu trữ trọng số mô hình..... 86
2.5. ĐÁNH GIÁ MÔ HÌNH..... 86
2.5.1. Các chỉ số đánh giá hiệu năng mô hình..... 87
2.5.1.1. Hệ thống chỉ số đo lường học máy tiêu chuẩn trong nhận diện tin giả..... 87
2.5.1.2. Thách thức phân loại trên tập dữ liệu mất cân bằng nhãn (70% Tin thật / 30% Tin giả).....87
2.5.2. Công thức toán học, ý nghĩa và cách tính toán chi tiết từng chỉ số..... 88
2.5.2.1. Ma trận nhầm lẫn (Confusion Matrix) và 4 thành phần cơ bản.. 88
2.5.2.2. Độ chính xác tổng thể (Accuracy).....89
2.5.2.3. Độ chính xác lớp (Precision)..... 90
2.5.2.4. Độ bao phủ / Độ nhạy (Recall).....90
2.5.2.5. Thang đo cân bằng F1-score.....91

2.5.2.6. Đường cong ROC và diện tích dưới đường cong AUC (Area Under Curve)..... 91
2.5.3. Phân tích chi phí và tác động của các dạng sai lệch dự đoán.....92
2.5.3.1. Phân tích tác động và chi phí rủi ro của lỗi False Positive (FP)..93
2.5.3.2. Phân tích tác động và chi phí rủi ro của lỗi False Negative (FN)... 93
2.6. TÓM TẮT CHƯƠNG 2..... 94
2.6.1. Tổng hợp các giai đoạn kỹ thuật cốt lõi trong phương pháp nghiên cứu. 94
2.6.2. Bảng tổng hợp các thông số kỹ thuật cốt lõi của hệ thống..... 96
2.6.3. Ý nghĩa khoa học và tiền đề chuyển giao sang Chương 3..... 97
Danh mục công trình của tác giả đã công bố.....99
Danh mục tài liệu tham khảo..... 100
Phụ lục.....102

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

1	AI	Artificial Intelligence
2	API	Application Programming Interface (Giao diện lập trình ứng dụng)
3	AUC	Area Under the Curve (Diện tích dưới đường cong)
4	BERT	Bidirectional Encoder Representations from Transformers
5	Bi-LSTM	Bidirectional Long Short-Term Memory
6	BoW	Bag-of-Words (Mô hình túi từ)
7	CNN	Convolutional Neural Network (Mạng nơ-ron tích chập)
8	CNN-BiLSTM	Convolutional Neural Network – Bidirectional Long Short-Term Memory
9	FN	False Negative (Âm tính giả)
10	FP	False Positive (Dương tính giả)
11	LSTM	Long Short-Term Memory
12	NLP	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
13	PhoBERT	Pre-trained Language Model for Vietnamese
14	REST	Representational State Transfer
15	ROC	Receiver Operating Characteristic

16	SVM	Support Vector Machine (Máy véc-tơ hỗ trợ)
17	TF-IDF	Term Frequency–Inverse Document Frequency
18	TN	True Negative (Âm tính thật)
19	TP	True Positive (Dương tính thật)
20	VFND	Vietnamese Fake News Dataset (Bộ dữ liệu tin giả tiếng Việt)

DANH MỤC CÁC BẢNG

Bảng 1.1. So sánh các kiến trúc NLP.....29

Bảng 1.2: So sánh tổng hợp đặc tính kỹ thuật giữa các nhóm phương pháp phân loại văn bản..... 35

Bảng 2.1: Minh họa quá trình biến đổi của câu văn bản qua 5 bước tiền xử lý chuyên biệt 68

Bảng 2.2: Thống kê chi tiết phân bố dữ liệu và số lượng mẫu trên các tập Train, Validation và Test 70

Bảng 2.3: Các thông số kỹ thuật cấu hình cho quá trình trích xuất đặc trưng ..... .75

Bảng 2.4: So sánh đặc tính kỹ thuật giữa Linear Kernel và RBF Kernel trong phân loại véc-tơ PhoBERT 82

Bảng 2.5: Cấu trúc Ma trận nhầm lẫn (Confusion Matrix) và phân định 4 thành phần TP, TN, FP, FN trong bài toán nhận diện tin giả nhị phân 88

Bảng 2.6: Bảng tổng hợp cấu trúc Ma trận nhầm lẫn trong bài toán phân loại tin tức nhị phân 89

Bảng 2.7: Phân tích so sánh tác động và chi phí rủi ro xã hội giữa lỗi False Positive và False Negative..... 92

DANH MỤC CÁC HÌNH VẼ

Hình 1.1: Mẫu dữ liệu các bài đăng tin tức văn bản thô chưa qua xử lý..... 17

Hình 1.2: Bảng dữ liệu dự đoán của các mô hình học máy trên phần mềm MedCalc.. 26

Hình 1.3: Kết quả so sánh đường cong ROC và chỉ số AUC giữa các mô hình học máy.....27

Hình 1.4: Ma trận nhầm lẫn (Intent Confusion Matrix) phân loại ý định văn bản bằng PhoBERT.....31

Hình 1.5: Quy trình 4 bước phân loại câu văn bản tiếng Việt bằng PhoBERT và Softmax..... 33

Hình 1.6: Kiến trúc mô hình đa phương pháp kết hợp PhoBERT và Swin Transformer V2.....34

Hình 1.7: Sơ đồ cấu trúc cây thư mục tập dữ liệu tin giả VFND (Fake_Real_Dataset).....41

Hình 1.9: Sơ đồ kiến trúc tổng thể và quy trình tương tác giữa Tiện ích mở rộng Chrome Extension và dịch vụ REST API.....47

Hình 2.1: Sơ đồ kiến trúc PHOBERT-BASE 12 tầng..... 52

Hình 2.2: Sơ đồ kiến trúc tổng thể 12 tầng Transformer Encoder của PhoBERT-base 54

Hình 2.3: Sơ đồ toán học mô tả siêu phẳng phân tách wTx+b=0 và khoảng cách lề Margin 2||w|| của thuật toán SVM.....59

Hình 2.4: Quy trình tổng quát nhận diện tin giả từ dữ liệu thô qua PhoBERT trích xuất véc-tơ 768 chiều đến bộ phân loại SVM.....64

Hình 2.5: Sơ đồ quy trình phân chia dữ liệu ngẫu nhiên thành các tập huấn luyện, xác thực và kiểm tra..... 71

Hình 2.6: Sơ đồ luồng quy trình mã hóa văn bản và chuẩn bị dữ liệu đầu vào..... 73

Hình 2.7: Minh họa các lệnh khởi tạo và huấn luyện mô hình Support Vector Classification (SVC) bằng thư viện Scikit-learn trong Python..... 81

LỜI MỞ ĐẦU

1. Lý do chọn đề tài

Trong những năm gần đây, sự phát triển nhanh chóng của các nền tảng mạng xã hội như Facebook, TikTok, X và các diễn đàn trực tuyến đã làm cho thông tin được lan truyền với tốc độ rất cao. Bên cạnh các thông tin chính thống, môi trường mạng xã hội cũng xuất hiện ngày càng nhiều tin giả, thông tin sai lệch hoặc thông tin bị bóp méo.

Tin giả có thể gây ra nhiều tác động tiêu cực như làm sai lệch nhận thức người dùng, tạo dư luận không chính xác, ảnh hưởng đến uy tín cá nhân/ tổ chức, tác động đến doanh nghiệp, thị trường và trong một số trường hợp có thể dẫn đến hệ quả nghiêm trọng đối với xã hội. Vì vậy, việc phát hiện sớm và hạn chế lan truyền tin giả là nhu cầu cấp thiết.

Tuy nhiên, với khối lượng dữ liệu rất lớn và tốc độ cập nhật liên tục trên mạng xã hội, phương pháp kiểm tra thủ công không còn phù hợp do tốn thời gian, nhân lực và khó mở rộng. Do đó, việc xây dựng phương pháp tự động nhận diện và phân loại tin giả dựa trên nội dung văn bản là hướng tiếp cận cần thiết và có tính ứng dụng cao.

Đối với dữ liệu tiếng Việt, các phương pháp biểu diễn văn bản truyền thống còn gặp hạn chế trong việc thể hiện ngữ cảnh và quan hệ ngữ nghĩa giữa các từ. PhoBERT là mô hình ngôn ngữ tiền huấn luyện cho tiếng Việt, có khả năng biểu diễn ngữ nghĩa theo ngữ cảnh và đã cho kết quả tốt trong nhiều bài toán xử lý ngôn ngữ tự nhiên. Bên cạnh đó, Support Vector Machine (SVM) là thuật toán học máy phổ biến, có hiệu quả ổn định trong các bài toán phân loại văn bản.

Từ những cơ sở trên, nhóm lựa chọn đề tài: “Ứng dụng kỹ thuật tiền xử lý văn bản và học máy (PhoBERT, SVM) trong nhận diện tin giả tiếng Việt trên mạng xã hội.”

2. Lịch sử nghiên cứu vấn đề / Tổng quan

Nhận diện tin giả là một hướng nghiên cứu quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên và khai phá dữ liệu, đặc biệt trong bối cảnh thông tin trên mạng xã hội gia tăng nhanh cả về số lượng lẫn mức độ ảnh hưởng.

Ở giai đoạn đầu, việc phát hiện tin giả chủ yếu dựa trên phương pháp kiểm chứng thủ công bởi chuyên gia hoặc các tổ chức kiểm chứng thông tin. Mặc dù có độ tin cậy cao, phương pháp này có nhược điểm là tốn thời gian, chi phí lớn và khó đáp ứng yêu cầu xử lý dữ liệu quy mô lớn theo thời gian thực.

Để nâng cao khả năng tự động hóa, nhiều nghiên cứu đã áp dụng các thuật toán học máy truyền thống, xem bài toán nhận diện tin giả là bài toán phân lớp văn bản. Các mô hình thường được sử dụng gồm Naive Bayes, Logistic Regression, Random Forest và SVM; trong đó SVM được đánh giá có hiệu quả ổn định đối với dữ liệu văn bản nhiều chiều. Các kỹ thuật biểu diễn văn bản phổ biến trong giai đoạn này là Bag-of-Words, Term Frequency–Inverse Document Frequency (TF-IDF) và N-gram, kết hợp với các bước tiền xử lý dữ liệu.

Trong những năm gần đây, các mô hình học sâu và mô hình ngôn ngữ tiền huấn luyện phát triển mạnh, giúp cải thiện đáng kể hiệu quả phân loại nhờ khả năng nắm bắt ngữ cảnh tốt hơn. Đối với tiếng Việt, PhoBERT là mô hình tiền huấn luyện tiêu biểu, đã được ứng dụng trong nhiều bài toán NLP - Natural Language Processing (Xử lý ngôn ngữ tự nhiên) và cho kết quả khả quan. Việc kết hợp PhoBERT để trích xuất đặc trưng ngữ nghĩa với thuật toán phân lớp như SVM là một hướng nghiên cứu có tính khả thi.

Tại Việt Nam, nghiên cứu về nhận diện tin giả đang ngày càng được quan tâm, tuy nhiên vẫn tồn tại một số hạn chế như: dữ liệu tiếng Việt gán nhãn còn hạn chế, dữ liệu mạng xã hội có độ nhiễu cao (viết tắt, sai chính tả, tiếng lóng, pha trộn ngôn

ngữ), và chưa có nhiều nghiên cứu xây dựng quy trình thực nghiệm thống nhất cho từng nguồn dữ liệu cụ thể.

Từ tổng quan trên, đề tài định hướng nghiên cứu theo hướng: ứng dụng kỹ thuật tiền xử lý văn bản kết hợp PhoBERT và SVM để nhận diện tin giả trên mạng xã hội. Hướng tiếp cận này phù hợp với điều kiện thực hiện của nhóm, đồng thời có ý nghĩa thực tiễn trong hỗ trợ phát hiện thông tin sai lệch trên môi trường mạng xã hội.

3. Mục đích và nhiệm vụ nghiên cứu

3.1. Mục đích nghiên cứu

Mục đích tổng quát của đề tài là nghiên cứu, thiết kế và xây dựng một hệ thống tự động nhận diện tin giả trên mạng xã hội dựa trên nội dung văn bản tiếng Việt. Hệ thống này kết hợp quy trình tiền xử lý văn bản mạng xã hội chuyên biệt, mô hình ngôn ngữ tiền huấn luyện PhoBERT đóng vai trò trích xuất biểu diễn ngữ nghĩa theo ngữ cảnh và thuật toán Support Vector Machine (SVM) đóng vai trò bộ phân loại tối ưu.

Mục tiêu cụ thể bao gồm:

- **Xây dựng giải pháp kỹ thuật:** Thiết lập quy trình tiền xử lý dữ liệu tự động loại bỏ độ nhiễu đặc thù của văn bản trên mạng xã hội (teencode, icon/emoji, từ viết tắt, URL).
- **Tối ưu hóa mô hình phân loại:** Kết hợp véc-tơ đặc trưng 768 chiều từ PhoBERT với khả năng xác định siêu phẳng phân tách của SVM nhằm nâng cao độ chính xác nhận diện tin giả.
- **Đánh giá và kiểm chứng:** Thực nghiệm mô hình trên tập dữ liệu thực tế, phân tích hiệu năng thông qua ma trận nhầm lẫn (Confusion Matrix) và các độ đo chuẩn mực (Accuracy, Precision, Recall, F1-score).

Triển khai mô hình đã huấn luyện thành dịch vụ sử dụng giao diện lập trình ứng dụng (Application Programming Interface - API) theo kiểu kiến trúc REST

(Representational State Transfer) và tích hợp vào tiện ích mở rộng Chrome (Chrome Extension) để hỗ trợ cảnh báo tin giả trực tiếp cho người dùng.

3.2. Nhiệm vụ nghiên cứu

Để đạt được các mục đích trên, đề tài đề ra 8 nhiệm vụ nghiên cứu cụ thể được triển khai theo trình tự logic sau:

Nghiên cứu cơ sở lý thuyết: Tổng quan các khái niệm về tin giả, các tác động xã hội của tin giả, lý thuyết xử lý ngôn ngữ tự nhiên (NLP) và các phương pháp phân loại văn bản tự động.

Nghiên cứu kỹ thuật tiền xử lý văn bản tiếng Việt: Khảo sát các đặc điểm nhiễu ngôn ngữ trên mạng xã hội (tiếng lóng, viết tắt, ký tự đặc biệt, cấu trúc link) và xây dựng bộ công cụ tiền xử lý, chuẩn hóa phù hợp.

Nghiên cứu mô hình PhoBERT: Tìm hiểu kiến trúc Transformer, cơ chế Masked Language Modeling của PhoBERT, cách sử dụng mô hình pre-trained để trích xuất véc-tơ đặc trưng tại vị trí token [CLS].

Nghiên cứu thuật toán SVM: Tìm hiểu nguyên lý hoạt động của Support Vector Machine, các hàm nhân (Kernel functions) và phương pháp tối ưu siêu tham số cho bài toán phân loại nhị phân.

Thu thập và chuẩn hóa dữ liệu: Tổng hợp, làm sạch và gán nhãn tập dữ liệu tin tức tiếng Việt trên mạng xã hội, phân chia thành các tập huấn luyện (Train), xác thực (Validation) và kiểm tra (Test).

Xây dựng mô hình kết hợp PhoBERT-SVM: Cài đặt quy trình trích xuất véc-tơ biểu diễn từ PhoBERT và đưa vào mô hình SVM để huấn luyện, tinh chỉnh các tham số tối ưu.

Thực nghiệm và đánh giá kết quả: Đo lường hiệu năng mô hình trên tập kiểm tra, phân tích ma trận nhầm lẫn, đánh giá các trường hợp đoán đúng/sai và so sánh với

các mô hình tham chiếu (Naive Bayes, Long Short-Term Memory (LSTM), Convolutional Neural Network (CNN)).

Đề xuất giải pháp và hướng phát triển: Đúc kết các hạn chế của mô hình, đề xuất giải pháp cải tiến hiệu năng và hoàn thiện giao diện ứng dụng thực tế.

4. Đối tượng và phạm vi nghiên cứu

4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài bao gồm các thành phần lý thuyết, dữ liệu và công nghệ sau:

- **Dữ liệu văn bản mạng xã hội:** Các bài đăng (posts), bài chia sẻ và nội dung văn bản tiếng Việt được cập nhật trên nền tảng mạng xã hội.
- **Thực thể thông tin:** Các bài viết được dán nhãn phân loại thành Tin thật (Real News) và Tin giả (Fake News).
- **Kỹ thuật tiền xử lý văn bản:** Các thuật toán làm sạch ký tự nhiễu, chuẩn hóa teencode, loại bỏ URL/hashtag và công cụ phân tách từ tiếng Việt (VnCoreNLP / RDRSegmenter).
- **Mô hình PhoBERT:** Kiến trúc Transformer tiền huấn luyện chuyên biệt cho tiếng Việt (phiên bản PhoBERT-base) được sử dụng làm bộ trích xuất đặc trưng.
- **Thuật toán SVM:** Bộ phân loại Support Vector Machine với các cấu hình hàm nhân (Linear, RBF).

Hệ thống chỉ số đánh giá: Bảng ma trận nhầm lẫn (Confusion Matrix) và các độ đo định lượng Accuracy, Precision, Recall, F1-score.

4.2. Phạm vi nghiên cứu

Đề tài xác định rõ các ranh giới và giới hạn nghiên cứu nhằm đảm bảo tính khả thi và tập trung sâu vào mục tiêu chính:

- **Phạm vi dữ liệu:** Giới hạn ở tập dữ liệu văn bản tiếng Việt có nội dung liên quan đến các bài đăng hoặc được lan truyền trên mạng xã hội.
- **Phạm vi bài toán:** Giới hạn ở bài toán phân loại nhị phân (Binary Classification) gồm 2 nhãn duy nhất: Tin thật và Tin giả. Đề tài không đi sâu vào phân loại đa nhãn hoặc phân chia tin tức thành nhiều cấp độ tin cậy; điểm tin cậy của kết quả dự đoán chỉ được sử dụng để biểu thị mức độ chắc chắn của mô hình đối với nhãn được dự đoán.
- **Phạm vi phương thức:** Tập trung duy nhất vào phương thức văn bản. Đề tài không phân tích các kênh dữ liệu đa phương thức như hình ảnh, video, âm thanh hoặc đồ thị mạng lưới tương tác của người dùng (likes, shares, comments network).
- **Phạm vi công nghệ:** Áp dụng PhoBERT làm bộ trích xuất đặc trưng ngữ nghĩa tĩnh/đã đóng đóng băng trọng số kết hợp bộ phân loại SVM.
- **Phạm vi đánh giá:** Đánh giá hiệu năng dựa trên các bộ dữ liệu thử nghiệm trong phòng thí nghiệm thông qua các chỉ số đo lường học máy tiêu chuẩn.

5. Phương pháp nghiên cứu

5.1. Phương pháp nghiên cứu lý thuyết

Tổng quan tin giả & NLP: Nghiên cứu khái niệm tin giả, thông tin sai lệch và đặc điểm phi cấu trúc của văn bản trên mạng xã hội (chứa teencode, icon, hashtag, URL).

Tiền xử lý & Tách từ tiếng Việt: Khảo sát đặc thù ngôn ngữ đơn lập của tiếng Việt và ứng dụng công cụ RDRSegmenter (VnCoreNLP) để phân tách từ ghép.

Mô hình PhoBERT: Tìm hiểu kiến trúc Transformer/RoBERTa tiền huấn luyện trên 20GB dữ liệu tiếng Việt.

Thuật toán SVM: Nghiên cứu nguyên lý phân loại bằng siêu phẳng tối ưu trên không gian nhiều chiều, kết hợp tìm kiếm siêu tham số) và hàm nhân (Kernel) phù hợp.

5.2. Phương pháp thu thập và xử lý dữ liệu

Nguồn dữ liệu: Khai thác các tập dữ liệu tin giả tiếng Việt gán nhãn sẵn như VFND (Vietnamese Fake News Dataset) và ReINTEL.

Quy trình tiền xử lý (5 bước):

1. Loại bỏ ký tự rác, thẻ HTML và chuẩn hóa Unicode (NFC).
2. Chuẩn hóa link web thành HTTPURL, nhắc tên thành @USER.
3. Chuyển đổi/loại bỏ emoji và teencode về từ chuẩn.
4. Phân tách từ ghép tiếng Việt bằng RDRSegmenter (VnCoreNLP).
5. Loại bỏ bản ghi rỗng hoặc trùng lặp.

Phân chia dữ liệu: Chia ngẫu nhiên theo tỷ lệ 80% Train (huấn luyện), 10% Validation (tinh chỉnh tham số) và 10% Test (kiểm tra độc lập)

5.3. Phương pháp thực nghiệm

Quy trình nghiên cứu dự kiến:

Thu thập dữ liệu → Tiền xử lý văn bản → PhoBERT → Trích xuất đặc trưng → SVM → Phân loại Fake/Real → Đánh giá kết quả

Tiến hành thực nghiệm với các bộ dữ liệu khác nhau hoặc các cấu hình xử lý khác nhau để đánh giá ảnh hưởng của bước tiền xử lý và mô hình đến kết quả nhận diện.

5.4. Phương pháp đánh giá

Mô hình được đánh giá trên tập dữ liệu kiểm thử (test set) thông qua các chỉ số sau:

- **Accuracy:** Đánh giá tỷ lệ dự đoán đúng trên tổng số mẫu kiểm thử.
- **Precision:** Đánh giá độ tin cậy của các dự đoán thuộc lớp dương.
- **Recall:** Đánh giá khả năng nhận diện các mẫu thực tế thuộc lớp dương.
- **F1-score:** Đánh giá sự cân bằng giữa Precision và Recall.
- **Confusion Matrix:** Thống kê số lượng mẫu được phân loại đúng và số lượng mẫu bị phân loại nhầm giữa hai lớp.

Các chỉ số được sử dụng để phân tích kết quả phân loại của mô hình trên tập kiểm thử. Kết quả thực nghiệm được tổng hợp và so sánh nhằm đánh giá hiệu quả của mô hình PhoBERT-SVM trong bài toán phân loại tin giả.

6. Giả thuyết khoa học

6.1. Cơ sở luận hình thành giả thuyết

Mạng xã hội hiện nay là không gian tương tác trực tuyến có lượng dữ liệu văn bản tiếng Việt cực kỳ lớn và tăng trưởng liên tục. Tuy nhiên, đặc thù ngôn ngữ trên mạng xã hội mang tính phi cấu trúc cao, chứa nhiều độ nhiễu như từ viết tắt, teencode, icon/emoji, hashtag, liên kết nhúng và các lỗi chính tả tự do. Các phương pháp phân loại văn bản truyền thống thường gặp hạn chế do chỉ dựa trên tần suất xuất hiện của từ mà bỏ qua ngữ cảnh và mối quan hệ ngữ nghĩa giữa các từ trong câu.

Sự ra đời của mô hình ngôn ngữ tiền huấn luyện PhoBERT — kiến trúc Transformer được huấn luyện trên 20GB dữ liệu tiếng Việt chuyên biệt — đã tạo ra bước tiến mới. PhoBERT có khả năng mã hóa các đặc trưng ngữ nghĩa theo ngữ cảnh hai chiều sâu sắc, giúp đại diện văn bản dưới dạng các véc-tơ đa chiều giàu thông tin (như véc-tơ đại diện tại vị trí token). Ở tầng phân loại, thuật toán Support Vector Machine (SVM) có ưu thế vượt trội trong việc xác định siêu phẳng tối ưu để phân tách dữ liệu trên không gian nhiều chiều, có độ ổn định cao và hạn chế hiện tượng quá khớp (overfitting).

Từ các cơ sở lý thuyết và thực tiễn trên, nghiên cứu đặt ra giả định rằng việc làm sạch và chuẩn hóa dữ liệu văn bản tiếng Việt trên mạng xã hội sẽ tạo tiền đề cho PhoBERT trích xuất đặc trưng ngữ nghĩa chính xác, từ đó giúp SVM tối ưu ranh giới phân loại nhị phân giữa Tin thật và Tin giả.

6.2. Phát biểu các giả thuyết khoa học cụ thể

Giả thuyết H1 (Giả thuyết tổng thể): Sự kết hợp giữa quy trình tiền xử lý văn bản tiếng Việt chuyên biệt cho mạng xã hội, kỹ thuật trích xuất véc-tơ đặc trưng ngữ nghĩa bằng mô hình PhoBERT và thuật toán phân loại SVM sẽ tạo ra một mô hình nhận diện tin giả tự động đạt hiệu năng cao (thể hiện qua các độ đo Accuracy, Precision, Recall và F1-score).

Giả thuyết H2 (Giả thuyết về tác động của tiền xử lý dữ liệu): Chất lượng và cách thức tiền xử lý dữ liệu (loại bỏ URL, làm sạch teencode, chuẩn hóa icon/emoji và tách từ ghép bằng công cụ chuyên dụng như RDRSegmenter/VnCoreNLP) có ảnh hưởng đáng kể và thuận chiều đến chất lượng véc-tơ nhúng của PhoBERT cũng như độ chính xác phân loại của mô hình SVM.

Giả thuyết H3 (Giả thuyết về hiệu quả của mô hình PhoBERT-SVM): Mô hình lai (hybrid) PhoBERT-SVM cho khả năng tổng quát hóa tốt hơn, hạn chế sai số và đạt kết quả nhận diện tin giả ổn định hơn so với việc sử dụng các mô hình học máy truyền thống dựa trên trích xuất đặc trưng thô.

7. Những đóng góp mới

7.1. Xây dựng quy trình tiền xử lý dữ liệu chuyên biệt cho văn bản tiếng Việt trên mạng xã hội

Bối cảnh & Thách thức: Văn bản mạng xã hội chứa rất nhiều độ nhiễu như từ viết tắt, biểu tượng cảm xúc, từ lóng, đường dẫn liên kết và lỗi gõ phím. Nếu đưa trực tiếp dữ liệu thô vào mô hình, các từ ngữ nhiễu này sẽ làm giảm độ chính xác của hệ thống.

Đóng góp của đề tài: Đề tài đề xuất quy trình tiền xử lý tự động gồm các bước chuẩn hóa được tối ưu hóa:

Làm sạch dữ liệu rác: Loại bỏ đường dẫn web (thay bằng ký hiệu chuẩn), gạt bỏ các ký tự đặc biệt vô nghĩa.

Chuẩn hóa ngôn ngữ mạng xã hội: Chuyển đổi các từ teencode và từ viết tắt về dạng từ tiếng Việt chuẩn mực (ví dụ: "ko" ->"không", "đc" ->"được").

Bảo tồn ngữ nghĩa cảm xúc: Chuyển đổi các biểu tượng cảm xúc thành từ ngữ diễn đạt tương ứng thay vì xóa bỏ hoàn toàn, giúp mô hình giữ lại thái độ của bài viết.

Phân tách từ ghép tiếng Việt: Tích hợp công cụ tách từ ghép (RDRSegmenter) để liên kết các từ ghép (như "tin_giả", "mạng_xã_hội"), giúp máy tính hiểu đúng khái niệm trong tiếng Việt đơn lập.

7.2. Ứng dụng PhoBERT để khai thác sâu đặc trưng ngữ nghĩa theo ngữ cảnh

Bối cảnh & Thách thức: Các phương pháp đếm từ truyền thống chỉ nhìn vào từ ngữ rời rạc mà bỏ qua thứ tự và ngữ cảnh trong câu, dẫn đến việc không hiểu được các câu văn mỉa mai hoặc cấu trúc phức tạp.

Đóng góp của đề tài: Đề tài ứng dụng mô hình PhoBERT để mã hóa toàn bộ câu văn thành véc-tơ ngữ nghĩa 768 chiều. Véc-tơ này cô đọng trọn vẹn ngữ cảnh và mối quan hệ giữa các từ trong bài đăng, giúp hệ thống "hiểu" được bản chất nội dung tin tức thay vì chỉ tìm kiếm từ khóa đơn lẻ.

7.3. Đề xuất mô hình kết hợp giữa PhoBERT và Máy véc-tơ hỗ trợ (SVM)

Bối cảnh & Thách thức: Việc tinh chỉnh toàn bộ mô hình học sâu đòi hỏi máy tính cấu hình rất mạnh, thời gian tính toán lâu và dễ bị hiện tượng quá khớp (học vẹt) khi tập dữ liệu nhỏ.

Đóng góp của đề tài: Đề tài đề xuất giải pháp kết hợp thông minh:

- PhoBERT đóng vai trò là bộ trích xuất véc-tơ đặc trưng ngữ nghĩa.
- SVM đóng vai trò là bộ phân loại tối ưu, chịu trách nhiệm tìm đường ranh giới phân tách giữa hai lớp Tin thật và Tin giả trong không gian nhiều chiều.

Ý nghĩa: Tận dụng tối đa khả năng hiểu ngữ nghĩa của PhoBERT và tốc độ phân loại nhanh, chính xác, tốn ít tài nguyên của SVM.

7.4. Thực nghiệm toàn diện và đánh giá khách quan trên tập dữ liệu tiếng Việt

Đóng góp của đề tài: Đề tài triển khai thực nghiệm bài bản trên các tập dữ liệu tin giả tiếng Việt thực tế:

- Xây dựng bộ chỉ số đánh giá đa chiều (Độ chính xác tổng thể, Độ chính xác, Độ nhạy, Điểm F1) và Ma trận nhầm lẫn.
- Tiến hành đối sánh trực tiếp giữa mô hình PhoBERT-SVM với các phương pháp truyền thống, cung cấp luận cứ khoa học chứng minh tính vượt trội của giải pháp đề xuất.

7.5. Phân tích chuyên sâu các trường hợp dự đoán sai

Đóng góp của đề tài: Đề tài đi sâu phân tích nguyên nhân các trường hợp đoán sai trên tập kiểm tra:

- **Trường hợp Tin thật bị đoán nhầm thành tin giả:** Thường do bài viết chứa từ ngữ cảm xúc mạnh hoặc tiêu đề giật tít.
- **Trường hợp Tin giả bị bỏ sót:** Thường do tin giả được viết theo văn phong báo chí chính thống, trích dẫn nguồn giả mạo tinh vi.

Ý nghĩa: Giúp xác định rõ ranh giới năng lực của mô hình, tránh việc thần thánh hóa trí tuệ nhân tạo và đặt nền móng cho các cải tiến tiếp theo.

7.6. Đề xuất ứng dụng thực tế (Tiện ích mở rộng trên trình duyệt)

Đóng góp của đề tài: Đề tài hiện thực hóa mô hình nghiên cứu thành sản phẩm thực tế bằng cách triển khai mô hình lên máy chủ giao tiếp ứng dụng (REST API) và tích hợp vào Tiện ích mở rộng trên trình duyệt Chrome. Tiện ích này tự động quét bài đăng trên mạng xã hội và hiển thị cảnh báo tin thật/tin giả trực tiếp cho người dùng theo thời gian thực.

8. Cấu trúc của Đồ Án Chuyên Ngành: Ngoài phần mở đầu, kết luận, danh mục tài liệu tham khảo và phụ lục, Đồ Án Chuyên Ngành gồm có 3 chương:

Chương 1: Giới thiệu về nhận diện tin giả Trình bày tổng quan về tin giả (khái niệm, phân loại, bối cảnh bùng nổ trên mạng xã hội và tác động xã hội); các phương pháp phát hiện tin giả truyền thống và tự động; khảo sát các công trình liên quan (dữ liệu ReINTEL, VFND, mô hình LSTM, Bidirectional Long Short-Term Memory (Bi-LSTM), CNN-BiLSTM, PhoBERT); nhận diện các thách thức đặc thù đối với dữ liệu tiếng Việt; đồng thời phân tích lý do lựa chọn giải pháp kết hợp **PhoBERT và SVM** cùng khả năng ứng dụng thực tế.

Chương 2: Phương pháp nghiên cứu Trình bày chi tiết phương pháp luận và mô hình toán học kết hợp **PhoBERT-SVM**; quy trình thu thập, làm sạch và tiền xử lý dữ liệu 5 bước (chuẩn hóa Unicode, xử lý teencode/emoji, loại bỏ URL/Hashtag, phân tách từ ghép bằng RDRSegmenter VnCoreNLP và đồng nhất độ dài max_length = 256); phân chia dữ liệu ngẫu nhiên phân tầng (Train 80%, Validation 10%, Test 10%); kỹ thuật trích xuất véc-tơ ngữ nghĩa 768 chiều từ PhoBERT; xây dựng, tối ưu siêu phẳng phân tách SVM với Linear Kernel; và thiết lập hệ thống đo lường hiệu năng (Accuracy, Precision, Recall, F1-score, Confusion Matrix).

Chương 3: Thực nghiệm và xây dựng ứng dụng Trình bày chi tiết cấu hình môi trường thực nghiệm (phần cứng, phần mềm, thư viện Python); kết quả huấn luyện, dự đoán và đánh giá định lượng mô hình trên tập kiểm tra độc lập; phân tích, thảo luận về hiệu suất phân loại và các hạn chế của mô hình; so sánh đối sánh

PhoBERT-SVM với các mô hình baseline; quy trình đóng gói mô hình thành tệp trọng số (svm_model.pkl), triển khai dịch vụ **REST API bằng Flask Server** và tích hợp vào **Tiện ích mở rộng Chrome Extension** phục vụ cảnh báo tin giả trực tiếp theo thời gian thực.

CHƯƠNG 1. GIỚI THIỆU VỀ NHẬN DIỆN TIN GIẢ

1.1. TỔNG QUAN VỀ TIN GIẢ

1.1.1. Khái niệm và Bối cảnh phát sinh Tin giả

1.1.1.1. Bối cảnh bùng nổ thông tin trên mạng xã hội tại Việt Nam

Trong kỷ nguyên chuyển đổi số và Cách mạng Công nghiệp 4.0, sự phát triển bùng nổ của hạ tầng Internet cùng các nền tảng mạng xã hội xuyên biên giới (Facebook, TikTok, YouTube, X/Twitter, Zalo) đã tái định hình toàn bộ phương thức sản xuất, truyền tải và tiếp nhận thông tin của xã hội. Tính đến những năm gần đây, Việt Nam có hàng chục triệu tài khoản mạng xã hội hoạt động thường xuyên, biến không gian mạng thành môi trường tương tác phi tập trung, nơi bất kỳ người dùng nào cũng có thể đóng vai trò là một "nhà xuất bản" nội dung độc lập.

Đặc trưng cốt lõi của mạng xã hội là tốc độ lan truyền tính bằng mili giây, cơ chế phân phối thuật toán gợi ý (recommendation algorithms) dựa trên mức độ tương tác (likes, shares, comments), và tính chất ẩn danh tương đối. Cơ chế này vô hình trung tạo ra hiệu ứng "phòng phản chiếu" (echo chambers), trong đó các thông tin giật gân, ly kỳ thường thu hút sự chú ý mạnh mẽ hơn so với các tin tức báo chí chính thống. Bên cạnh những giá trị tích cực về kết nối và chia sẻ tri thức, tính chất mở và thiếu kiểm duyệt tiền kiểm của không gian mạng đã trở thành dung thổ thuận lợi cho sự bùng phát của tin giả (Fake News), thông tin sai lệch (Misinformation) và thông tin độc hại bị xuyên tạc (Disinformation) với quy mô và mật độ ngày càng phức tạp.

1.1.1.2. Định nghĩa khoa học về Tin giả (Fake News)

Dưới góc độ khoa học dữ liệu và truyền thông hiện đại, Tin giả (Fake News) được định nghĩa là những thông tin không đúng sự thật, thông tin bịa đặt hoàn toàn hoặc bị bóp méo một phần thực tế, được cố ý tạo ra và phát tán dưới hình thức các bài báo, bài đăng mạng xã hội hay bản tin truyền thông nhằm mục đích lừa dối công chúng, điều hướng dư luận, phục vụ ý đồ chính trị hoặc thu lợi bất chính [6].

Theo từ điển Cambridge, Fake News được định nghĩa là *"những câu chuyện sai sự thật xuất hiện dưới dạng tin tức, lan truyền trên Internet hoặc phương tiện truyền thông khác, thường được tạo ra để ảnh hưởng đến quan điểm chính trị hoặc như một trò đùa"*. Năm 2017, cụm từ này đã chính thức trở thành "Từ của năm" do từ điển Collins lựa chọn, phản ánh mức độ báo động toàn cầu về hiện tượng này. Trong ngữ cảnh không gian mạng Việt Nam, tin giả không chỉ dừng lại ở các bài viết chữ thô (plain text) mà còn biến tướng dưới nhiều hình thức kết hợp tinh vi nhằm qua mặt các công cụ lọc từ khóa truyền thống [6].

1.1.1.3. Phân biệt Fake News, Misinformation và Disinformation

Để xây dựng các mô hình xử lý ngôn ngữ tự nhiên (NLP) phân loại chính xác, việc phân định ranh giới lý luận giữa ba thuật ngữ thường bị đánh đồng trong truyền thông là vô cùng cấp thiết:

- **Misinformation (Thông tin sai lệch vô ý):** Là những thông tin không chính xác hoặc sai sự thật, nhưng người tạo ra hoặc chia sẻ không nhận thức được tính sai lệch và không có động cơ cố ý gây hại cho cộng đồng. Ví dụ: Người dùng chia sẻ lại một mẹo chữa bệnh dân gian chưa được kiểm chứng khoa học vì tin rằng nó có ích cho bạn bè.
- **Disinformation (Thông tin độc hại cố ý):** Là những thông tin sai sự thật được cố tình sáng tạo, thêu dệt, dàn dựng và phát tán có hệ thống với mục đích rõ ràng nhằm gây tổn hại đến cá nhân, tổ chức, gây hoảng loạn xã hội hoặc xâm phạm an ninh quốc gia.
- **Fake News (Tin giả):** Là dạng thức thể hiện nội dung cụ thể và phổ biến nhất của Disinformation, trong đó đối tượng sử dụng văn phong báo chí, định dạng tin tức hoặc cấu trúc giao diện mạng xã hội để mạo danh sự thật.

1.1.1.4. Tác động tiêu cực của tin giả đối với xã hội và an ninh quốc gia

Tác hại của tin giả không dừng lại ở mức độ phiền nhiễu thông tin mà đã trở thành một nguy cơ an ninh phi truyền thống trực tiếp đối với xã hội và quốc gia [8]:

- **Gây tổn hại an ninh quốc gia và trật tự an toàn xã hội:** Các thế lực thù địch và đối tượng bất mãn thường xuyên lợi dụng sự cố xã hội, thiên tai, dịch bệnh để thêu dệt tin giả, bôi nhọ lãnh đạo, kích động chia rẽ khối đại đoàn kết dân tộc. Thống kê cho thấy trung bình mỗi tháng có hàng chục nghìn bài viết và video xuyên tạc được phát tán trên các nền tảng mạng xã hội.
- **Gây hoang mang dư luận và khủng hoảng tâm lý cộng đồng:** Tin giả về dịch bệnh, tình hình an ninh trật tự hay thiên tai gây ra làn sóng tích trữ hàng hóa, hoảng loạn tâm lý và làm suy giảm niềm tin của nhân dân vào các cơ quan quản lý nhà nước [8].
- **Thiệt hại kinh tế nặng nề cho doanh nghiệp:** Các tin đồn thất thiệt về thương hiệu bị bôi nhọ, sản phẩm chứa chất độc hại hoặc doanh nghiệp phá sản khiến giá cổ phiếu sụt giảm, người tiêu dùng tẩy chay, gây thiệt hại hàng tỷ đồng trong thời gian ngắn.
- **Xói mòn giá trị tri thức và quyền tiếp nhận thông tin:** Tin giả làm nhiễu loạn môi trường tri thức, khiến công sống mất phương hướng trong việc phân biệt giữa tri thức khoa học và thông tin bịa đặt [8].

1.1.2. PHÂN LOẠI TIN GIẢ TRÊN MẠNG XÃ HỘI

1.1.2.1. Phân loại theo động cơ và mục đích phát tán

Dựa trên khảo sát thực tế dữ liệu mạng xã hội Việt Nam và các công trình nghiên cứu lý thuyết tổng quan, tin giả được chia thành các nhóm động cơ chính [9]:

- **Tin giả trục lợi kinh tế (Financial Motivation / Clickbait):**
  - **Đặc điểm:** Sử dụng tiêu đề giật tít, giật gân, cắt ghép scandal về người nổi tiếng hoặc sự kiện nhạy cảm.
  - **Mục tiêu:** Thu hút lượng nhấp chuột (clicks) và chia sẻ (shares) cực lớn nhằm tăng traffic cho trang web, phục vụ bán hàng online, chạy quảng cáo thương mại hoặc lừa đảo chiếm đoạt tài sản.
- **Tin giả tác động Chính trị - An ninh (Political Motivation):**
  - **Đặc điểm:** Giả mạo phát ngôn của cán bộ, xuyên tạc văn bản pháp luật, cắt ghép hình ảnh sự kiện để nói sai sự thật.

+ **Mục tiêu:** Định hướng dư luận theo chiều hướng tiêu cực, gây bất mãn, kích động biểu tình hoặc làm suy giảm uy tín của bộ máy chính quyền.

- **Tin giả bôi nhọ cá nhân và mâu thuẫn thương mại (Defamation / Commercial Rivalry):**
  + **Đặc điểm:** Thêu dệt các câu chuyện đời tư, dàn dựng bằng chứng giả nhằm xúc phạm danh dự cá nhân hoặc hạ thấp uy tín đối thủ cạnh tranh trên thị trường.
  + **Mục tiêu:** Làm tổn hại danh tiếng, gây mất niềm tin của công chúng đối với cá nhân hoặc doanh nghiệp bị nhắm đến, từ đó tạo lợi thế cho bên phát tán thông tin trong các mối quan hệ xã hội hoặc hoạt động cạnh tranh thương mại.

1.1.2.2. Phân loại theo hình thức biểu diễn dữ liệu (Data Modality)

Dưới góc độ Xử lý ngôn ngữ tự nhiên và Thị giác máy tính, tin giả được phân chia theo dạng thức lưu trữ dữ liệu:

- **Dạng Văn bản thô (Unstructured Plain Text):** Các bài đăng (posts), câu dòng trạng thái (status), bài chia sẻ hoặc đoạn bình luận (comments) chứa câu từ bịa đặt. Đây là đối tượng nghiên cứu chính của đề tài.

	A	B	C	D
1	title	text	subject	date
2	Donald Trump Sends Out Embar	Donald Trump just couldn t wish all Americans a Happy	News	31-Dec-17
3	Drunk Bragging Trump Staffer St	House Intelligence Committee Chairman Devin Nunes i	News	31-Dec-17
4	Sheriff David Clarke Becomes Ar	On Friday, it was revealed that former Milwaukee Sheri	News	30-Dec-17
5	Trump Is So Obsessed He Even H	On Christmas day, Donald Trump announced that he wc	News	29-Dec-17
6	Pope Francis Just Called Out Dor	Pope Francis used his annual Christmas Day message to	News	25-Dec-17
7	Racist Alabama Cops Brutalize B	The number of cases of cops brutalizing and killing peo	News	25-Dec-17
8	Fresh Off The Golf Course, Trum	Donald Trump spent a good portion of his day at his gol	News	23-Dec-17
9	Trump Said Some INSANELY Raci	In the wake of yet another court decision that derailed	News	23-Dec-17
10	Former CIA Director Slams Trum	Many people have raised the alarm regarding the fact tl	News	22-Dec-17

Hình 1.1: Mẫu dữ liệu các bài đăng tin tức văn bản thô chưa qua xử lý

Nguồn: Bùi Công Tùng và cs., 2022

- **Dạng Bài đăng nhúng Liên kết ngoại (URL Posts):** Bài viết bao gồm một đoạn tóm tắt ngắn kèm đường dẫn (hyperlink) trỏ về các trang web báo lá cải, trang web giả mạo giao diện báo chính thống.
- **Dạng Văn bản nhúng trong Hình ảnh (Text-in-Image / Meme):** Thông tin giả mạo được thiết kế thành các bức ảnh trích dẫn (quote), ảnh chụp màn hình bài báo đã bị chỉnh sửa bằng công cụ đồ họa.
- **Dạng Đa phương thức (Multimodal Data):** Sự kết hợp đồng thời giữa văn bản, hình ảnh, biểu đồ và video (bao gồm công nghệ Deepfake dựng giọng nói/gương mặt giả).

1.1.2.3. Đặc điểm cấu trúc và phương thức lan truyền của tin giả trên mạng xã hội

Tin giả tiếng Việt trên nền tảng các mạng xã hội sở hữu những đặc điểm cấu trúc ngôn ngữ vô cùng đặc thù:

- **Sử dụng ngôn ngữ cảm xúc mạnh (Emotional Language):** Bài viết thường chứa mật độ dày đặc các từ ngữ kích động (*"SỐC"*, *"KHẨN CẤP"*, *"MỌI NGƯỜI CHÚ Ý"*, *"GẤP GẤP"*), dấu chấm cảm (!) và ký tự viết hoa toàn bộ (UPPERCASE) nhằm đánh vào tâm lý lo sợ hoặc tò mò của người đọc.
- **Kỹ thuật "Trộn lẫn sự thật" (Partial Truths):** Tin giả tinh vi thường lồng ghép 70-80% sự kiện có thật đã diễn ra trong quá khứ với 20-30% chi tiết bịa đặt hoặc sai lệch về thời gian/địa điểm, khiến các công cụ kiểm tra từ khóa thông thường hoàn toàn bị đánh lừa.
- **Làm giả nguồn trích dẫn đáng tin cậy:** Sử dụng các cụm từ mơ hồ như *"Theo nguồn tin nội bộ"*, *"Bác sĩ Bệnh viện X chia sẻ"*, *"Người nhà làm ở Bộ Y tế cho biết"* để tạo cảm giác uy tín giả tạo.
- **Mật độ nhiễu ngôn ngữ cực cao:** Chứa ngôn ngữ teencode, từ viết tắt tự do, sai lỗi chính tả Telex/VNI, biểu tượng cảm xúc (emoji/icon) chèn dày đặc giữa các từ, cấu trúc hashtag và liên kết rác.

1.2. CÁC PHƯƠNG PHÁP PHÁT HIỆN TIN GIẢ

1.2.1. Phương pháp kiểm chứng truyền thống (Fact-Checking thủ công)

1.2.1.1. Khái niệm và Bối cảnh áp dụng kiểm chứng thủ công

Phương pháp phát hiện tin giả truyền thống xuất phát từ nghiệp vụ báo chí chính thống và hoạt động kiểm chứng thông tin (Fact-checking). Phương pháp này vận hành dựa hoàn toàn vào trí tuệ, kinh nghiệm chuyên môn, kỹ năng điều tra và năng lực phân tích bối cảnh của con người. Đối tượng thực hiện quy trình này thường là các nhà báo điều tra, các chuyên gia truyền thông, hoặc các tổ chức kiểm chứng độc lập uy tín trên thế giới (như Snopes, FactCheck.org, PolitiFact) cũng như tại Việt Nam (như Trung tâm Xử lý Tin giả Việt Nam - VAFC thuộc Cục Phát thanh, Truyền hình và Thông tin điện tử).

Trong giai đoạn đầu của sự phát triển Internet, kiểm chứng thủ công là con đường duy nhất để thẩm định tính xác thực của một thông tin trước khi xuất bản hoặc đính chính dư luận .

1.2.1.2. Quy trình thực hiện kiểm chứng thông tin tiêu chuẩn

Một quy trình kiểm chứng thông tin thủ công tiêu chuẩn do các chuyên gia thực hiện thường bao gồm 4 bước nghiêm ngặt:

1. **Bước 1:** Tiếp nhận và sàng lọc manh mối (Identification): Thu thập các bài viết, tin đồn, bài đăng mạng xã hội có dấu hiệu bất thường, chứa từ ngữ giật gân, hoặc nhận được lượng phản ánh, tương tác (likes, shares, comments) tăng đột biến từ cộng đồng .
2. **Bước 2:** Truy vết dữ liệu và thu thập chứng cứ (Traceability & Evidence Collection): Sử dụng các công cụ kỹ thuật số hỗ trợ như tìm kiếm hình ảnh ngược (Reverse Image Search) để kiểm tra mốc thời gian xuất bản gốc của ảnh/video; kiểm tra địa chỉ IP, tên miền (domain registration) của các trang web dẫn liên kết; tra cứu dòng sự kiện trên các kho dữ liệu báo chí chính thống .
3. **Bước 3:** Đối soát chuyên môn và tham vấn cơ quan chức năng (Verification): Tiến hành phỏng vấn trực tiếp các nhân chứng tại hiện trường, liên hệ các

bên liên quan, gửi văn bản xác minh chính thức đến các cơ quan quản lý nhà nước, chuyên gia y tế, cơ quan công an hoặc đại diện doanh nghiệp bị ảnh hưởng .

4. **Bước 4:** Công bố báo cáo kiểm chứng (Publication & Rating): Tổng hợp chứng cứ, lập luận giải trình và đưa ra kết luận phân loại cụ thể (Đúng / Sai / Bóp méo một phần / Thiếu bối cảnh) kèm theo báo cáo phân tích chi tiết để định hướng lại dư luận .

1.2.1.3. Ưu điểm của phương pháp kiểm chứng truyền thống

Độ chính xác và tính pháp lý cao: Kết quả kiểm chứng đạt độ tin cậy rất cao do được thẩm định đa chiều qua nhiều cấp chuyên gia, có đầy đủ lập luận chứng cứ và giá trị pháp lý để các cơ quan chức năng làm cơ sở xử lý vi phạm .

Khả năng phân tích bối cảnh sâu sắc (Contextual Understanding): Con người sở hữu khả năng nhận biết tinh tế các sắc thái ngôn ngữ phức tạp mà máy tính rất khó phát hiện, như sự mỉa mai (sarcasm), châm biếm (irony), ẩn dụ văn hóa, hoặc các thủ thuật "trộn lẫn 80% sự thật với 20% bịa đặt" .

1.2.1.4. Hạn chế và Rào cản quy mô (Scalability Bottleneck)

Mặc dù có độ chính xác cao, phương pháp kiểm chứng thủ công đối mặt với những rào cản kỹ thuật không thể vượt qua trong kỷ nguyên bùng nổ dữ liệu số:

- **Tốn kém thời gian và chi phí vận hành:** Quy trình xác minh thủ công thường kéo dài từ nhiều giờ đến nhiều ngày. Trong khoảng thời gian "độ trễ" đó, tin giả đã kịp lan truyền đến hàng triệu người dùng, gây ra những hậu quả xã hội hoặc thiệt hại kinh tế không thể đảo ngược .
- **Đòi hỏi nguồn nhân lực chất lượng cao:** Yêu cầu đội ngũ chuyên gia đông đảo, được đào tạo bài bản về nghiệp vụ báo chí và công nghệ, dẫn đến chi phí duy trì hệ thống kiểm chứng là vô cùng đắt đỏ .
- **Nút thắt về khả năng mở rộng (Unscalable Bottleneck):** Trước dòng chảy dữ liệu khổng lồ với hàng triệu bài viết, bình luận mới phát sinh mỗi ngày

trên Facebook, TikTok hay Zalo, con người hoàn toàn rơi vào trạng thái quá tải. Phương pháp thủ công chỉ có thể xử lý được một tỷ lệ cực kỳ nhỏ (dưới 1%) số lượng tin tức nghi vấn trên mạng xã hội .

1.2.2. Phương pháp phát hiện tin giả tự động bằng Học máy và Xử lý ngôn ngữ tự nhiên (NLP)

1.2.2.1. Biểu diễn toán học bài toán dưới dạng phân loại văn bản nhị phân (Binary Text Classification)

Để khắc phục triệt để hạn chế về tốc độ và quy mô của phương pháp thủ công, hướng tiếp cận phát hiện tin giả tự động ứng dụng Xử lý ngôn ngữ tự nhiên (NLP) và Học máy (Machine Learning / Deep Learning) đã ra đời.

Dưới góc độ toán học và khoa học máy tính, bài toán phát hiện tin giả tự động dựa trên nội dung văn bản được biểu diễn dưới dạng bài toán Phân loại văn bản nhị phân (Binary Text Classification) :

Giả sử ta có một tập dữ liệu huấn luyện D gồm N mẫu bài đăng được định nghĩa:

$$D = \{(X_1, y_1), (X_2, y_2), \ldots, (X_N, y_N)\} \quad (1.1)$$

Trong đó:

- X_i đại diện cho chuỗi văn bản thô tiếng Việt (tiêu đề, nội dung bài viết, dòng trạng thái, bình luận) của mẫu thứ i.
- $y_i \in \{0, 1\}$ là nhãn phân loại tương ứng được gán cho văn bản X_i:
- $y_i = 1$: Đại diện cho lớp Tin thật (Real News / Trusted)
- $y_i = 0$: Đại diện cho lớp Tin giả (Fake News / Unverified).

Mục tiêu của thuật toán học máy là tìm kiếm một hàm quyết định $f: X \to Y$ thông qua việc tối thiểu hóa hàm mất mát (Loss Function) trên tập dữ liệu huấn luyện, từ đó cho phép dự đoán chính xác nhãn y cho một bài đăng văn bản mới X chưa từng xuất hiện trong quá trình huấn luyện.

Trong phạm vi đề tài, đầu vào của hệ thống là văn bản tiếng Việt thuộc tập dữ liệu nghiên cứu, được tiền xử lý và biểu diễn thành véc-tơ đặc trưng bằng mô hình

PhoBERT. Véc-tơ đặc trưng này được đưa vào bộ phân loại SVM để dự đoán một trong hai nhãn: tin thật ($y_i = 1$) hoặc tin giả ($y_i = 0$). Phạm vi xử lý tập trung vào nội dung văn bản; hệ thống không trực tiếp phân tích hình ảnh, video, âm thanh hoặc mạng lưới tương tác giữa người dùng. Kết quả dự đoán chỉ hỗ trợ nhận diện tin giả, không thay thế hoàn toàn việc kiểm chứng thông tin từ các nguồn độc lập.

1.2.2.2. Quy trình 4 bước tổng quát của hệ thống phát hiện tự động

Một hệ thống tự động nhận diện tin giả tiếng Việt tiêu chuẩn vận hành nối tiếp qua 4 giai đoạn kỹ thuật :

1. **Giai đoạn 1:** Thu thập & Tiền xử lý dữ liệu (Data Preprocessing): Tiếp nhận luồng văn bản thô từ mạng xã hội, tiến hành loại bỏ ký tự nhiễu (mã HTML, liên kết URL rác, biểu tượng cảm xúc), chuẩn hóa teencode và từ viết tắt, xử lý lỗi chính tả Telex/VNI và phân tách từ ghép tiếng Việt (Word Segmentation) bằng công cụ chuyên dụng.
2. **Giai đoạn 2:** Trích xuất đặc trưng (Feature Extraction & Vectorization): Chuyển đổi chuỗi văn bản đã tiền xử lý thành dạng biểu diễn số học (véc-tơ đặc trưng) mà máy tính có thể tính toán được. Các kỹ thuật bao gồm ma trận tần suất TF-IDF truyền thống hoặc véc-tơ nhúng ngữ nghĩa theo ngữ cảnh (Contextual Embeddings) 768 chiều từ mô hình PhoBERT.
3. **Giai đoạn 3:** Huấn luyện & Phân loại (Model Training & Classification): Đưa các véc-tơ đặc trưng vào thuật toán học máy (như Support Vector Machine - SVM, Naive Bayes) hoặc mạng nơ-ron sâu để phân tách không gian và tính toán xác suất phân lớp.
4. **Giai đoạn 4:** Trả kết quả & Cảnh báo (Inference & Deployment): Trả về nhãn dự đoán (Tin thật / Tin giả) kèm theo độ tin cậy (Confidence Score), đồng thời đóng gói mô hình thành dịch vụ REST API phục vụ tích hợp vào ứng dụng web hoặc tiện ích Chrome Extension.

1.2.2.3. Ưu điểm vượt trội của hướng tiếp cận tự động

Tốc độ xử lý tính bằng mili giây: Máy tính có thể phân tích và trả về kết quả dự đoán cho một bài viết ngay lập tức tại thời điểm người dùng tiếp cận thông tin.

Khả năng mở rộng không giới hạn (High Scalability): Hệ thống có thể tự động xử lý đồng thời hàng triệu bài đăng mỗi ngày, giải quyết triệt để vấn đề quá tải dữ liệu của phương pháp kiểm chứng thủ công.

Cảnh báo thời gian thực (Real-time Alerting): Cho phép triển khai các công cụ cảnh báo tin giả trực tiếp trên giao diện trình duyệt web, giúp ngăn chặn sự lan truyền của tin giả trước khi nó gây ra tác động tiêu cực trong cộng đồng.

1.3. KHẢO SÁT CÁC CÔNG TRÌNH LIÊN QUAN

1.3.1. Các bộ dữ liệu tin giả tiếng Việt

1.3.1.1. Bộ dữ liệu ReINTEL (Reliable Intelligence Identification)

ReINTEL (Reliable Intelligence Identification on Vietnamese Social Network Sites) là bộ dữ liệu được xây dựng trong khuôn khổ cuộc thi nhận diện thông tin đáng tin cậy trên mạng xã hội tiếng Việt năm 2020. Bài toán hướng đến việc xác định một thông tin được chia sẻ trên mạng xã hội thuộc nhóm đáng tin cậy (*Reliable*) hay không đáng tin cậy (*Unreliable*). Theo thông tin do ban tổ chức công bố, dữ liệu cung cấp cho cuộc thi gồm khoảng 8.000 mẫu huấn luyện có nhãn và 2.000 mẫu kiểm thử chưa có nhãn. Nhãn dữ liệu được gán thủ công, trong đó nhãn 0 biểu thị thông tin đáng tin cậy và nhãn 1 biểu thị thông tin không đáng tin cậy [14].

ReINTEL có ý nghĩa đối với nghiên cứu nhận diện tin giả tiếng Việt vì cung cấp dữ liệu mạng xã hội phục vụ việc xây dựng và đánh giá mô hình phân loại văn bản. Tuy nhiên, nhãn *Unreliable* nên được hiểu là thông tin không đáng tin cậy theo định nghĩa của bộ dữ liệu, không nhất thiết đồng nghĩa rằng mọi mẫu đều đã được chứng

minh là tin giả. Vì vậy, khi sử dụng bộ dữ liệu này, cần xem xét cách định nghĩa nhãn và phương pháp gán nhãn trước khi so sánh kết quả với các bộ dữ liệu khác.

1.3.1.2. Bộ dữ liệu VFND (Vietnamese Fake News Dataset)

VFND (Vietnamese Fake News Dataset) là bộ dữ liệu phục vụ nghiên cứu nhận diện tin giả bằng tiếng Việt, do Hồ Quang Thanh và cộng sự xây dựng. Theo thông tin trong kho dữ liệu được công bố năm 2019, VFND tập hợp các bài báo tiếng Việt và bài đăng trên Facebook, được phân loại thành hai nhãn *Fake* (tin giả) và *Real* (tin thật). Dữ liệu được thu thập trong giai đoạn 2017–2019; việc xác định nhãn dựa trên các nguồn tham chiếu, đối chiếu thông tin giữa các nguồn và thông tin phân loại từ cộng đồng [4].

Theo mô tả của nhóm phát triển, dữ liệu tập trung vào các tin tức tường thuật về sự kiện, thuộc những lĩnh vực như thể thao, văn hóa, xã hội, kinh tế và pháp luật. Một số phiên bản hoặc bản cập nhật có thể bổ sung các chủ đề khác, vì vậy cần ghi rõ phiên bản được tham khảo khi mô tả dữ liệu. VFND cung cấp nguồn ngữ liệu tiếng Việt để nghiên cứu và đánh giá các phương pháp phân loại tin giả. Tuy nhiên, quy mô của bộ dữ liệu tương đối nhỏ, do đó cần thận trọng khi khái quát kết quả thực nghiệm sang các nguồn tin và bối cảnh khác.

1.3.1.3. Tập dữ liệu vào thực tế từ các nền tảng mạng xã hội và các trang tin tức trực tuyến

Bên cạnh các bộ dữ liệu đã được công bố, dữ liệu thu thập từ mạng xã hội và các trang tin tức trực tuyến cũng là một nguồn ngữ liệu có thể được sử dụng trong nghiên cứu nhận diện tin giả. Nguồn dữ liệu này có thể phản ánh đặc điểm ngôn ngữ và nội dung xuất hiện trong môi trường thực tế, bao gồm sự khác biệt về cách diễn đạt giữa bài báo chính thống và bài đăng trên mạng xã hội.

Tuy nhiên, dữ liệu thu thập từ Internet cần được xử lý và kiểm soát chất lượng trước khi đưa vào huấn luyện mô hình. Quy trình xây dựng dữ liệu cần xác định rõ nguồn thu thập, tiêu chí lựa chọn mẫu, phương pháp xác minh thông tin, quy tắc gán

nhãn và cách loại bỏ các mẫu trùng lặp hoặc không đủ căn cứ phân loại. Nếu sử dụng phương pháp thu thập tự động như Web Scraping hoặc Crawling, cần bảo đảm việc thu thập phù hợp với điều khoản sử dụng của nguồn dữ liệu và các quy định liên quan. Do đó, độ tin cậy của tập dữ liệu không chỉ phụ thuộc vào số lượng mẫu mà còn phụ thuộc vào chất lượng xác minh và gán nhãn.

1.3.2. Nhận diện tin giả bằng Học máy truyền thống và Học sâu chuỗi

1.3.2.1. Hướng tiếp cận bằng các thuật toán Học máy truyền thống (Naive Bayes, KNN, SVM)

Ở giai đoạn đầu của hướng tiếp cận tự động, bài toán nhận diện tin giả được mô hình hóa thành bài toán phân loại văn bản có giám sát dựa trên các thuật toán học máy truyền thống. Các thuật toán phân lớp phổ biến bao gồm Naive Bayes (NB), K-Nearest Neighbors (KNN), Logistic Regression (LR) và Support Vector Machine (SVM).

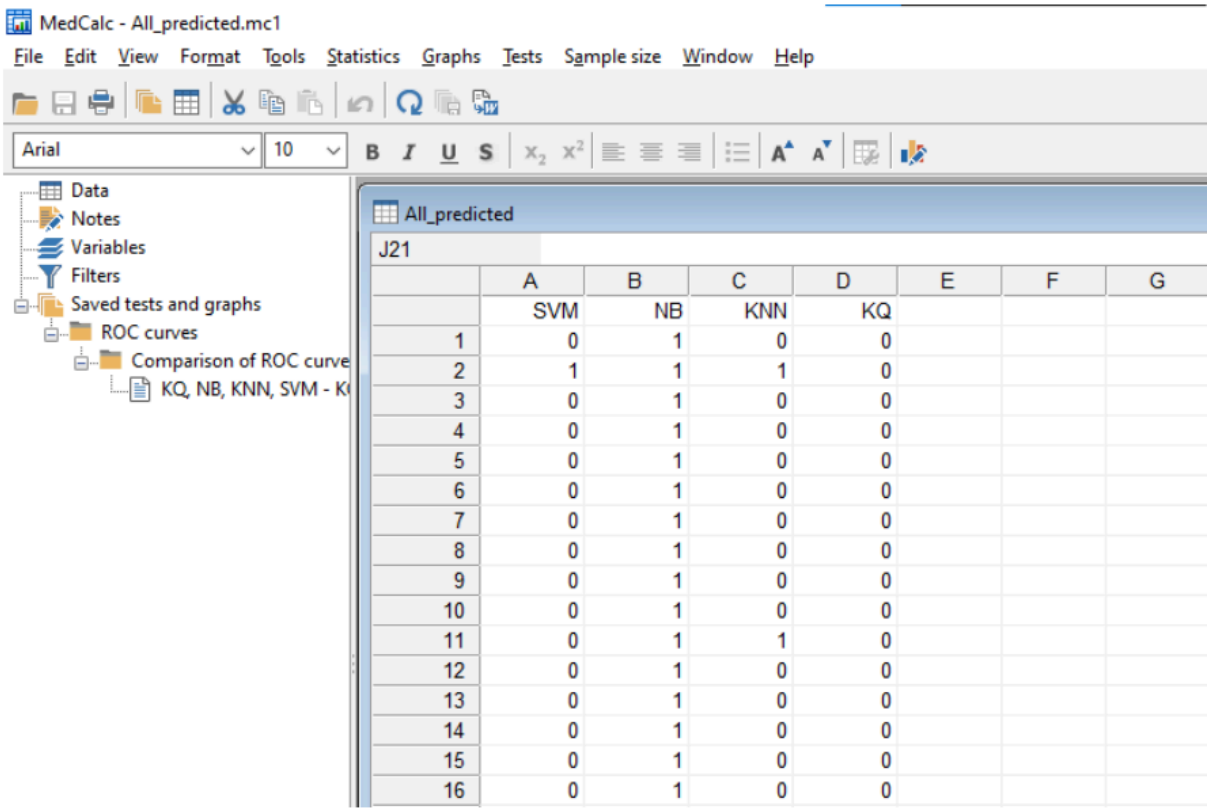
Để đưa văn bản vào thuật toán học máy, các nhà nghiên cứu sử dụng các kỹ thuật biểu diễn văn bản thô dạng ma trận như Bag-of-Words (BoW), N-gram hoặc TF-IDF (Term Frequency - Inverse Document Frequency). Kỹ thuật TF-IDF đánh giá độ quan trọng của một từ t trong văn bản d thuộc tập ngữ liệu D thông qua tích số giữa tần suất xuất hiện của từ $TF(t, d)$ và tần suất nghịch đảo văn bản $IDF(t, D)$:

$$TF - IDF(t, d, D) = TF(t, d) \times IDF(t, D) \quad (1.2)$$

Trong công trình nghiên cứu của Bùi Công Tùng, Nguyễn Thị Hường và Vũ Chí Trung (2022), nhóm tác giả đã tiến hành thực nghiệm đối sánh các mô hình học máy truyền thống trong phân loại tin tức thô. Kết quả phân tích đường cong ROC (Receiver Operating Characteristic) và diện tích dưới đường cong AUC (Area Under Curve) trên phần mềm MedCalc chứng minh sự vượt trội rõ rệt của thuật toán SVM:

1. Thuật toán SVM đạt chỉ số AUC = 0.934 (độ chính xác phân loại đạt khoảng 93%).

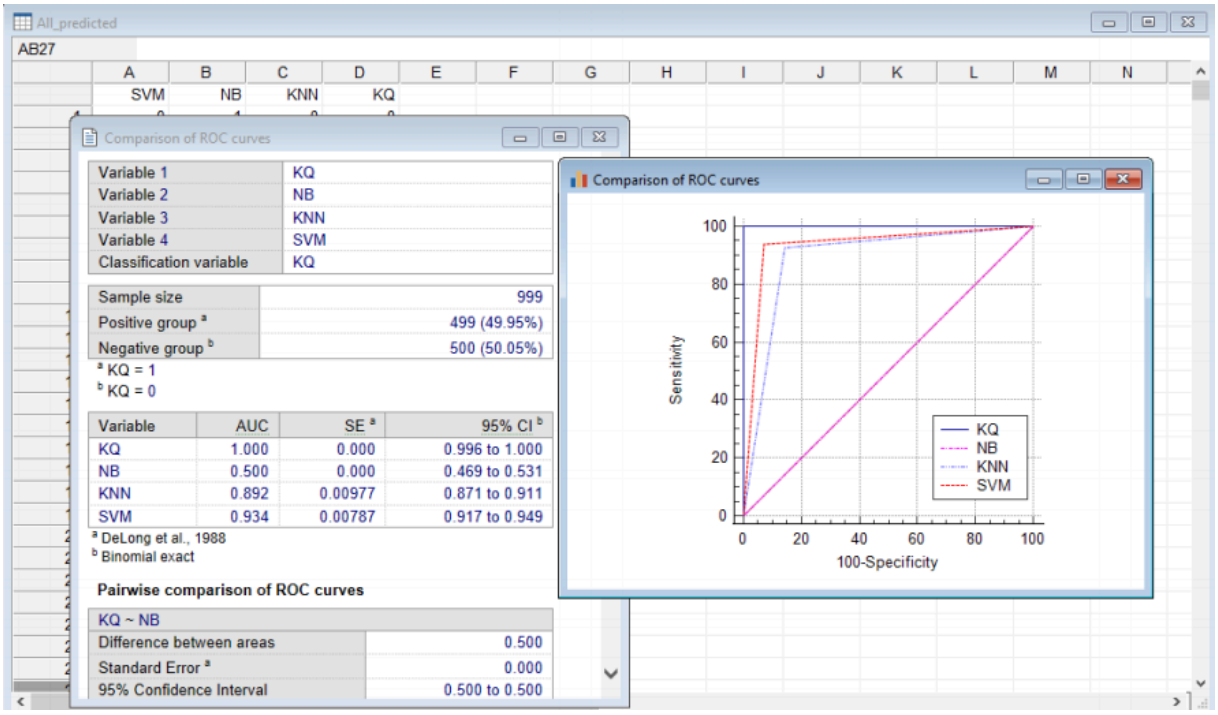
2. Thuật toán KNN chỉ đạt chỉ số AUC = 0.892.
3. Thuật toán Naive Bayes chỉ đạt chỉ số AUC = 0.500 (tương đương với đoán ngẫu nhiên do giả định các thuộc tính độc lập bị vi phạm nghiêm trọng trên dữ liệu văn bản).



	A	B	C	D	E	F	G
	SVM	NB	KNN	KQ			
1	0	1	0	0			
2	1	1	1	0			
3	0	1	0	0			
4	0	1	0	0			
5	0	1	0	0			
6	0	1	0	0			
7	0	1	0	0			
8	0	1	0	0			
9	0	1	0	0			
10	0	1	0	0			
11	0	1	1	0			
12	0	1	0	0			
13	0	1	0	0			
14	0	1	0	0			
15	0	1	0	0			
16	0	1	0	0			

Hình 1.2: Bảng dữ liệu dự đoán của các mô hình học máy trên phần mềm MedCalc

Nguồn: Bùi Công Tùng và cs., 2022



Hình 1.3: Kết quả so sánh đường cong ROC và chỉ số AUC giữa các mô hình học máy

Nguồn: Bùi Công Tùng và cs., 2022

Hạn chế cố hữu của học máy truyền thống: Mặc dù SVM đạt kết quả tốt trên ma trận TF-IDF, kỹ thuật biểu diễn TF-IDF/BoW tồn tại nhược điểm lớn là bỏ qua hoàn toàn thứ tự từ và ngữ cảnh câu. Ma trận đặc trưng thu được có số chiều rất lớn nhưng bị thưa (sparse matrix), khiến mô hình không thể hiểu được các câu văn mỉa mai, ẩn dụ hoặc cấu trúc cú pháp phức tạp trên mạng xã hội.

1.3.2.2. Hướng tiếp cận bằng các mô hình Mạng nơ-ron chuỗi (LSTM, Bi-LSTM, CNN-BiLSTM)

Việc ứng dụng các mô hình học sâu dạng chuỗi (như LSTM, Bi-LSTM) kết hợp với biểu diễn từ Word Embeddings cho bài toán nhận diện tin giả tiếng Việt đã được Võ Đức Vĩnh và Đỗ Phúc triển khai thực nghiệm thành công trên tập dữ liệu VFND [7].

Để giải quyết nhược điểm bỏ qua ngữ cảnh của TF-IDF, các nghiên cứu tiếp theo chuyển sang ứng dụng các mô hình học sâu dạng chuỗi như RNN (Recurrent Neural Network), LSTM (Long Short-Term Memory), Bi-LSTM (Bidirectional LSTM) và mạng kết hợp CNN-BiLSTM.

Các mô hình học sâu chuỗi kết hợp với các véc-tơ biểu diễn từ tĩnh tiền huấn luyện (Word Embeddings) như Word2Vec hoặc FastText. Bằng cách truyền trạng thái ẩn (hidden state) qua từng bước thời gian, LSTM có khả năng học được mối phụ thuộc chuỗi giữa các từ đứng trước và từ đứng sau trong câu. Mạng Bi-LSTM cải tiến việc học ngữ cảnh bằng cách duyệt câu văn theo cả hai chiều (từ trái sang phải và từ phải sang trái).

Hạn chế của mô hình học sâu chuỗi: Mặc dù nắm bắt được ngữ cảnh ngắn, các mô hình dạng chuỗi như LSTM vẫn gặp hiện tượng mất mát thông tin (gradient vanishing / suy giảm bộ nhớ) khi văn bản đầu vào quá dài. Đồng thời, quá trình huấn luyện chuỗi tuần tự không thể tính toán song song, dẫn đến thời gian huấn luyện rất chậm và tốn kém tài nguyên phần cứng.

1.3.3. Nhận diện tin giả và phân loại văn bản tiếng Việt bằng các mô hình Pre-trained Language Models (BERT, PhoBERT)

1.3.3.1. Đột phá từ kiến trúc Transformer và mô hình PhoBERT

Năm 2018, sự ra đời của kiến trúc Transformer (Devlin et al., 2018) với cơ chế Self-Attention (Tự chú ý) đã tạo nên cuộc cách mạng trong lĩnh vực Xử lý ngôn ngữ tự nhiên. Kiến trúc Transformer cho phép mô hình tính toán mối tương quan giữa tất cả các từ trong câu đồng thời theo thời gian thực mà không bị giới hạn bởi khoảng cách chuỗi.

PhoBERT do Nguyễn Quốc Đạt và Nguyễn Tuấn Anh (Viện Nghiên cứu Trí tuệ Nhân tạo VinAI Research) công bố vào tháng 3/2020 là mô hình ngôn ngữ tiền huấn luyện chuyên biệt dành riêng cho tiếng Việt [5]. PhoBERT được phát triển dựa trên kiến trúc RoBERTa (Robustly Optimized BERT Approach), áp dụng tác vụ huấn

luyện Masked Language Modeling (MLM) với các đặc điểm nổi bật bao gồm [5],[12]:

- **Tập ngữ liệu huấn luyện khổng lồ:** PhoBERT được huấn luyện trên 20GB dữ liệu tiếng Việt chuẩn, bao gồm 1GB dữ liệu từ Wikipedia tiếng Việt và 19GB dữ liệu tin tức báo chí trực tuyến [5].
- **Giải quyết rào cản phân đoạn từ tiếng Việt:** Khác với tiếng Anh (các từ phân tách rõ ràng bằng khoảng trắng), tiếng Việt là ngôn ngữ đơn lập. PhoBERT tích hợp công cụ RDRSegmenter (thuộc bộ VnCoreNLP) để thực hiện tách từ ghép tiếng Việt trước khi đưa vào mã hóa subword bằng thuật toán fastBPE [5].
- **Hai phiên bản tiêu chuẩn:** Phiên bản PhoBERT-base (12 lớp Transformer, 768 chiều ẩn, 12 đầu Attention, 110 triệu tham số) và PhoBERT-large (24 lớp Transformer, 1024 chiều ẩn, 16 đầu Attention, 340 triệu tham số [5].

Bảng 1.1: So sánh đặc tính kỹ thuật giữa các kiến trúc xử lý ngôn ngữ tự nhiên (NLP)

ĐẶC TÍNH KỸ THUẬT	BERT (Google)	RoBERTa (Facebook)	PhoBERT (VinAI)
Loại ngôn ngữ	Đa ngôn ngữ (Multilingual)	Đa ngôn ngữ	Đơn ngữ (Tiếng Việt)
Dung lượng dữ liệu	16 GB	160 GB	20 GB (News + Wiki)
Công cụ tách từ	WordPiece	Byte-Pair Encoding	RDRSegmenter (VnCore)
Tác vụ huấn luyện	MLM + NSP	MLM (Dynamic	MLM (Dynamic

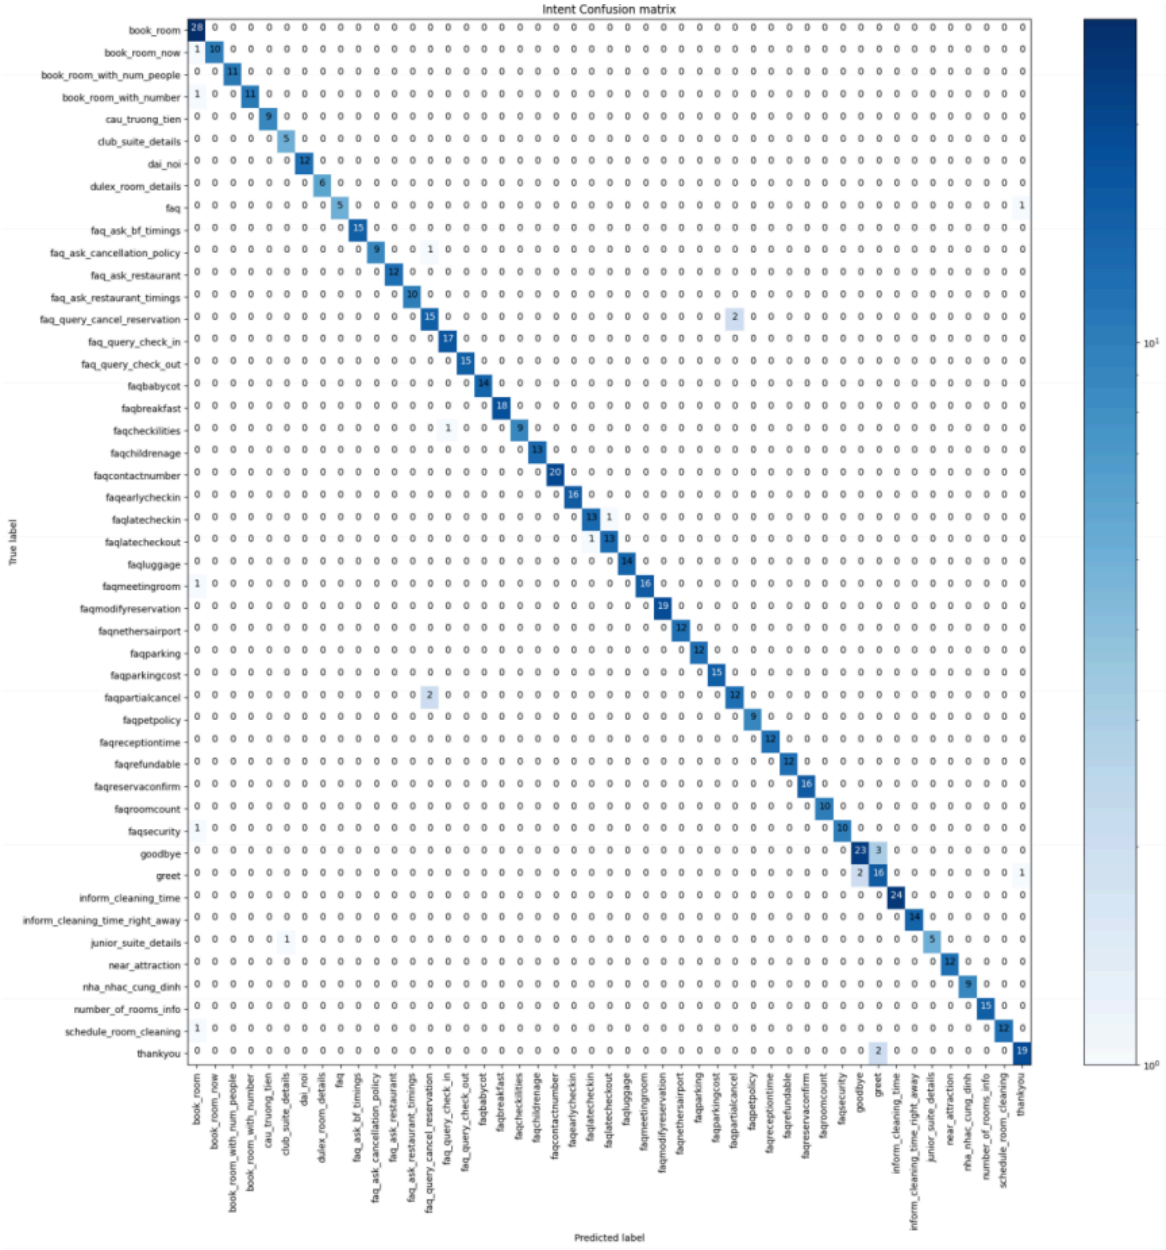
		Masking)	Masking)

1.3.3.2. Ứng dụng PhoBERT trong bài toán phân loại ý định Chatbot tiếng Việt

Trong công trình *"Một cải tiến của PhoBERT nhằm tăng khả năng hiểu tiếng Việt của chatbot thông tin khách sạn"* (2022), Ngô Văn Sơn, Nguyễn Thị Minh Nghĩa, Hoàng Thị Huế, Nguyễn Hữu Liêm và Võ Viết Minh Nhật đã ứng dụng PhoBERT để phân loại ý định (Intent Classification) câu hỏi của khách hàng.

Nhóm tác giả tiến hành tinh chỉnh (fine-tuning) PhoBERT và đối sánh trực tiếp với hai mô hình tham chiếu là FastText và mBERT (Multilingual BERT) trên tập dữ liệu du lịch. Kết quả thực nghiệm chứng minh hiệu năng đạt kết quả tốt hơn trong thực nghiệm được báo cáo của PhoBERT:

- Mô hình PhoBERT đạt Accuracy = 96.4%, Precision = 97.4%, Recall = 96.4% và F1-score = 96.9%.
- Mô hình mBERT chỉ đạt F1-score = 81.1% (thấp hơn PhoBERT 15.8%).
- Mô hình FastText chỉ đạt F1-score = 66.5% (thấp hơn PhoBERT 30.4%).



Hình 1.4: Ma trận nhầm lẫn (Intent Confusion Matrix) phân loại ý định văn bản bằng PhoBERT

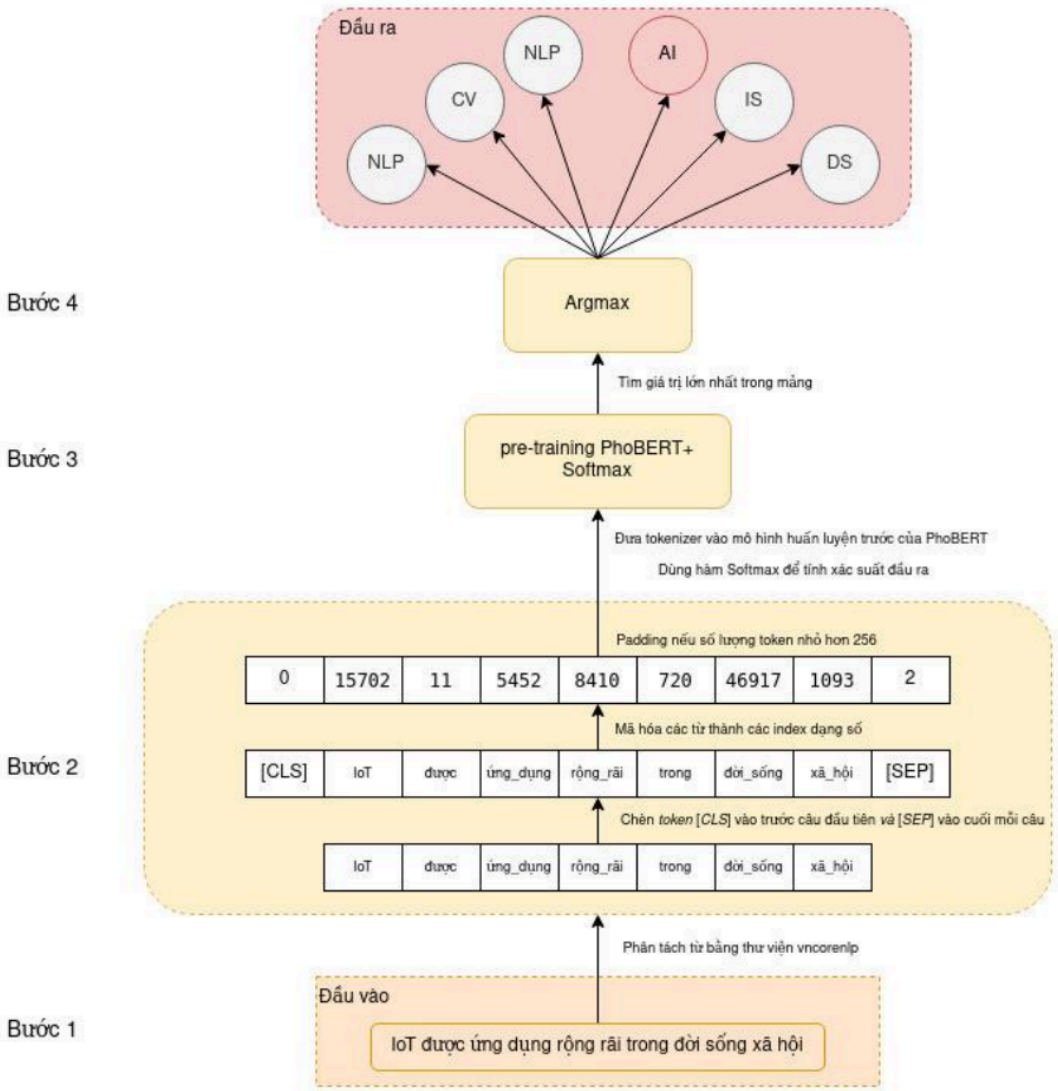
Nguồn: Ngô Văn Sơn và cs., 2022

1.3.3.3. Ứng dụng PhoBERT trong bài toán gom cụm bài báo khoa học

Trong nghiên cứu *"Xây dựng ứng dụng gom cụm bài báo khoa học theo chủ đề"* (2023), Nguyễn Lê Minh Hòa và Trần Văn Lăng đã triển khai mô hình

PhoBERT-base để tự động phân loại các tóm tắt bài báo khoa học tiếng Việt thuộc hội nghị FAIR vào 6 nhóm chủ đề công nghệ thông tin.

Quy trình xử lý của nhóm tác giả bao gồm: Văn bản thô → Tách từ bằng VnCoreNLP → Thêm token đặc biệt [CLS] và [SEP] → Mã hóa subword bằng BPE → Đưa qua PhoBERT → Lớp Softmax phân loại. Kết quả thực nghiệm đạt điểm F1-score = 100% trên tập dữ liệu xác thực, khẳng định khả năng biểu diễn ngữ nghĩa chính xác của PhoBERT trên ngữ liệu tiếng Việt chuyên ngành.



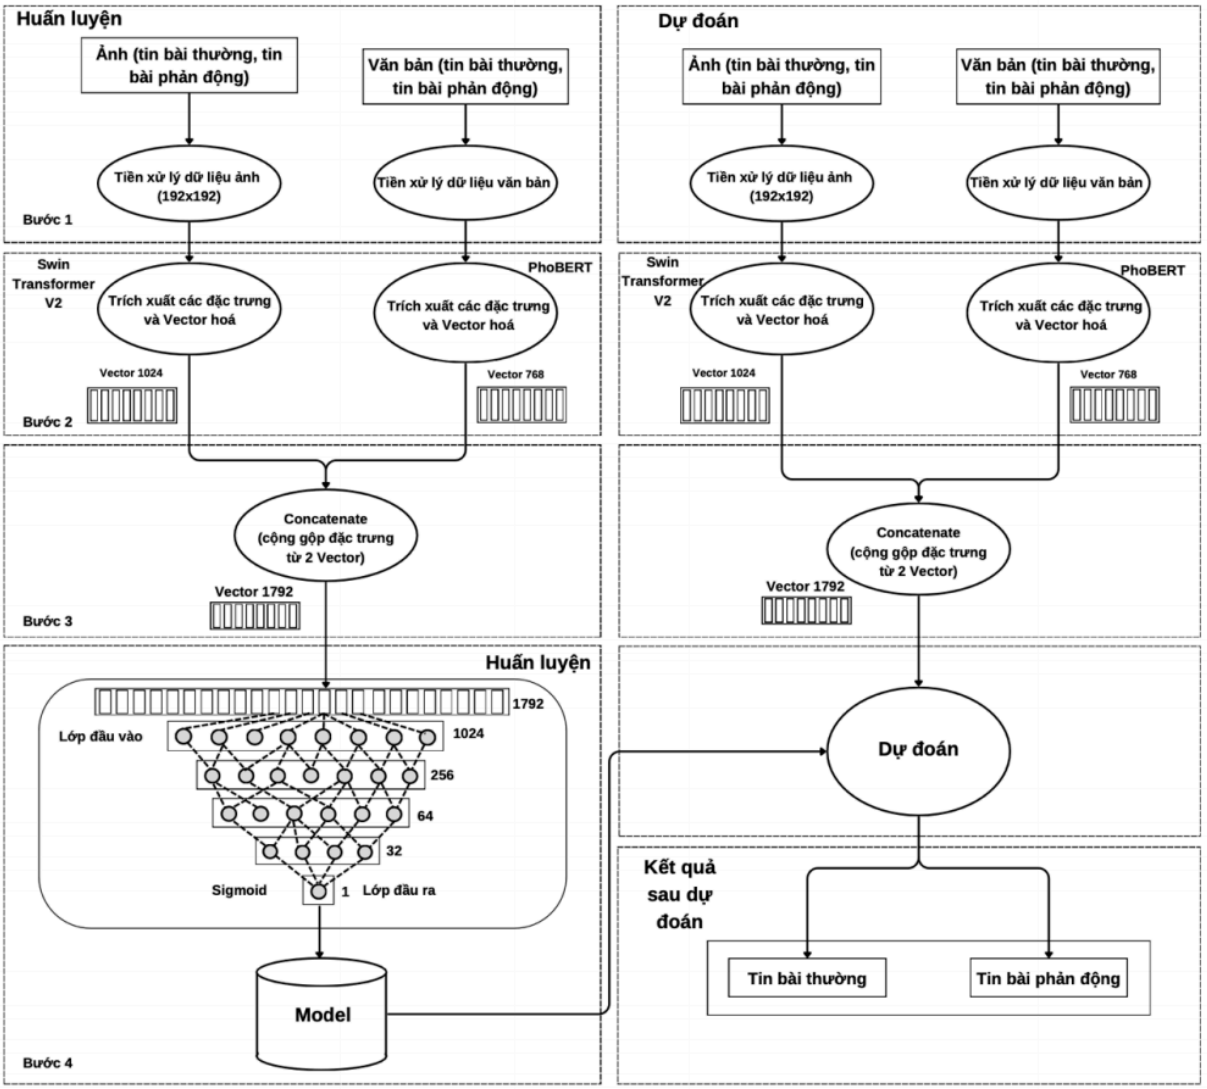
Hình 1.5: Quy trình 4 bước phân loại câu văn bản tiếng Việt bằng PhoBERT và Softmax

Nguồn: Nguyễn Lê Minh Hòa và Trần Văn Lăng, 2023

1.3.3.4. Ứng dụng PhoBERT trong mô hình đa phương pháp nhận diện tin bài phản động

Trong công trình *"Một mô hình đa phương pháp cho phát hiện tin bài phản động tiếng Việt"* (2024), Lê Ngọc An, Hoàng Xuân Dậu, Dương Trần Đức và Đinh Tuấn Long đã đề xuất mô hình lai kết hợp giữa PhoBERT (trích xuất véc-tơ văn bản 768 chiều) và Swin Transformer V2 (trích xuất véc-tơ hình ảnh 1024 chiều).

Hai véc-tơ đặc trưng từ hai nhánh được ghép nối bằng phương pháp Concatenate tạo thành véc-tơ hợp nhất 1792 chiều trước khi đưa qua lớp mạng Dense để phân loại nhị phân. Kết quả thực nghiệm trên tập 4.000 tin bài tiếng Việt đạt điểm Accuracy = 97.0%, Precision = 97.0%, Recall = 97.5% và F1-score = 97.0%, vượt trội hơn hẳn so với việc sử dụng từng mô hình đơn lẻ.



Hình 1.6: Kiến trúc mô hình đa phương pháp kết hợp PhoBERT và Swin Transformer V2

Nguồn: Lê Ngọc An và cs., 2024

1.3.4. So sánh, đánh giá tổng hợp các mô hình đã khảo sát

1.3.4.1. Bảng đối sánh kỹ thuật giữa các nhóm mô hình

Từ kết quả khảo sát toàn diện các công trình nghiên cứu trên, Bảng 1.2 tổng hợp sự đối sánh về đặc tính kỹ thuật, ưu điểm và hạn chế giữa ba nhóm phương pháp phân loại văn bản hiện nay:

Bảng 1.2: So sánh tổng hợp đặc tính kỹ thuật giữa các nhóm phương pháp phân loại văn bản

Nhóm phương pháp	**Mô hình tiêu biểu**	**Kỹ thuật biểu diễn dữ liệu**	**Ưu điểm cốt lõi**	**Hạn chế cố hữu**
Học máy truyền thống	Naive Bayes, KNN, SVM	Bag-of-Words, TF-IDF, N-gram	Tốc độ phân loại cực nhanh, tốn rất ít tài nguyên tính toán, tính ổn định cao.	Bỏ qua hoàn toàn thứ tự từ và ngữ cảnh câu; ma trận đặc trưng bị thưa.
Học sâu chuỗi	RNN, LSTM, Bi-LSTM, CNN-BiLSTM	Word2Vec, FastText (Word Embeddings)	Học được mối phụ thuộc chuỗi và ngữ cảnh ngắn trong câu.	Mất mát thông tin khi văn bản quá dài; huấn luyện chậm, tốn GPU.
Pre-trained Transformer	BERT, RoBERTa, PhoBERT	Contextual Embeddings (Véc-tơ nhúng 768 chiều)	Biểu diễn ngữ nghĩa hai chiều sâu sắc; tối ưu riêng cho tiếng Việt.	Yêu cầu hạ tầng GPU đắt đỏ nếu tinh chỉnh (fine-tuning) toàn bộ.

1.3.4.2. Tiêu chí đánh giá chất lượng các thuật toán phát hiện tin giả tự động

Để đánh giá và so sánh hiệu năng của các thuật toán học máy và học sâu trong bài toán phân loại văn bản tin tức, nghiên cứu sử dụng các chỉ số đánh giá phổ biến trong học máy có giám sát. Trong phạm vi bài toán phân loại nhị phân, lớp dương (Positive Class / Label 1) được quy ước là **tin thật (Real News)**, trong khi lớp âm (Negative Class / Label 0) là **tin giả (Fake News)**. Hiệu năng của mô hình được đánh giá thông qua các tiêu chí sau:

- **Ma trận nhầm lẫn (Confusion Matrix):** Là bảng thống kê đối soát giữa nhãn thực tế và nhãn dự đoán của mô hình, bao gồm 4 thành phần cơ bản: Dương tính thật (TP - phát hiện đúng tin thật), Âm tính thật (TN - xác nhận đúng tin giả), Dương tính giả (FP - gán nhãn sai tin giả thành tin thật) và Âm tính giả (FN - bỏ sót tin thật). Đây là cơ sở để tính toán các thước đo định lượng.
- **Độ chính xác tổng thể (Accuracy):** Đo tỷ lệ phần trăm các mẫu văn bản được mô hình dự đoán đúng (cả tin thật và tin giả) trên tổng số mẫu kiểm thử. Mặc dù Accuracy phản ánh năng lực phân loại chung, chỉ số này không thể dùng làm tiêu chí duy nhất đối với bài toán tin giả - nơi dữ liệu thường bị mất cân bằng nhãn (số lượng tin thật chiếm đa số), vì một mô hình luôn dự đoán mọi bài viết là tin thật vẫn có thể đạt Accuracy cao nhưng hoàn toàn thất bại trong việc phát hiện tin giả.
- **Độ chính xác dự đoán (Precision):** Đo tỷ lệ các bài viết thực sự là tin thật trong tổng số các bài viết mà thuật toán dự đoán là tin thật ($\frac{TP}{TP+FP}$) . Trong thực tiễn, Precision cao cho thấy các dự đoán tin thật có độ tin cậy cao, hạn chế việc hệ thống gán nhãn nhầm các bài viết tin giả thành tin thật.

- **Độ bao phủ / Độ nhạy (Recall):** Đo tỷ lệ các bài viết tin thật được mô hình phát hiện thành công trên tổng số tin thật thực tế tồn tại trong tập dữ liệu ($\frac{TP}{TP+FN}$) . Chỉ số Recall phản ánh khả năng nhận diện tin thật của thuật toán và mức độ hạn chế các trường hợp tin thật bị phân loại nhầm thành tin giả.
- **Thang đo cân bằng F1-score:** Là trung bình điều hòa giữa Precision và Recall, được tính bằng công thức: F1 = ($2 \times \frac{Precision \times Recall}{Precision+Recall}$). F1-score giúp đánh giá đồng thời độ chính xác dự đoán và độ bao phủ, đặc biệt hữu ích khi cần xem xét sự cân bằng giữa hai chỉ số này trên tập dữ liệu mất cân bằng.
- **Diện tích dưới đường cong ROC (AUC-ROC):** Biểu diễn mối quan hệ giữa tỷ lệ phát hiện đúng lớp dương (TPR) và tỷ lệ dương tính giả (FPR) trên nhiều ngưỡng phân loại khác nhau. Chỉ số AUC càng tiến gần 1.0 thì khả năng phân biệt giữa hai lớp của thuật toán càng tốt; giá trị gần 0.5 thường tương ứng với khả năng phân biệt không tốt hơn mức ngẫu nhiên.

1.3.4.3. Nhận xét và Khoảng trống nghiên cứu (Research Gap)

Qua quá trình phân tích đối sánh, đề tài rút ra hai kết luận khoa học quan trọng:

1. **Khoảng trống về chi phí tính toán khi fine-tuning PhoBERT thuần túy:** Mặc dù việc tinh chỉnh (fine-tuning) toàn bộ mô hình PhoBERT cho kết quả chính xác cao, nhưng quy trình này đòi hỏi hạ tầng máy tính có GPU dung lượng rất lớn, thời gian huấn luyện lâu và dễ bị hiện tượng quá khớp (overfitting) khi tập dữ liệu huấn luyện có kích thước vừa và nhỏ.
2. **Luận cứ cho giải pháp lai PhoBERT + SVM:** Thuật toán SVM có thế mạnh vượt trội trong việc tìm kiếm siêu phẳng tối ưu để phân tách dữ liệu trên không gian nhiều chiều, có tốc độ phân loại cực nhanh và khả năng kháng overfitting rất tốt.

Do đó, việc sử dụng PhoBERT đóng vai trò bộ trích xuất véc-tơ đặc trưng ngữ nghĩa (Feature Extractor) kết hợp với thuật toán SVM làm bộ phân loại chính là

hướng đi tối ưu nhất, giải quyết triệt để bài toán dung hòa giữa độ chính xác cao và tính khả thi về tài nguyên tính toán cho dự án.

1.4. THÁCH THỨC TRONG NHẬN DIỆN TIN GIẢ TIẾNG VIỆT TRÊN MẠNG XÃ HỘI

1.4.1. Thách thức từ đặc thù ngôn ngữ Tiếng Việt và dữ liệu mạng xã hội

1.4.1.1. Rào cản ranh giới từ trong ngôn ngữ đơn lập

Một trong những thách thức kỹ thuật lớn nhất khi áp dụng các kỹ thuật Xử lý ngôn ngữ tự nhiên (NLP) cho tiếng Việt chính là đặc thù của một ngôn ngữ đơn lập. Khác với các ngôn ngữ hòa kết như tiếng Anh hay tiếng Pháp (nơi các từ đơn phân tách rõ ràng với nhau bằng khoảng trắng), ranh giới giữa các từ trong tiếng Việt không trùng khớp với khoảng trắng. Tiếng Việt cấu tạo dựa trên các âm tiết (syllables); nhiều âm tiết kết hợp lại mới tạo thành một từ ghép hoặc từ phức mang một khái niệm hoàn chỉnh.

Ví dụ, cụm âm tiết *"nhà nghiên cứu"* bao gồm 3 âm tiết đơn lẻ, nhưng khi hợp lại mới biểu thị đúng một khái niệm thực thể duy nhất. Nếu máy tính xử lý trực tiếp khoảng trắng mà không qua công cụ phân tách từ chuyên biệt (Word Segmentation) như RDRSegmenter trong bộ công cụ VnCoreNLP, hệ thống sẽ hiểu tách rời thành 3 khái niệm riêng biệt. Việc phân tách từ sai lệch dẫn đến hiện tượng hiểu sai hoàn toàn ngữ cảnh câu văn, làm sai lệch véc-tơ biểu diễn dữ liệu đầu vào của các thuật toán học máy.

1.4.1.2. Mật độ nhiễu ngôn ngữ cực lớn trên mạng xã hội (Social Media Noise)

Văn bản trên các nền tảng mạng xã hội như Facebook, TikTok hay Zalo sở hữu tính chất phi cấu trúc cao và chứa mật độ nhiễu ngôn ngữ vô cùng phức tạp:

- **Ngôn ngữ teencode và từ viết tắt tự do:** Người dùng mạng xã hội thường xuyên sử dụng các biến thể viết tắt ngẫu hứng (như *"ko"*, *"k"* → *"không"*; *"đc"*, *"dc"* → *"được"*; *"j"* → *"gì"*; *"ntn"* → *"như thế này"*).

- **Lỗi chính tả do quy tắc gõ Telex/VNI và tiếng lóng:** Sự xuất hiện của các từ gõ sai dấu, từ lóng thay đổi theo trào lưu (trend), hoặc việc lặp lại ký tự để biểu thị cảm xúc (như *"vuiiii quáaaa"*, *"trờiii ơiii"*).
- **Sự pha trộn ngôn ngữ (Code-switching):** Dòng trạng thái mạng xã hội thường xuyên đan xen giữa tiếng Việt, tiếng Anh và các thuật ngữ vay mượn chưa được chuẩn hóa.

Tất cả các yếu tố nhiễu trên tạo ra một tập từ vựng ngoài từ điển (Out-Of-Vocabulary - OOV) khổng lồ, làm gia tăng số chiều của ma trận đặc trưng và suy giảm đáng kể độ chính xác của các mô hình phân loại nếu không có quy trình tiền xử lý chuyên biệt.

1.4.1.3. Sự bùng nổ của biểu tượng cảm xúc (Emoji/Icon) và yếu tố phi văn bản

Bên cạnh chuỗi ký tự chữ viết, bài đăng mạng xã hội hiện đại tích hợp mật độ dày đặc các biểu tượng cảm xúc (Emoji/Icon), các thẻ bắt đầu bằng dấu thăng (Hashtag #), và các đường dẫn liên kết nhúng (URL).

Mặc dù biểu tượng cảm xúc mang thông tin thái độ và sắc thái cảm xúc rất mạnh (như phẫn nộ, mỉa mai, tò mò), nhưng các bộ tiền xử lý truyền thống thường loại bỏ hoàn toàn các ký tự này, làm thất thoát nguồn tri thức quan trọng. Ngược lại, các liên kết URL rác hoặc ký tự lạ nếu không được mã hóa chuẩn xác sẽ gây nhiễu nghiêm trọng cho mô hình.

1.4.2. Thách thức từ sự biến đổi tinh vi của hành vi tạo và phát tán tin giả

1.4.2.1. Thủ thuật "Trộn lẫn sự thật" (Partial Truths) và giả mạo văn phong báo chí

Đối tượng sản xuất tin giả hiện đại đã nâng cao kỹ thuật thao túng thông tin nhằm qua mặt các hệ thống kiểm duyệt tự động dựa trên từ khóa:

- **Kỹ thuật lồng ghép tinh vi:** Cố tình trộn lẫn 70% - 80% thông tin sự thật đã diễn ra trong thực tế với 20% - 30% chi tiết bịa đặt hoặc làm sai lệch mốc thời gian, địa điểm và nhân vật.

- **Giả mạo văn phong chính thống (Imposter Content):** Tin giả được viết bằng văn phong báo chí nghiêm túc, cấu trúc câu mạch lạc, trích dẫn các cụm từ mạo danh cơ quan chức năng hoặc chuyên gia y tế (như "Theo thông tin từ Bộ Y tế", "Bác sĩ bệnh viện X xác nhận"). Điều này khiến bài viết có chỉ số đọc hiểu tương tự tin thật, làm cho các bộ phân loại tuyến tính đơn giản không thể phân tách được ranh giới.

1.4.2.2. Sự biến đổi theo thời gian thực và hiện tượng trôi lệch dữ liệu (Temporal Drift)

Tin giả trên mạng xã hội biến đổi liên tục theo các sự kiện thời sự nóng hổi (dịch bệnh, thiên tai, biến động kinh tế, sự kiện chính trị). Một mô hình phân loại được huấn luyện trên tập dữ liệu tin giả chủ đề dịch bệnh COVID-19 có thể hoạt động rất tốt ở thời điểm đó, nhưng sẽ bị suy giảm hiệu năng nghiêm trọng khi đối mặt với các dạng tin giả về tài chính hoặc thiên tai mới phát sinh. Hiện tượng trôi lệch dữ liệu theo thời gian (Concept Drift / Temporal Drift) đòi hỏi hệ thống phải có khả năng cập nhật tri thức liên tục mà không cần huấn luyện lại từ đầu.

1.4.2.3. Sự thiếu hụt bộ dữ liệu gán nhãn chuẩn hóa và hiện tượng mất cân bằng lớp

Trong nghiên cứu NLP tiếng Việt, việc xây dựng một bộ dữ liệu tin giả chuẩn hóa gặp rất nhiều rào cản:

- **Chi phí gán nhãn thủ công lớn:** Việc xác minh một bài viết là tin thật hay tin giả đòi hỏi sự tham gia của các chuyên gia kiểm chứng, tốn kém nhiều thời gian và công sức.
- **Mất cân bằng lớp (Class Imbalance):** Trong tập dữ liệu thực tế, số lượng bài đăng tin thật luôn chiếm tỷ lệ áp đảo so với tin giả (thường ở tỷ lệ 70% tin thật - 30% tin giả hoặc chênh lệch lớn hơn). Sự mất cân bằng này khiến mô hình phân loại dễ bị thiên lệch (bias), thiên vị dự đoán về lớp đa số (tin thật) và bỏ sót các mẫu lớp thiểu số (tin giả).

Để minh họa cách tổ chức dữ liệu phục vụ bài toán phân loại tin giả, Hình 1.7 trình bày cấu trúc cây thư mục của bộ dữ liệu VFND (Fake_Real_Dataset).



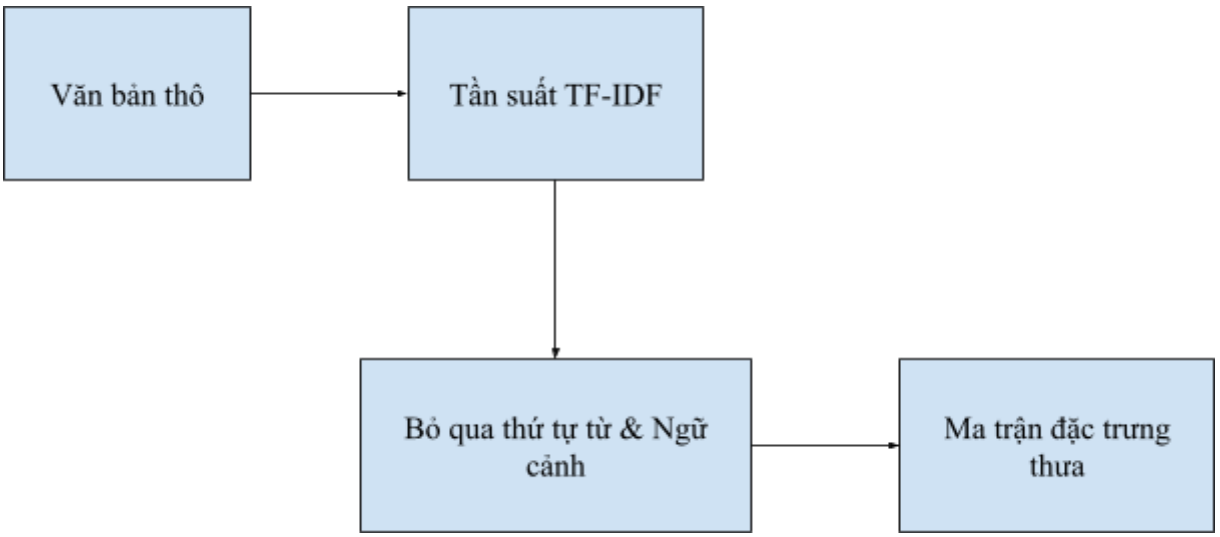
Hình 1.7: Sơ đồ cấu trúc cây thư mục tập dữ liệu tin giả VFND (Fake_Real_Dataset)

Nguồn: Bùi Trường Thịnh, 2025 (dựa trên bộ dữ liệu VFND của Hồ Quang Thành & ninh-pm-se, 2019)

1.4.3. Thách thức về mặt kỹ thuật và hạ tầng công nghệ

1.4.3.1. Hạn chế của các phương pháp trích xuất đặc trưng truyền thống

Các phương pháp biểu diễn văn bản cổ điển như Bag-of-Words (BoW) hay TF-IDF (Term Frequency - Inverse Document Frequency) chỉ dừng lại ở việc thống kê tần suất xuất hiện của các từ riêng lẻ.



Hình 1.8: Quy trình biểu diễn văn bản bằng TF-IDF và đặc điểm của phương pháp Bag-of-Words

Nhược điểm cố hữu của hướng tiếp cận này là:

1. **Bỏ qua hoàn toàn thứ tự từ và cấu trúc ngữ pháp:** Hai câu văn có từ ngữ giống nhau nhưng trật tự khác nhau (mang ý nghĩa đối lập) sẽ tạo ra véc-tơ TF-IDF hoàn toàn giống nhau.
2. **Không biểu diễn được ngữ cảnh hai chiều:** Không thể phân biệt được từ đa nghĩa hoặc câu văn mỉa mai.
3. **Ma trận đặc trưng bị thưa (Sparse Matrix):** Kích thước ma trận tăng theo dung lượng từ điển nhưng chứa rất nhiều giá trị 0, gây lãng phí bộ nhớ và giảm hiệu năng thuật toán.

1.4.3.2. Giới hạn tài nguyên tính toán khi triển khai mô hình Transformer

Sự xuất hiện của các mô hình ngôn ngữ lớn như BERT hay PhoBERT giúp giải quyết triệt để vấn đề biểu diễn ngữ nghĩa theo ngữ cảnh. Tuy nhiên, việc ứng dụng PhoBERT thuần túy vấp phải rào cản hạ tầng kỹ thuật:

1. **Chi phí tính toán khi Fine-tuning toàn bộ:** Việc tinh chỉnh (fine-tuning) tất cả 110 triệu tham số của PhoBERT-base đòi hỏi máy tính phải trang bị cạc đồ họa GPU đắt đỏ với dung lượng VRAM lớn.
2. **Thời gian phản hồi chậm:** Mô hình học sâu thuần túy có độ trễ (latency) tương đối cao khi thực hiện dự đoán thời gian thực trên các thiết bị người dùng cuối.
3. **Nguy cơ học vẹt (Overfitting):** Khi dung lượng tập dữ liệu huấn luyện khiêm tốn, việc fine-tuning toàn bộ mô hình PhoBERT rất dễ dẫn đến hiện tượng quá khớp, làm mất khả năng tổng quát hóa trên dữ liệu mới.

1.5. MỘT SỐ THÁCH THỨC VÀ GIẢI PHÁP

1.5.1. Mô hình đề xuất PhoBERT - SVM cho nhận diện tin giả tiếng Việt

1.5.1.1. Lý do lựa chọn sự kết hợp giữa PhoBERT và SVM

Như đã phân tích tại phần khảo sát các công trình liên quan, bài toán nhận diện tin giả tiếng Việt trên mạng xã hội vấp phải hai rào cản kỹ thuật song song:

1. Các phương pháp biểu diễn từ truyền thống (TF-IDF, Bag-of-Words) bỏ qua hoàn toàn thứ tự từ và ngữ cảnh câu, dẫn đến việc không hiểu được văn phong mỉa mai hoặc cấu trúc ngữ nghĩa phức tạp.
2. Việc tinh chỉnh (fine-tuning) toàn bộ mô hình ngôn ngữ lớn như PhoBERT đòi hỏi hạ tầng máy tính có GPU dung lượng rất lớn, thời gian tính toán kéo dài và nguy cơ bị hiện tượng học vẹt (overfitting) khi tập dữ liệu huấn luyện có kích thước vừa và nhỏ.

Để giải quyết triệt để bài toán dung hòa giữa độ chính xác nhận diện và tính khả thi về mặt tài nguyên tính toán, đề tài đề xuất giải pháp mô hình lai kết hợp giữa PhoBERT và SVM . Trong kiến trúc này, nhiệm vụ của hai thành phần được phân định rõ ràng:

1. **PhoBERT đóng vai trò bộ trích xuất đặc trưng ngữ nghĩa (Feature Extractor):** Tận dụng tri thức tiền huấn luyện từ 20GB ngữ liệu tiếng Việt để mã hóa toàn bộ văn bản đầu vào thành véc-tơ trạng thái ẩn 768 chiều tại vị trí token đặc biệt [CLS]. Véc-tơ này cô đọng trọn vẹn ngữ cảnh hai chiều và mối quan hệ giữa các từ trong bài viết.
2. **SVM đóng vai trò bộ phân loại tối ưu (Classifier):** Tiếp nhận véc-tơ 768 chiều từ PhoBERT và tiến hành phân loại nhị phân (Tin thật / Tin giả). SVM có ưu thế toán học vượt trội trong việc xác định siêu phẳng phân tách tối ưu trên không gian nhiều chiều, có tốc độ phân loại cực nhanh, tính ổn định cao và khả năng kháng overfitting rất tốt ngay cả khi dung lượng dữ liệu hạn chế.

1.5.1.2. Cơ sở toán học của thuật toán SVM và bài toán tối ưu lề Margin

Thuật toán Support Vector Machine (SVM) do Vladimir Vapnik đề xuất là phương pháp học máy có giám sát dựa trên lý thuyết học thống kê. Trong không gian đặc trưng 768 chiều (tương ứng với véc-tơ nhúng ngữ nghĩa trích xuất từ PhoBERT), SVM tìm kiếm một siêu phẳng phân tách (Hyperplane) để chia tập dữ liệu thành hai lớp nhãn: Tin thật (gán nhãn $y_i = +1$) và Tin giả (gán nhãn $y_i = -1$).

Phương trình tổng quát của siêu phẳng phân tách trong không gian 768 chiều được biểu diễn:

$$w^T x + b = 0 \quad (1.3)$$

Trong đó:

- $w = (w_1, w_2, \ldots, w_{768})^T$ là véc-tơ trọng số pháp tuyến quyết định định hướng của siêu phẳng trong không gian .
- $x \in \mathbb{R}^{768}$ là véc-tơ đặc trưng ngữ nghĩa 768 chiều đầu vào trích xuất từ PhoBERT.
- $b \in \mathbb{R}$ là hệ số độ lệch (bias) điều chỉnh khoảng cách từ siêu phẳng đến gốc tọa độ.

Khoảng cách lề (Margin) giữa hai đường biên hỗ trợ song song với siêu phẳng được tính bằng $\frac{2}{||w||}$. Mục tiêu của SVM là tìm siêu phẳng có khoảng cách lề cực đại (Maximal Margin Hyperplane) nhằm đảm bảo khoảng cách an toàn lớn nhất đến các điểm dữ liệu gần ranh giới nhất (gọi là các véc-tơ hỗ trợ - Support Vectors) , .

Để xử lý các điểm dữ liệu nhiễu trên mạng xã hội có thể nằm sai phía ranh giới phân tách (Soft Margin), thuật toán SVM đưa vào các biến chùng (slack variables) $\xi_i \geq 0$ và tham số phạt lỗi $C > 0$, . Bài toán tối ưu hóa SVM được phát biểu dưới dạng toán học:

$$min_{\{w,b,\xi\}} \frac{1}{2}||w||^2 + C\sum_{i=1}^{n} \xi i \quad (1.4)$$

thỏa mãn $y_i(w^T x_i + b) \geq 1 - \xi i\,,\ \xi i \geq 0,\ \forall i = 1, \ldots, n$

Trong đó:

- ξ_i: biến chùng cho phép mẫu vi phạm lề hoặc bị phân loại sai.
- $C > 0$: tham số điều chỉnh mức phạt đối với các vi phạm; C lớn thường phạt lỗi mạnh hơn, còn C nhỏ cho phép dung hòa nhiều hơn giữa độ rộng lề và lỗi trên tập huấn luyện.
- n: số lượng mẫu trong tập huấn luyện.
- $y_i \in \{-1, +1\}$: nhãn lớp; $+1$ là tin thật, -1 là tin giả.

Trong trường hợp dữ liệu phân bố phi tuyến phức tạp trong không gian 768 chiều, SVM áp dụng kỹ thuật biến đổi nhân (Kernel Trick) để ánh xạ dữ liệu lên không gian đặc trưng vô hạn chiều thông qua hàm nhân RBF (Radial Basis Function):

$$K(x_i, x_j) = \exp(-\gamma||x_i - x_j||^2) \quad (1.5)$$

Trong đó:

- $K(x_i, x_j)$: mức độ tương đồng giữa hai véc-tơ đặc trưng theo hàm nhân.
- $\gamma > 0$: tham số điều chỉnh phạm vi ảnh hưởng của từng mẫu.
- exp: hàm mũ cơ số e.

Hàm nhân RBF được giới thiệu nhằm minh họa khả năng xử lý dữ liệu phi tuyến của SVM. Tuy nhiên, trong phạm vi thực nghiệm của đề tài, mô hình chính thức sử dụng Linear Kernel để phân loại các véc-tơ đặc trưng ngữ nghĩa được trích xuất từ PhoBERT. Việc lựa chọn Linear Kernel được trình bày và phân tích cụ thể tại mục 2.4.2.2.

1.5.2. Ý nghĩa khoa học và khả năng ứng dụng thực tế

1.5.2.1. Đóng góp về mặt lý thuyết khoa học

Đề tài mang lại các đóng góp lý luận quan trọng cho lĩnh vực Xử lý ngôn ngữ tự nhiên tiếng Việt :

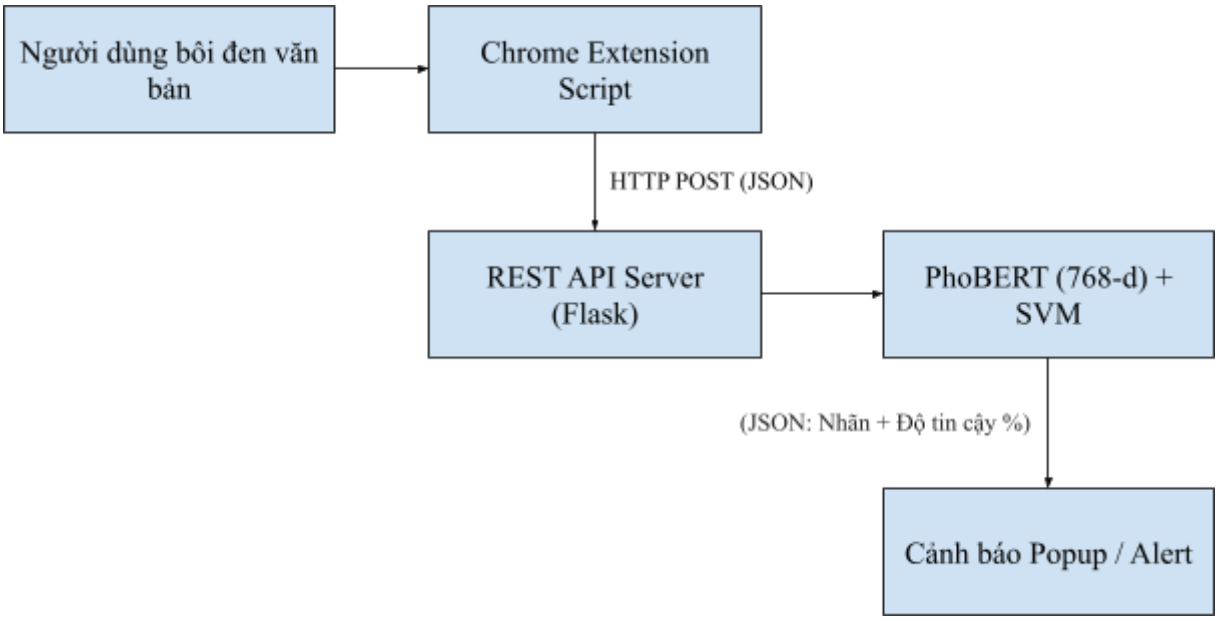
1. **Khẳng định tính hiệu quả của mô hình kết hợp (Hybrid Model):** Chứng minh rằng việc sử dụng mô hình ngôn ngữ tiền huấn luyện sâu PhoBERT làm bộ trích xuất véc-tơ đặc trưng cố định kết hợp với thuật toán SVM cho ra kết quả phân loại vượt trội so với các mô hình chuỗi cổ điển (LSTM, Bi-LSTM) nhưng lại tiết kiệm tài nguyên hơn nhiều so với việc fine-tuning toàn bộ PhoBERT ,.
2. **Quy trình tiền xử lý chuẩn hóa cho văn bản mạng xã hội:** Xây dựng quy trình làm sạch dữ liệu 5 bước chuyên biệt xử lý teencode, từ viết tắt, lỗi chính tả Telex/VNI và phân tách từ ghép tiếng Việt bằng RDRSegmenter (VnCoreNLP), tạo tiền đề cho các nghiên cứu tiếp theo về dữ liệu phi cấu trúc tiếng Việt.

1.5.2.2. Đóng góp về mặt thực tiễn - Triển khai REST API và tiện ích Chrome Extension

Để hiện thực hóa nghiên cứu thành sản phẩm có giá trị sử dụng trực tiếp trong đời sống xã hội, đề tài tiến hành đóng gói mô hình và phát triển ứng dụng cảnh báo thời gian thực :

Xây dựng dịch vụ REST API trên máy chủ (Server-side API): Mô hình PhoBERT và SVM sau khi huấn luyện hoàn chỉnh được lưu trữ thành các tệp trọng số (tệp phobert_model.pt và svm_model.pkl) ,. Nhóm nghiên cứu xây dựng một ứng dụng REST API bằng ngôn ngữ Python sử dụng framework Flask, triển khai một endpoint giao tiếp /predict nhận dữ liệu qua giao thức HTTP POST.

Khi nhận được đoạn văn bản thô từ ứng dụng khách, máy chủ tự động thực hiện tiền xử lý, gọi PhoBERT trích xuất véc-tơ 768 chiều, đưa qua SVM dự đoán nhãn (Tin thật / Tin giả) và tính toán độ tin cậy (Confidence Score %) dựa trên xác suất dự đoán trước khi trả về kết quả cấu trúc định dạng JSON.



Hình 1.9: Sơ đồ kiến trúc tổng thể và quy trình tương tác giữa Tiện ích mở rộng Chrome Extension và dịch vụ REST API

Phát triển tiện ích mở rộng trên trình duyệt Chrome (Chrome Extension): Tiện ích được lập trình dựa trên chuẩn Manifest V3 sử dụng các công nghệ HTML5, CSS3 và JavaScript . Tiện ích cấp quyền contextMenus tạo tùy chọn *"Kiểm tra tin giả"* trong menu chuột phải khi người dùng bôi đen một đoạn văn bản bất kỳ khi đang lướt mạng xã hội Facebook hay đọc báo trực tuyến .

Background script của tiện ích tự động bắt sự kiện, gửi văn bản bôi đen tới dịch vụ REST API trên máy chủ và hiển thị ngay lập tức một bảng kết quả cảnh báo (Popup/Alert) trực quan tại giao diện trình duyệt chỉ sau 3–5 giây . Điều này giúp người dùng phổ thông chủ động phát hiện và cảnh giác trước các luồng tin giả ngay tại thời điểm tiếp cận thông tin.

1.6. TÓM TẮT CHƯƠNG 1

1.6.1. Tổng kết các nội dung lý thuyết và kết quả khảo sát trong Chương 1

Chương 1 đã tiến hành nghiên cứu tổng quan và hệ thống hóa toàn bộ cơ sở lý luận, thực trạng cùng các phương pháp khoa học liên quan đến bài toán nhận diện tin giả trên không gian mạng. Cụ thể, các kết quả cốt lõi được đúc kết như sau:

1. **Khái niệm và Tác hại của Tin giả:** Tin giả (Fake News) cùng các dạng biến tướng như thông tin sai lệch (Misinformation) và thông tin độc hại cố ý (Disinformation) đã trở thành mối đe dọa nghiêm trọng đối với trật tự an toàn xã hội, nền tri thức và sự tiếp cận thông tin trung thực của cộng đồng.
2. **So sánh Phương pháp Kiểm chứng:**

   Phương pháp truyền thống (Fact-checking thủ công): Đạt độ chính xác và tính pháp lý cao nhưng gặp phải nút thắt cổ chai về chi phí, nhân lực và hoàn toàn không thể mở rộng quy mô (unscalable) để đáp ứng dòng dữ liệu khổng lồ phát sinh theo thời gian thực trên mạng xã hội.

   Phương pháp phát hiện tự động: Mô hình hóa việc nhận diện tin giả thành bài toán phân loại văn bản nhị phân có giám sát (Binary Text Classification), giúp tự động hóa hoàn toàn quy trình xử lý với tốc độ tính bằng mili giây.

3. **Khảo sát Các Hướng tiếp cận và Mô hình Kỹ thuật:**

   Học máy truyền thống (Naive Bayes, Logistic Regression, Random Forest, SVM) kết hợp TF-IDF/BoW: Phân loại nhanh trên ma trận đặc trưng nhưng bỏ qua hoàn toàn trật tự từ và ngữ cảnh câu, dẫn đến việc không hiểu được các câu văn mỉa mai hoặc cấu trúc ngôn ngữ phức tạp.

   Mô hình ngôn ngữ tiền huấn luyện PhoBERT: Được huấn luyện chuyên biệt trên 20GB ngữ liệu tiếng Việt (1GB Wikipedia và 19GB tin tức báo chí) và tích hợp công cụ phân đoạn từ RDRSegmenter (VnCoreNLP), PhoBERT mã hóa trọn vẹn ngữ cảnh hai chiều của văn bản thành véc-tơ đặc trưng 768 chiều chất lượng cao.

4. **Nhận diện Thách thức Đặc thù và Giải pháp Mô hình Lai PhoBERT - SVM:** Dữ liệu tiếng Việt trên mạng xã hội chứa mật độ nhiễu rất cao (teencode, từ viết tắt, sai chính tả, tiếng lóng, pha trộn ngôn ngữ). Trong khi việc tinh chỉnh (fine-tuning) toàn bộ mô hình PhoBERT đòi hỏi hạ tầng GPU đắt đỏ và dễ gây hiện tượng quá khớp (overfitting), giải pháp kết hợp PhoBERT (Bộ trích xuất đặc trưng ngữ nghĩa 768 chiều) và SVM (Bộ phân loại siêu phẳng tối ưu lề Margin) vừa đảm bảo độ chính xác vượt trội vừa tiết kiệm tối đa tài nguyên tính toán.

1.6.2. Ý nghĩa lý luận, thực tiễn và định hướng sang Chương 2

1. **Ý nghĩa Lý luận Khoa học:** Việc tổng quan toàn diện và đề xuất mô hình lai PhoBERT-SVM đã cung cấp luận cứ khoa học vững chắc về sự kết hợp giữa mô hình Transformer tiền huấn luyện hiện đại và thuật toán học máy tối ưu lề truyền thống trong xử lý ngôn ngữ tiếng Việt. Đồng thời, quy trình tiền xử lý chuẩn hóa (xử lý teencode, phân tách từ ghép bằng RDRSegmenter) đóng góp một khung giải pháp hiệu quả cho việc xử lý dữ liệu phi cấu trúc trên mạng xã hội.

2. **Ý nghĩa Thực tiễn và Khả năng Triển khai:** Đề tài không chỉ dừng lại ở thử nghiệm phòng thí nghiệm mà còn định hướng đóng gói mô hình thành dịch vụ REST API trên máy chủ và phát triển Tiện ích mở rộng Chrome Extension. Tiện ích này cho phép người dùng bôi đen văn bản trực tiếp trên trình duyệt để kiểm tra tính xác thực và nhận cảnh báo thời gian thực, góp phần chủ động ngăn chặn sự lan truyền của thông tin sai lệch.
3. **Định hướng Chuyển tiếp sang Chương 2:** Toàn bộ hệ thống lý thuyết, mô hình toán học và kết quả khảo sát ở Chương 1 đóng vai trò là nền tảng trực tiếp để triển khai **CHƯƠNG 2: PHƯƠNG PHÁP NGHIÊN CỨU**. Trong Chương 2, báo cáo sẽ trình bày chi tiết quy trình thu thập và làm sạch dữ liệu, toán học mã hóa véc-tơ 768 chiều của PhoBERT, thuật toán tối ưu siêu phẳng SVM và các chỉ số đo lường hiệu năng (Accuracy, Precision, Recall, F1-score, Confusion Matrix) phục vụ công tác thực nghiệm.

CHƯƠNG 2: PHƯƠNG PHÁP NGHIÊN CỨU

Trong chương này, báo cáo sẽ trình bày chi tiết cơ sở lý thuyết, mô hình toán học và quy trình thực nghiệm được sử dụng để xây dựng hệ thống nhận diện tin giả tiếng Việt. Trọng tâm phương pháp luận dựa trên giải pháp kết hợp giữa mô hình ngôn ngữ tiền huấn luyện PhoBERT (đóng vai trò trích xuất véc-tơ đặc trưng ngữ nghĩa 768 chiều) và thuật toán học máy Support Vector Machine (SVM) (đóng vai trò phân loại tối ưu siêu phẳng).

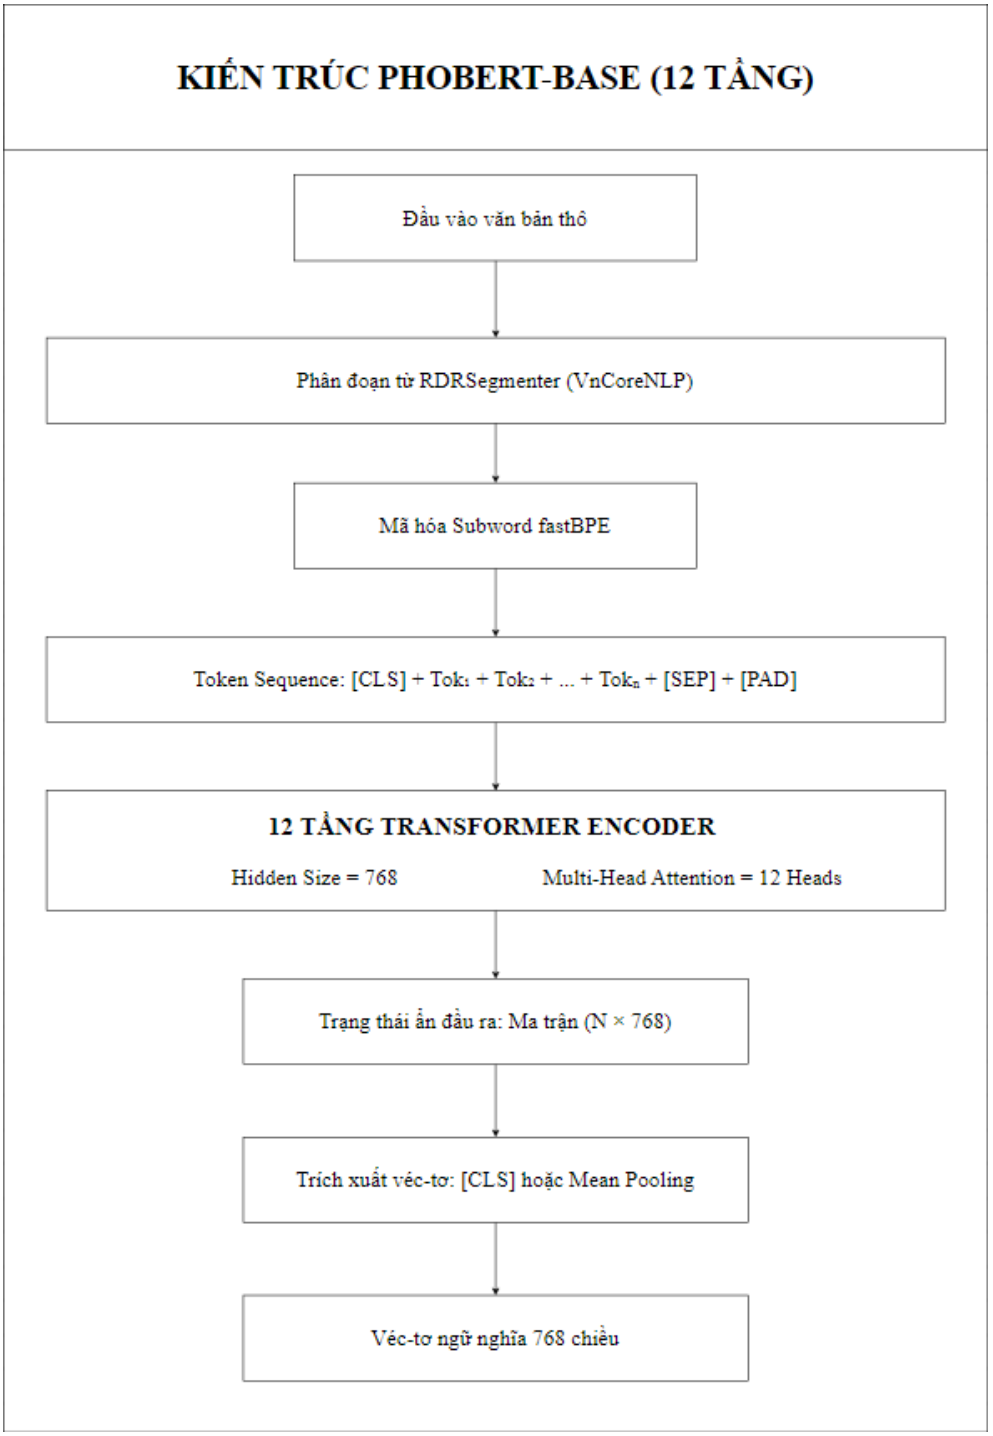
2.1. TỔNG QUAN PHƯƠNG PHÁP PHOBERT VÀ SVM

Phương pháp đề xuất trong nghiên cứu này được thiết kế theo kiến trúc học máy kết hợp (Hybrid Machine Learning Architecture). Nhằm khắc phục tình trạng ma trận thưa và thiếu thông tin ngữ cảnh của các phương pháp đếm từ truyền thống (như TF-IDF hay Bag-of-Words), đồng thời tránh chi phí tính toán đắt đỏ khi tinh chỉnh (fine-tuning) toàn bộ mạng học sâu, hệ thống phân chia bài toán thành hai giai đoạn độc lập: trích xuất ngữ nghĩa hai chiều bằng PhoBERT và phân lớp tối ưu lề bằng SVM.

2.1.1. PhoBERT - Mô hình trích xuất đặc trưng ngữ nghĩa

2.1.1.1. Kiến trúc mô hình PhoBERT

PhoBERT là mô hình ngôn ngữ học sâu tiền huấn luyện (Pre-trained Language Model) chuyên biệt cho tiếng Việt do Viện Nghiên cứu Trí tuệ Nhân tạo VinAI Research công bố vào tháng 03/2020. Mô hình được phát triển dựa trên kiến trúc RoBERTa (Robustly Optimized BERT Approach) của Facebook, kế thừa và tối ưu hóa từ mạng mã hóa Transformer Encoder.



Hình 2.1: Sơ đồ kiến trúc PHOBERT-BASE 12 tầng

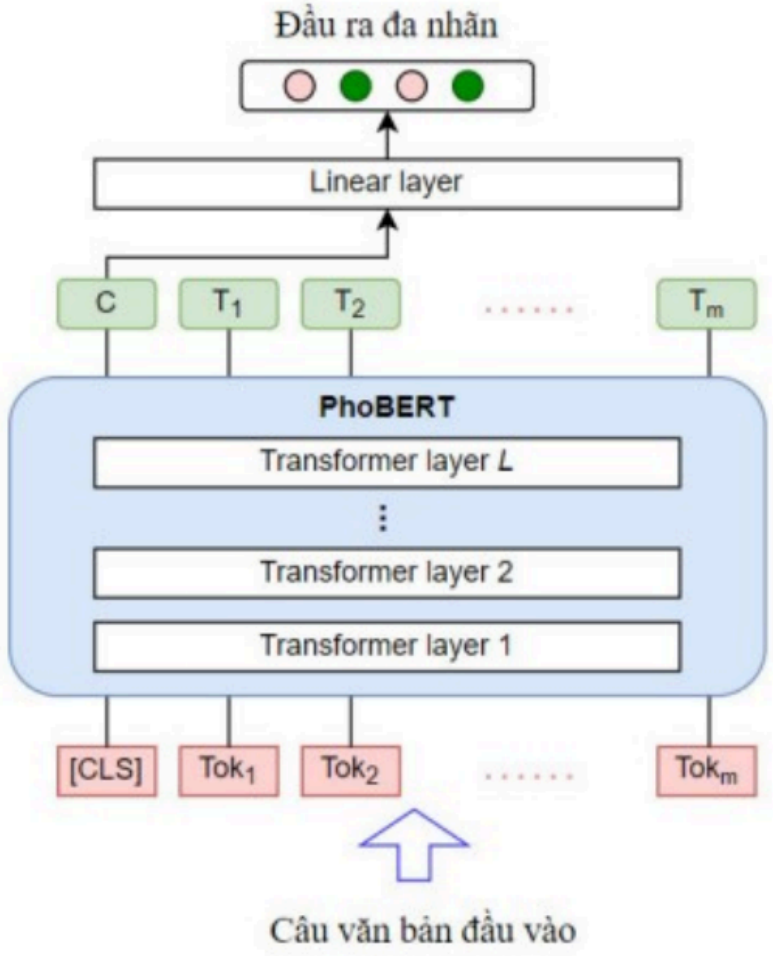
Nguồn: Tác giả tự tổng hợp (dựa trên Dat Quoc Nguyen & Anh Tuan Nguyen, 2020 và Nguyễn Lê Minh Hòa & Trần Văn Lăng, 2023)

PhoBERT chỉ sử dụng nửa Encoder của kiến trúc Transformer để đóng vai trò mã hóa câu văn bản thành biểu diễn số học mà không bao gồm phần Decoder sinh câu. PhoBERT có hai phiên bản kiến trúc chuẩn:

1. **PhoBERT-base:** Bao gồm 12 tầng Transformer Encoder (layers), kích thước không gian ẩn (hidden size) $d = 768$ chiều, 12 đầu chú ý (Multi-Head Self-Attention heads), chứa tổng cộng khoảng 110 triệu đến 135 triệu tham số.
2. **PhoBERT-large:** Bao gồm 24 tầng Transformer Encoder, kích thước không gian ẩn $d = 1024$ chiều, 16 đầu chú ý, chứa tổng cộng khoảng 340 triệu đến 370 triệu tham số.

Trong nghiên cứu này, phiên bản PhoBERT-base được lựa chọn làm bộ trích xuất đặc trưng chính nhờ sự cân bằng tối ưu giữa năng lực biểu diễn ngữ nghĩa và chi phí tài nguyên tính toán. Mỗi tầng Transformer trong PhoBERT-base được cấu tạo từ hai khối chức năng cốt lõi:

- **Cơ chế Tự chú ý đa đầu (Multi-Head Self-Attention):** Cho phép mô hình đồng thời tính toán trọng số tương quan giữa từng từ với tất cả các từ còn lại trong câu, giúp nắm bắt ngữ cảnh hai chiều (bên trái và bên phải) cùng các mối quan hệ ngữ pháp xa nhau trong câu.
- **Mạng Nơ-ron Truyền thẳng (Feed-Forward Neural Network):** Áp dụng biến đổi phi tuyến tính độc lập trên từng vị trí véc-tơ đặc trưng để tăng khả năng biểu diễn ngữ nghĩa. Tầng này kết hợp các kỹ thuật chuẩn hóa lớp (Layer Normalization) và kết nối tắt (Residual Connections) để đảm bảo sự ổn định khi lan truyền thông tin qua 12 tầng sâu.



Hình 2.2: Sơ đồ kiến trúc tổng thể 12 tầng Transformer Encoder của PhoBERT-base

Nguồn: Nguyễn Lê Minh Hòa và Trần Văn Lăng, 2023

2.1.1.2. Dữ liệu và phương pháp tiền huấn luyện

PhoBERT được huấn luyện tự giám sát (Self-supervised learning) trên tập ngữ liệu đơn ngữ tiếng Việt khổng lồ có dung lượng khoảng 20GB (bao gồm 1GB dữ liệu từ Wikipedia tiếng Việt và 19GB dữ liệu tin tức báo chí trực tuyến, tương đương với khoảng 145 triệu câu văn chuẩn).

Khác với mô hình BERT đa ngôn ngữ (mBERT) hay RoBERTa tiếng Anh, PhoBERT giải quyết triệt để rào cản phân đoạn từ ghép tiếng Việt nhờ quy trình tiền xử lý hai bước:

1. **Phân đoạn từ ghép tiếng Việt bằng RDRSegmenter:** PhoBERT tích hợp công cụ tách từ RDRSegmenter nằm trong bộ thư viện VnCoreNLP. Công cụ này gắn nối các âm tiết đơn hợp thành từ ghép bằng dấu gạch dưới (ví dụ: cụm *"tin tức"* → *"tin_tức"*, *"tiền xử lý"* → *"tiền_xử_lý"*) trước khi đưa vào bước mã hóa.
2. **Mã hóa Subword bằng fastBPE:** Sau khi tách từ ghép, chuỗi văn bản tiếp tục được phân tách thành các đơn vị subword bằng thuật toán fastBPE (Byte-Pair Encoding) để xử lý các từ hiếm hoặc từ ngoài từ điển (Out-Of-Vocabulary - OOV).

Về tác vụ huấn luyện, theo tư tưởng của RoBERTa, PhoBERT chỉ sử dụng tác vụ Mô hình ngôn ngữ bị che (Masked Language Modeling - MLM) và loại bỏ tác vụ Dự đoán câu tiếp theo (Next Sentence Prediction - NSP). Trong quá trình MLM, mô hình ngẫu nhiên che (mask) 15% các token trong câu văn và yêu cầu mạng Transformer dự đoán chính xác token gốc dựa trên ngữ cảnh hai chiều xung quanh. Kỹ thuật chế động (Dynamic Masking) qua mỗi epoch giúp PhoBERT học được biểu diễn ngữ nghĩa phong phú và kháng nhiễu tốt.

2.1.1.3. Ví dụ chi tiết quy trình trích xuất véc-tơ ngữ nghĩa từ văn bản đầu vào

Để minh họa quy trình trích xuất véc-tơ ngữ nghĩa từ một bài đăng mạng xã hội, xét câu văn bản thô đầu vào S:

$$S: "VaccineCOVID - 19gâyvôsinhởnamgiới."$$

Quy trình trích xuất qua mô hình PhoBERT-base diễn ra qua 3 bước kỹ thuật:

1. **Bước 1 – Tokenization và Tạo chuỗi ID:** Văn bản thô được RDR Segmenter (VnCoreNLP) phân đoạn từ ghép và chèn hai token quản lý cấu

trúc đặc biệt: token [CLS] (Classification) đặt tại đầu câu đại diện cho toàn bộ ngữ cảnh câu, và token [SEP] (Separator) đặt tại cuối câu.

$$ChuỗiToken: [CLS], vaccine, covid - 19, gây, vô_sinh, ở, nam_giới, [SEP]$$

Sau đó, Tokenizer của PhoBERT ánh xạ từng token thành các chỉ số ID tương ứng trong từ điển (Vocabulary Index) và tạo thêm mảng đệm Attention Mask.

2. **Bước 2 – Tương tác qua 12 tầng Transformer Encoder:** Chuỗi token được truyền qua 12 tầng Transformer. Cơ chế Tự chú ý (Self-Attention) tính toán mối tương quan ngữ nghĩa giữa các từ. Ví dụ: từ *"gây"* được tính toán trọng số liên kết mạnh với *"vaccine"* (nguyên nhân) và *"vô_sinh"* (kết quả), giúp mô hình nắm bắt trọn vẹn thông tin ngữ nghĩa mà không bị đánh lừa bởi từ khóa riêng lẻ.
3. **Bước 3 – Trích xuất Véc-tơ đặc trưng 768 chiều:** Tại tầng ra cuối cùng (lớp 12), PhoBERT xuất ra một ma trận trạng thái ẩn có kích thước $1 \times T \times 768$ (trong đó T là độ dài chuỗi token). Véc-tơ trạng thái ẩn tương ứng với vị trí token đặc biệt [CLS] được trích xuất để làm véc-tơ biểu diễn đại diện cho toàn bộ nội dung văn bản:

$$x_{[CLS]} = [x_1, x_2, x_3, \ldots, x_{768}]^T \in \mathbb{R}^{768} \quad (2.1)$$

Véc-tơ 768 chiều này đóng vai trò là đầu vào số học cố định, được lưu trữ để chuyển sang bộ phân loại SVM.

Quy trình xử lý chuỗi token đầu vào qua 12 tầng Transformer Encoder của PhoBERT nhằm trích xuất véc-tơ ngữ nghĩa [CLS] có 768 chiều đã được trình bày tại **Hình 1.5 (Chương 1, Mục 1.3.3.3)**.

2.1.2. SVM - Thuật toán phân loại tin tức

2.1.2.1. Kiến trúc và cơ sở toán học của SVM trong không gian 768 chiều

Support Vector Machine (SVM / Máy véc-tơ hỗ trợ) là một thuật toán học máy có giám sát được xây dựng trên nền tảng lý thuyết học thống kê của Vladimir Vapnik. Trong hệ thống nhận diện tin giả tiếng Việt, SVM đóng vai trò là bộ phân loại nhị phân ở tầng cuối cùng của mạng.

SVM tiếp nhận đầu vào là các véc-tơ nhúng ngữ nghĩa theo ngữ cảnh $x_i \in R^{768}$ trích xuất từ vị trí token đặc biệt [CLS] của mô hình PhoBERT. Thuật toán tiến hành phân tách tập dữ liệu thành hai lớp nhãn nhị phân hoàn toàn riêng biệt:

- **Lớp Tin thật (Real News):** Quy ước gán nhãn $y_i = -1$ (hoặc nhãn 0).
- **Lớp Tin giả (Fake News):** Quy ước gán nhãn $y_i = +1$ (hoặc nhãn 1).

Về mặt toán học, SVM tìm kiếm một siêu phẳng phân tách (Separating Hyperplane) trong không gian đặc trưng 768 chiều có phương trình tổng quát:

$$w^T x + b = 0 \quad \Leftrightarrow \quad \sum_{j=1}^{768} w_j x_j + b = 0 \tag{2.2}$$

Trong đó:

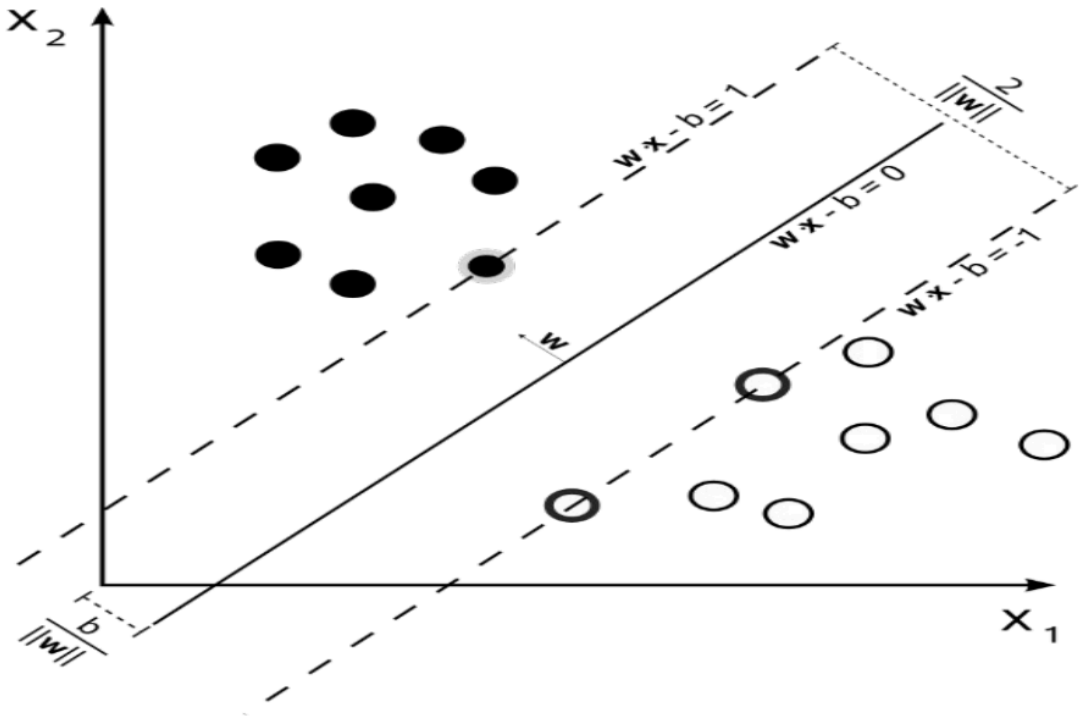
- $w = [w_1, w_2, w_3, ..., w_{768}]^T \in \mathbb{R}^{768}$ là véc-tơ trọng số pháp tuyến quyết định định hướng vuông góc của siêu phẳng trong không gian 768 chiều.
- $x \in \mathbb{R}^{768}$ là véc-tơ đặc trưng ngữ nghĩa đầu vào được trích xuất từ PhoBERT.
- $b \in \mathbb{R}$ là hệ số tự do (bias) điều chỉnh vị trí dịch chuyển của siêu phẳng so với gốc tọa độ.

Khoảng cách Euclidean từ một điểm véc-tơ đặc trưng x_i bất kỳ trong tập dữ liệu đến siêu phẳng phân tách được tính bằng công thức toán học:

$$d(x_i, hyperplane) = \frac{|w^T x_i + b|}{||w||_2} \quad (2.3)$$

Trong đó $||w||_2 = \sqrt{\sum_{j=1}^{768} w_j^2}$ đại diện cho độ dài Euclidean của véc-tơ trọng số pháp tuyến w.

Trong quá trình huấn luyện, các điểm dữ liệu nằm sát siêu phẳng nhất ở cả hai lớp được gọi là các véc-tơ hỗ trợ (Support Vectors). Các véc-tơ hỗ trợ này chính là các điểm mốc quyết định trực tiếp đến định hướng và vị trí của siêu phẳng tối ưu. Toàn bộ siêu phẳng phân tách có thể được tái dựng hoàn toàn chỉ dựa trên tập hợp các véc-tơ hỗ trợ mà không cần lưu trữ toàn bộ dữ liệu huấn luyện ban đầu, giúp tối ưu hóa dung lượng bộ nhớ.



Hình 2.3: Sơ đồ toán học mô tả siêu phẳng phân tách $w^T x + b = 0$ và khoảng cách lề $Margin \frac{2}{||w||}$ của thuật toán SVM

Nguồn: Bùi Công Tùng và cs., 2022

2.1.2.2. Lựa chọn Kernel (Linear vs RBF) và tham số phạt C, γ

Trong bài toán phân loại tin tức từ văn bản mạng xã hội, các véc-tơ đặc trưng 768 chiều từ PhoBERT có thể phân bố tuyến tính hoặc phi tuyến tính phức tạp trong không gian đa chiều. Thuật toán SVM hỗ trợ xử lý linh hoạt thông qua kỹ thuật biến đổi nhân (Kernel Trick):

1. **Linear Kernel (Hàm nhân tuyến tính):**

$$K(x_i, x_j) = x_i^T x_j \tag{2.4}$$

Hàm nhân tuyến tính tính trực tiếp tích vô hướng giữa hai véc-tơ đặc trưng trong không gian gốc. Hàm nhân này đặc biệt phù hợp với các véc-tơ ngữ nghĩa 768 chiều từ PhoBERT vì dữ liệu sau khi trải qua 12 tầng Transformer Encoder đã được biểu diễn ở dạng ngữ nghĩa chất lượng cao và có tính phân tách tuyến tính rất tốt. Ưu điểm nổi bật của Linear Kernel là tốc độ tính toán huấn luyện cực kỳ nhanh, cấu hình đơn giản và tốn ít bộ nhớ.

2. **RBF Kernel (Radial Basis Function - Hàm nhân đối xứng tâm):**

$$K(x_i, x_j) = exp(-\ \gamma\ ||x_i - x_j||^2) \tag{2.5}$$

Trong đó $||x_i - x_j||^2$ là bình phương khoảng cách Euclidean giữa hai véc-tơ nhúng x_i và x_j, còn $\gamma > 0$ (gamma) là siêu tham số điều chỉnh độ nhạy và bán kính ảnh hưởng của từng điểm dữ liệu. RBF Kernel ánh xạ dữ liệu phi tuyến tính lên không gian đặc trưng vô hạn chiều để tìm ranh giới phân tách mượt mà.

Cấu hình tối ưu của mô hình SVM phụ thuộc trực tiếp vào tham số phạt lỗi C (Penalty Parameter):

- **Khi tham số C chọn giá trị lớn:** Thuật toán ưu tiên tối đa hóa việc phân loại đúng tuyệt đối tất cả các mẫu trên tập huấn luyện, chấp nhận khoảng cách lề hẹp hơn. Điều này có thể khiến mô hình nhạy cảm với nhiễu và dễ dẫn đến hiện tượng quá khớp (overfitting).
- **Khi tham số C chọn giá trị vừa phải (mặc định $C = 1.0$):** Thuật toán chấp nhận cho phép một số điểm dữ liệu nhiễu nằm vi phạm đường biên lề (Lề mềm - Soft Margin) để ưu tiên mở rộng khoảng cách lề cực đại. Kỹ thuật này giúp mô hình đạt khả năng tổng quát hóa rất tốt trên tập dữ liệu kiểm thử thực tế.

2.1.2.3. Nguyên lý tối ưu lề $Margin\ \frac{2}{||w||}$ và ví dụ phân loại bằng siêu phẳng $w^T x + b = 0$

Nguyên lý vận hành cốt lõi của SVM là tìm kiếm siêu phẳng phân tách sao cho khoảng cách lề (Margin) giữa hai đường biên hỗ trợ song song $w^T x + b = +1$ và $w^T x + b = -1$ đạt giá trị lớn nhất. Khoảng cách lề Margin được tính bằng công thức toán học:

$$Margin = \frac{2}{||w||_2} \tag{2.6}$$

Để tối đa hóa khoảng cách lề $Margin\ \frac{2}{||w||}$, bài toán được chuyển đổi tương đương về việc tối thiểu hóa $\frac{1}{2}||w||^2$. Để xử lý hiện tượng dữ liệu mạng xã hội bị nhiễu (Soft Margin), thuật toán đưa vào các biến chùng (slack variables) $\xi_i \geq 0$ đại diện cho khoảng cách vi phạm lề của mẫu thứ i.

Bài toán tối ưu hóa SVM được phát biểu dưới dạng toán học tổng quát:

$$min_{w,b,\xi} \frac{1}{2}||w||^2 + C\sum_{i=1}^{N} \xi_i \quad (2.7)$$

thỏa mãn điều kiện: (2.8)

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad \forall i = 1, \ldots, N$$

Bài toán này được giải quyết thông qua bài toán đối kháng Lagrange (Dual Optimization Formulation). Sau khi tìm được véc-tơ trọng số w và hệ số b, hàm quyết định phân loại cho một mẫu văn bản mới được xác định:

- Nếu $f(x) = w^T x + b \geq 0$: Hệ thống dự đoán nhãn 1 (Tin giả).
- Nếu $f(x) = w^T x + b < 0$: Hệ thống dự đoán nhãn 0 (Tin thật).

Ví dụ số học minh họa quy trình phân loại: Giả sử xét một bài đăng nghi vấn có nội dung: *"Vaccine COVID-19 gây vô sinh ở nam giới."*. Véc-tơ đặc trưng nhúng 768 chiều được trích xuất từ vị trí token [CLS] của PhoBERT là

$$x_{test} = [0.12, \ -0.45, \ 0.78, \ ..., \ 0.23]^T \in \mathbb{R}^{768}.$$

Sau quá trình huấn luyện trên tập ngữ liệu, mô hình SVM học được véc-tơ trọng số pháp tuyến $w = [0.50, \ -0.20, \ 0.10, \ldots, \ 0.40]^T$ và hệ số độ lệch $b = -0.30$.

Giá trị hàm quyết định phân loại $f(x_{test})$ được tính toán chi tiết:

$$f(x_{test}) = w^T x_{test} + b = (0.50 \times 0.12) + (-0.20 \times -0.45) + (0.10 \times 0.78) + \ldots - 0.30 = +0.75 \quad (2.9)$$

Do giá trị $f(x_{test}) =+ 0.75 \geq 0$, hệ thống xuất ra kết quả phân loại nhãn $y = 1$, đưa ra kết luận bài đăng là Tin giả.

2.1.3. Lý do chọn và tính bổ trợ giữa PhoBERT và SVM

2.1.3.1. Ưu điểm của PhoBERT trong xử lý tiếng Việt

So với các phương pháp biểu diễn từ tĩnh (Word2Vec, FastText) hay các mô hình đa ngôn ngữ (mBERT), mô hình PhoBERT mang lại những lợi thế vượt trội khi xử lý dữ liệu tiếng Việt:

- **Tối ưu chuyên biệt cho ngôn ngữ đơn lập Tiếng Việt:** Được huấn luyện tự giám sát trên 20GB ngữ liệu tiếng Việt chuẩn và tích hợp sẵn công cụ phân đoạn từ RDRSegmenter (VnCoreNLP), PhoBERT giải quyết triệt để rào cản phân tách từ ghép. Điều này giúp mô hình hiểu sâu sắc cấu trúc ngữ pháp và sắc thái biểu đạt tiếng Việt hơn hẳn các mô hình đa ngôn ngữ.
- **Biểu diễn ngữ nghĩa theo ngữ cảnh hai chiều (Contextual Embeddings):** Nhờ cơ chế Tự chú ý (Self-Attention) của kiến trúc Transformer, véc-tơ nhúng do PhoBERT tạo ra phản ánh trọn vẹn ngữ cảnh hai chiều xung quanh từ. Cùng một từ tiếng Việt đứng trong các ngữ cảnh khác nhau sẽ được mã hóa thành các véc-tơ 768 chiều khác nhau, giúp mô hình nhận biết chính xác các câu văn đa nghĩa hoặc cố ý mỉa mai.
- **Nén thông tin ngữ cảnh vào véc-tơ 768 chiều chất lượng cao:** Véc-tơ tại token [CLS] (hoặc qua kỹ thuật Mean Pooling) cô đọng trọn vẹn nội dung bài viết thành một véc-tơ cố định có độ dài 768 chiều, tạo đầu vào số học chuẩn hóa cho bộ phân loại.

2.1.3.2. Ưu điểm của SVM trong phân loại

Trong tầng phân loại nhị phân, thuật toán Support Vector Machine là sự lựa chọn tối ưu khi làm việc trên không gian véc-tơ nhúng 768 chiều:

1. **Hiệu quả vượt trội trên không gian đặc trưng số chiều lớn ($d = 768$):** SVM được chứng minh là một trong những thuật toán học máy có độ ổn định

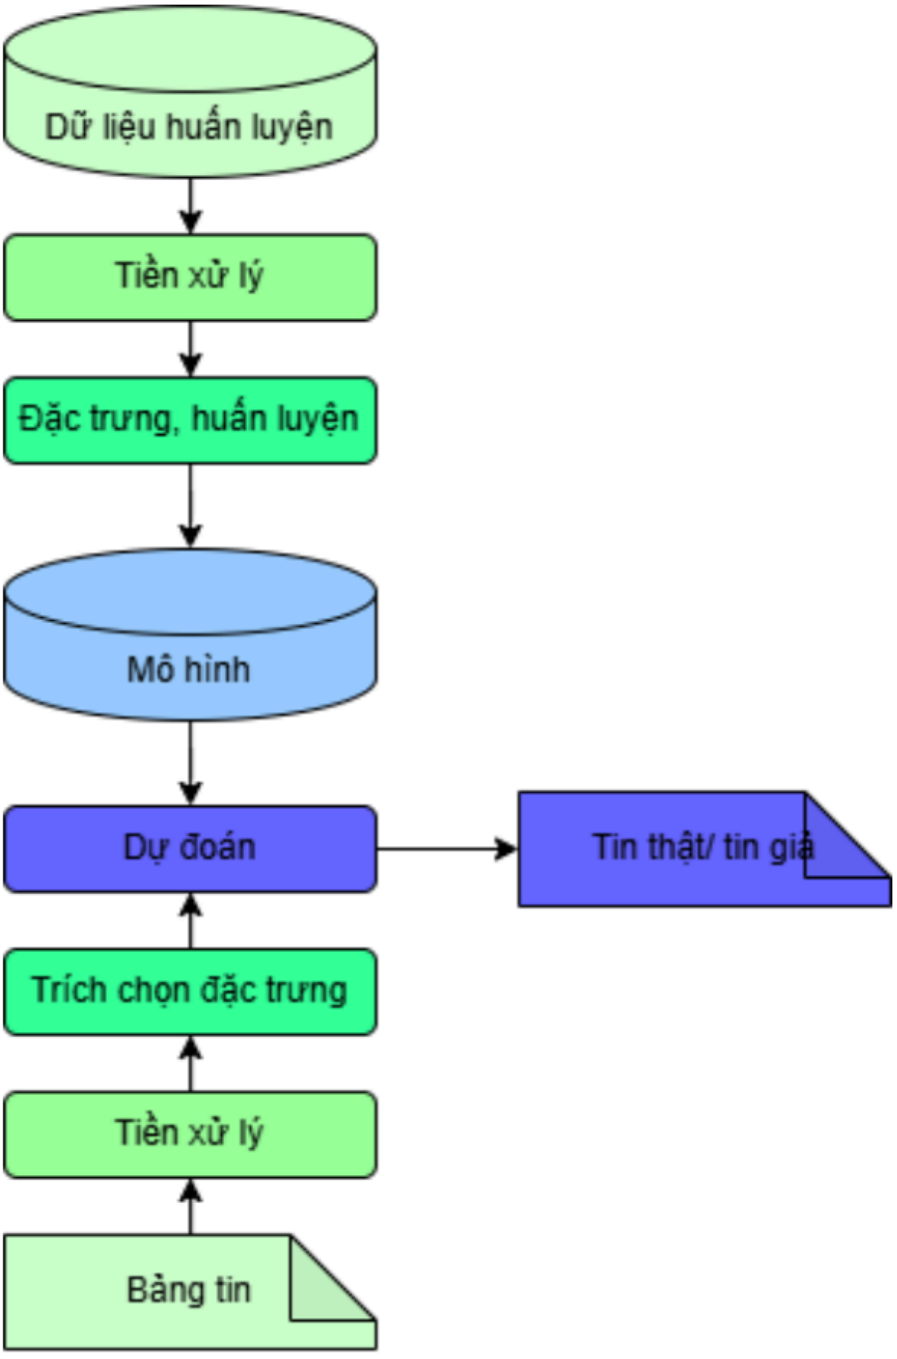
và chính xác cao nhất khi xử lý các bài toán phân loại văn bản có số chiều lớn.

2. **Khả năng kháng quá khớp (Anti-Overfitting) và tổng quát hóa cao:** Nhờ nguyên lý tối ưu lề cực đại (Margin Maximization) và đặc tính chỉ phụ thuộc vào tập hợp các véc-tơ hỗ trợ (Support Vectors), SVM tổng quát hóa rất tốt trên dữ liệu mới và hạn chế tối đa nguy cơ học vẹt.
3. **Tốc độ tính toán nhanh và tiết kiệm tài nguyên:** Quá trình huấn luyện và dự đoán của SVM với Kernel tuyến tính diễn ra cực kỳ nhanh chóng trên CPU thông thường mà không đòi hỏi hạ tầng GPU đắt đỏ.

2.1.3.3. Sự kết hợp PhoBERT-SVM giúp tối ưu hiệu năng và tài nguyên tính toán.

Sự kết hợp giữa PhoBERT và SVM tạo nên một mô hình lai bổ trợ hoàn hảo, khắc phục triệt để các hạn chế của các phương pháp đơn lẻ:

- **Phân định nhiệm vụ tối ưu:** PhoBERT đảm nhận toàn bộ vai trò trích xuất biểu diễn ngữ nghĩa hai chiều sâu sắc từ văn bản tiếng Việt. Trong khi đó, SVM đóng vai trò là bộ phân loại siêu phẳng chịu trách nhiệm xác định ranh giới phân tách tối ưu giữa Tin thật và Tin giả trong không gian 768 chiều.
- **Tiết kiệm tài nguyên và tính khả thi cao:** Thay vì phải fine-tuning tất cả 110 triệu tham số của PhoBERT (yêu cầu GPU cấu hình đắt đỏ và dễ bị overfitting trên tập dữ liệu nhỏ), hệ thống tiến hành đóng đóng băng (freeze) trọng số PhoBERT và chạy ở chế độ không tính đạo hàm (torch.no_grad()) để trích xuất véc-tơ 768 chiều. Các véc-tơ này sau đó được chuyển sang huấn luyện mô hình SVM, giúp quy trình đạt độ chính xác rất cao nhưng lại tiết kiệm tối đa thời gian và tài nguyên máy tính.



Hình 2.4: Quy trình tổng quát nhận diện tin giả từ dữ liệu thô qua PhoBERT trích xuất véc-tơ 768 chiều đến bộ phân loại SVM

Nguồn: Bùi Trường Thịnh, 2025

2.2. QUY TRÌNH THU THẬP VÀ XỬ LÝ DỮ LIỆU

Thành công của một hệ thống nhận diện tin giả dựa trên học máy và xử lý ngôn ngữ tự nhiên (NLP) phụ thuộc rất lớn vào chất lượng và quy mô của tập dữ liệu huấn luyện. Dữ liệu thô thu thập từ môi trường mạng xã hội vốn chứa mật độ nhiễu cao, không đồng nhất và mang đặc thù phi cấu trúc. Do đó, xây dựng một quy trình thu thập, làm sạch, chuẩn hóa và phân chia dữ liệu bài bản là bước tiền đề bắt buộc trước khi đưa dữ liệu vào giai đoạn trích xuất véc-tơ đặc trưng và huấn luyện mô hình.

2.2.1. Nguồn dữ liệu và đặc điểm tập dữ liệu

2.2.1.1. Mô tả các nguồn dữ liệu tin giả tiếng Việt

Để đảm bảo tính khách quan và khả năng so sánh với các công trình nghiên cứu trong nước, đề tài kết hợp khai thác nguồn ngữ liệu từ hai tập dữ liệu tin giả tiếng Việt tiêu chuẩn đã được cộng đồng nghiên cứu gán nhãn đáng tin cậy:

1. **Bộ dữ liệu VFND (Vietnamese Fake News Dataset):** Tập hợp các tin bài báo chí và bài viết mạng xã hội thuộc nhiều lĩnh vực đời sống xã hội nhạy cảm như chính trị, y tế, kinh tế, giáo dục và văn hóa.
2. **Bộ dữ liệu ReINTEL (Reliable Intelligence Identification):** Bộ ngữ liệu thu thập các bài đăng thực tế trên mạng xã hội kèm theo các tương tác cộng đồng, được gán nhãn bởi các chuyên gia truyền thông.

Ngoài ra, nhằm tăng cường khả năng nhận diện các dạng tin đồn và tin giả mới phát sinh theo thời gian thực, đề tài tích hợp thêm tập dữ liệu cào tự động (Web Scraping / Crawling) từ các diễn đàn công khai, Fanpage Facebook và các trang tin tức trực tuyến.

2.2.1.2. Cấu trúc tổ chức dữ liệu: Article_Contents và Social_Contents

Tập dữ liệu sử dụng trong nghiên cứu được tổ chức logic thành hai phần ngữ liệu chính:

- **Phần dữ liệu Báo chí (Article_Contents):** Bao gồm các bài báo chính thống được thu thập từ các cơ quan báo chí điện tử uy tín tại Việt Nam (như VnExpress, Tuổi Trẻ, Thanh Niên, VietnamNet). Các bài viết này được chọn lọc làm ngữ liệu chuẩn cho lớp Tin thật (Real News / Label = 0).
- **Phần dữ liệu Mạng xã hội (Social_Contents):** Bao gồm các bài đăng (posts), bài chia sẻ, trạng thái (status) và bình luận được trích xuất từ các nền tảng mạng xã hội.

Phần dữ liệu này chứa cả thông tin thật và các tin đồn, bài viết bịa đặt, giật tít, chưa qua kiểm chứng. Các mẫu bịa đặt được gán nhãn cho lớp Tin giả (Fake News / Label = 1).

2.2.1.3. Thống kê đặc điểm và phân bố tỷ lệ nhãn tập dữ liệu

Thống kê đặc điểm và phân bố tỷ lệ nhãn tập dữ liệu: Tập dữ liệu sau khi tổng hợp và loại bỏ các bản ghi hư hỏng chứa khoảng 10.000 mẫu văn bản tiếng Việt hoàn chỉnh. Mỗi mẫu dữ liệu cấu trúc bao gồm các trường thông tin: tiêu đề bài viết (title), nội dung chi tiết (text/content), thể loại tin tức (subject/domain), mốc thời gian xuất bản (date) và nhãn phân loại nhị phân (label).

- **Lớp Tin thật (Label = 0):** Chiếm khoảng 70% tổng số mẫu (tương đương 7.000 văn bản), phản ánh thực tế rằng các thông tin báo chí chính thống vẫn chiếm đa số trên môi trường truyền thông.
- **Lớp Tin giả (Label = 1):** Chiếm khoảng 30% tổng số mẫu (tương đương 3.000 văn bản), bao gồm các tin bài bịa đặt về dịch bệnh, lừa đảo tài chính, phát ngôn giả mạo.

Sự chênh lệch tỷ lệ 70 - 30 này phản ánh trung thực bản chất mất cân bằng lớp (Class Imbalance) của dữ liệu thực tế trên không gian mạng, đòi hỏi quy trình tiền xử lý và mô hình phân loại SVM phải có khả năng kháng lệch nhãn tốt.

2.2.2. Quy trình tiền xử lý văn bản tiếng Việt

2.2.2.1. Tầm quan trọng của tiền xử lý đối với dữ liệu mạng xã hội

Tầm quan trọng của tiền xử lý đối với dữ liệu mạng xã hội: văn bản trên mạng xã hội Việt Nam chứa độ nhiễu ngôn ngữ rất lớn. Nếu đưa trực tiếp chuỗi văn bản thô vào mô hình trích xuất véc-tơ PhoBERT, các ký tự rác, liên kết URL rác, từ viết tắt ngẫu hứng và lỗi gõ phím sẽ làm tăng kích thước từ điển ngoài mong muốn (Out-Of-Vocabulary - OOV), làm lệch ma trận chú ý (Attention Matrix) và suy giảm đáng kể độ chính xác phân loại. Do đó, quy trình tiền xử lý đóng vai trò loại bỏ yếu tố nhiễu nhưng vẫn bảo tồn trọn vẹn giá trị ngữ nghĩa hai chiều của câu.

2.2.2.2. Quy trình tiền xử lý văn bản tiếng Việt 5 bước chi tiết

Nghiên cứu thiết lập quy trình làm sạch và chuẩn hóa văn bản tự động gồm 5 bước kỹ thuật nối tiếp nhau:

1. **Bước 1 – Chuẩn hóa định dạng mã hóa và Làm sạch ký tự rác:** Chuyển đổi toàn bộ văn bản về chuẩn mã hóa ký tự Unicode NFC thống nhất, sửa chữa các lỗi font chữ tiếng Việt do gõ Telex/VNI khác nhau. Loại bỏ các thẻ định dạng HTML/XML còn sót lại từ quá trình cào dữ liệu (
, <p>, &) và chuyển đổi toàn bộ chuỗi văn bản về định dạng chữ thường (lowercase).
2. **Bước 2 – Chuẩn hóa các đại diện thực thể mạng xã hội (URL, User, Hashtag):** Các đường dẫn liên kết web phức tạp được thay thế bằng một từ khóa đại diện cố định là HTTPURL. Các thẻ nhắc tên tài khoản (như @ten_nguoi_dung) được thay thế bằng từ khóa HTTPUSER. Các thẻ Hashtag (#tin_nong) được giữ lại phần từ ngữ chính và loại bỏ dấu #.
3. **Bước 3 – Xử lý Teencode, Từ viết tắt và Biểu tượng cảm xúc (Emoji/Icon):** Sử dụng từ điển ánh xạ (Dictionary Mapping) để chuyển đổi các từ viết tắt và teencode mạng xã hội phổ biến về từ tiếng Việt chuẩn mực (ví dụ: *"ko"*, *"k"* → *"không"*; *"đc"*, *"dc"* → *"được"*; *"j"* → *"gì"*; *"ntn"* → *"như thế này"*). Chuyển đổi các biểu tượng cảm xúc (Emoji) có tần suất xuất hiện

cao thành cụm từ diễn đạt cảm xúc tương ứng (ví dụ: 😡 → *"tức giận"*, 😭 → *"khóc"*).

4. **Bước 4 – Phân tách từ ghép tiếng Việt (Word Segmentation) bằng RDRSegmenter:** Vì tiếng Việt là ngôn ngữ đơn lập, ranh giới từ không trùng với khoảng trắng. Đề tài tích hợp công cụ RDRSegmenter trong bộ thư viện VnCoreNLP để tự động xác định ranh giới từ ghép và gắn nối các âm tiết bằng dấu gạch dưới (ví dụ: *"tin giả"* → *"tin_giả"*, *"mạng xã hội"* → *"mạng_xã_hội"*).
5. **Bước 5 – Loại bỏ trùng lặp, Từ dừng (Stopwords) và Đồng nhất độ dài (Padding/Truncation):** Loại bỏ các bản ghi hoàn toàn trùng lặp hoặc các câu văn bản quá ngắn (dưới 3 từ). Thiết lập ngưỡng độ dài cố định max_length = 256 token. Các văn bản dài hơn 256 token sẽ bị cắt bỏ phần đuôi (truncation), các văn bản ngắn hơn sẽ được thêm các token đệm [PAD] (padding) để đảm bảo kích thước đầu vào đồng nhất cho mô hình PhoBERT.

2.2.2.3. Minh họa các bước biến đổi văn bản

Sự biến đổi cụ thể của một mẫu bài đăng thô mạng xã hội $S_{thô}$ = *"SỐC!! ko thể tin đc link URL_PLACEHOLDER #tin_nong dịch bệnh bùng phát* 😡*"* qua từng bước tiền xử lý được tổng hợp chi tiết trong Bảng 2.1:

Bảng 2.1: Minh họa quá trình biến đổi của câu văn bản qua 5 bước tiền xử lý chuyên biệt

Bước tiền xử lý	**Chuỗi văn bản sau khi xử lý**	**Mục đích & Mô tả kỹ thuật**
Văn bản thô ban đầu	SỐC!! ko thể tin đc link URL_PLACEHOLDER #tin_nong dịch bệnh bùng phát 😡	Tiếp nhận chuỗi văn bản thô từ mạng xã hội chứa teencode, icon, hashtag và liên kết rác

Bước 1: Chuẩn hóa NFC & Lowercase	sốc!! ko thể tin đc link URL_PLACEHOLDER #tin_nong dịch bệnh bùng phát 😡	Đồng nhất kiểu chữ thường và sửa lỗi mã hóa font tiếng Việt Unicode NFC
Bước 2: Chuẩn hóa URL & Hashtag	sốc ko thể tin đc link HTTPURL tin_nong dịch bệnh bùng phát 😡	Thay thế đường dẫn bằng đại diện HTTPURL, xóa dấu câu lặp !! và dấu #
Bước 3: Xử lý Teencode & Emoji	sốc không thể tin được link HTTPURL tin_nong dịch bệnh bùng phát tức giận	Ánh xạ ko → không, đc → được, và chuyển biểu tượng 😡 → tức giận.
Bước 4: Tách từ ghép (VnCoreNLP)	sốc không_thể tin được link HTTPURL tin_nóng dịch_bệnh bùng_phát tức_giận	Sử dụng RDRSegmenter gắn nối các âm tiết từ ghép tiếng Việt bằng dấu gạch dưới _ .
Bước 5: Bổ sung Token PhoBERT	[CLS] sốc không_thể tin được link HTTPURL tin_nóng dịch_bệnh bùng_phát tức_giận [SEP]	Chèn token đặc biệt [CLS] ở đầu câu và [SEP] ở cuối câu để làm đầu vào cho Tokenizer.

2.2.3. Phân chia tập huấn luyện và kiểm tra

2.2.3.1. Nguyên tắc lấy mẫu ngẫu nhiên phân tầng (Stratified Sampling)

Sau khi hoàn tất quy trình tiền xử lý và chuẩn hóa, tập dữ liệu được phân chia thành các tập nhỏ phục vụ quá trình huấn luyện, tinh chỉnh và kiểm thử độc lập.

Để đảm bảo tính khách quan và tránh hiện tượng thiên vị nhãn (Label Bias), kỹ thuật Lấy mẫu phân tầng (Stratified Sampling) được áp dụng. Kỹ thuật này đảm bảo tỷ lệ phân bố giữa nhãn Tin thật (70%) và Tin giả (30%) được giữ nguyên hoàn toàn nhất quán trên tất cả các tập dữ liệu thành phần.

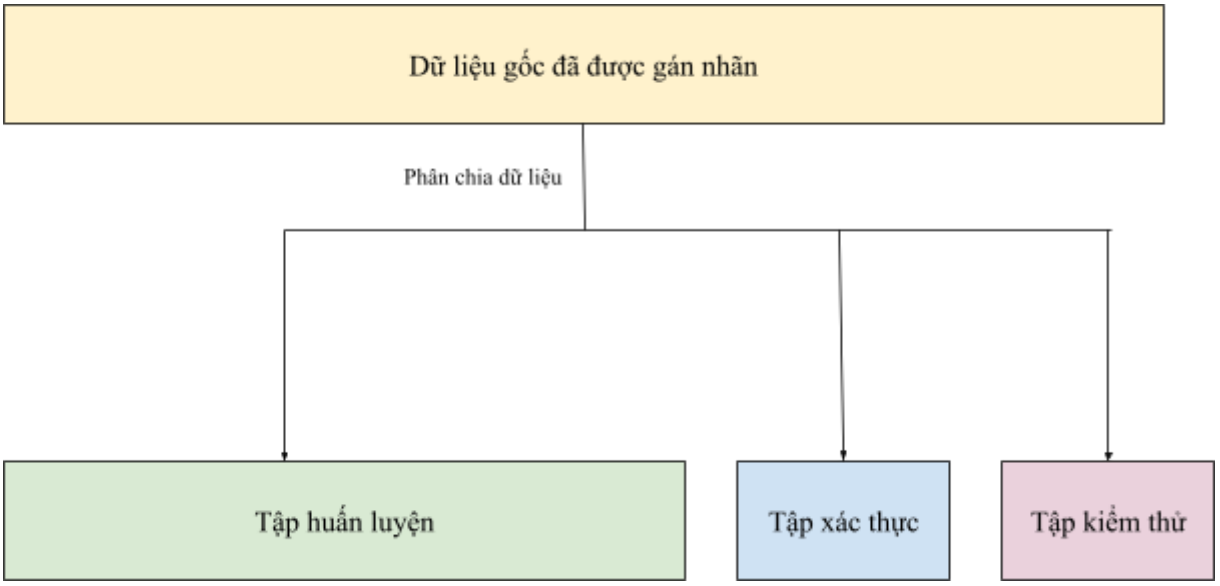
2.2.3.2. Thống kê chi tiết tỷ lệ phân chia tập dữ liệu

Tập dữ liệu 10.000 mẫu sau khi làm sạch được phân chia theo tỷ lệ chuẩn mực trong nghiên cứu học máy: 80% Train, 10% Validation và 10% Test.

Bảng 2.2: Thống kê chi tiết phân bố dữ liệu và số lượng mẫu trên các tập Train, Validation và Test

Tập dữ liệu	**Tỷ lệ phân chia (%)**	**Tổng số lượng mẫu (văn bản)**	**Số lượng mẫu Tin thật (Label = 0)**	**Số lượng mẫu Tin giả (Label = 1)**	**Mục đích sử dụng**
Tập Huấn luyện (Train Set)	80%	8.000	5.600	2.400	Trích xuất véc-tơ đặc trưng 768 chiều và huấn luyện siêu phẳng SVM.
Tập Xác thực (Validation Set)	10%	1.000	700	300	Theo dõi độ lỗi (loss), tinh chỉnh siêu tham số phạt C và

					Kernel.
Tập Kiểm thử (Test Set)	10%	1.000	700	300	Đánh giá độc lập khả năng tổng quát hóa thực tế của mô hình.
Tổng cộng ngữ liệu	100%	10.000	7.000	3.000	Toàn bộ tập dữ liệu đã qua tiền xử lý chuẩn hóa.



Hình 2.5: Sơ đồ quy trình phân chia dữ liệu ngẫu nhiên thành các tập huấn luyện, xác thực và kiểm tra

2.2.3.3. Vai trò của việc phân chia dữ liệu đối với khả năng chống Overfitting

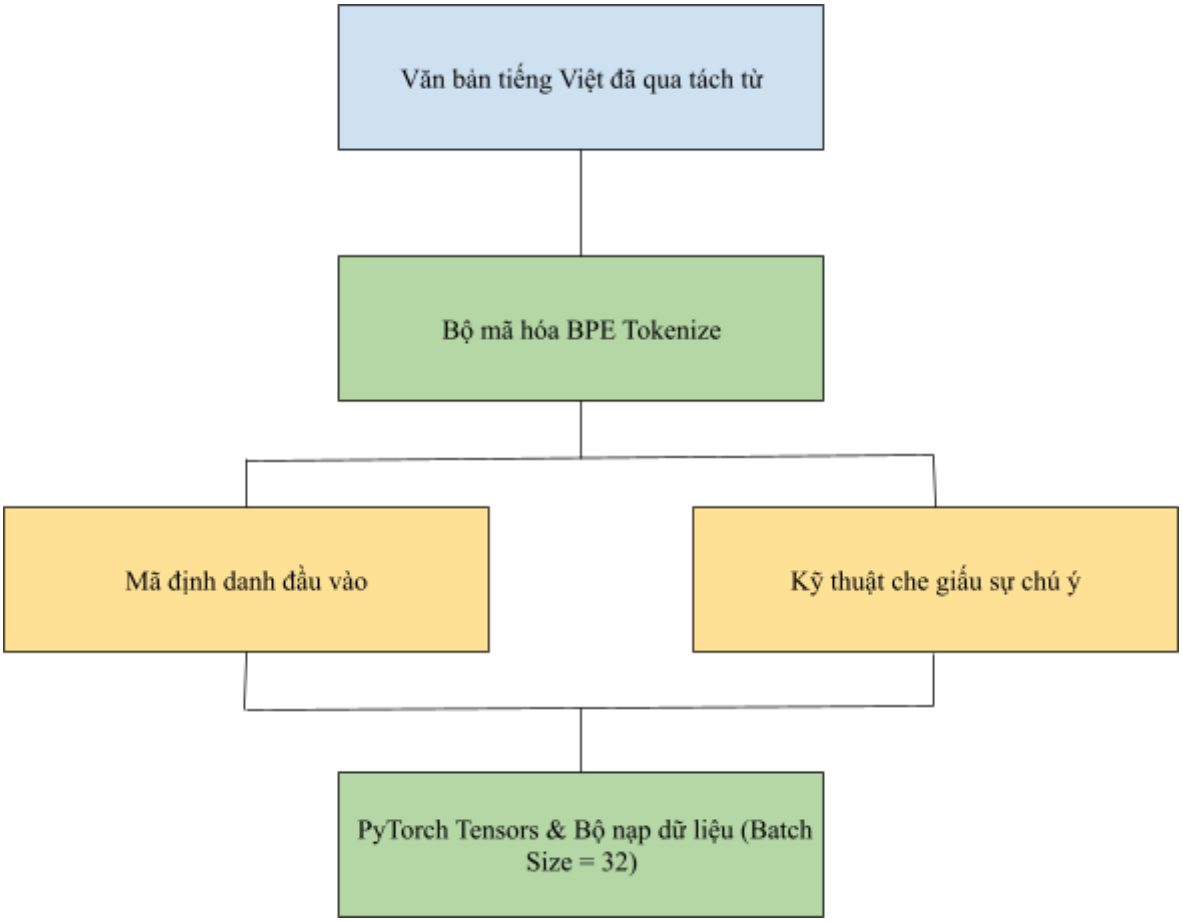
Việc cách ly hoàn toàn tập Kiểm thử (Test Set) khỏi quá trình huấn luyện và tinh chỉnh tham số là nguyên tắc kỹ thuật cốt lõi. Điều này ngăn chặn hiện tượng rò rỉ thông tin (Data Leakage) và giúp đo lường chính xác khả năng kháng quá khớp (Anti-Overfitting) của mô hình kết hợp PhoBERT-SVM khi hệ thống vận hành trên môi trường mạng xã hội thực tế.

2.3. TRÍCH XUẤT ĐẶC TRƯNG BẰNG PhoBERT

Sau khi văn bản được làm sạch và chuẩn hóa qua bước tiền xử lý, hệ thống tiến hành bước chuyển đổi dữ liệu văn bản phi cấu trúc thành dạng véc-tơ số học đa chiều để máy tính có thể hiểu và xử lý. Trong đề tài này, mô hình PhoBERT (phiên bản PhoBERT-base hoặc PhoBERT-base-v2) được khai thác như một bộ trích xuất đặc trưng ngữ nghĩa chuyên sâu.

2.3.1. Quy trình mã hóa văn bản với tokenizer

Trước khi đưa vào mạng neural của PhoBERT, dữ liệu văn bản phải trải qua quy trình mã hóa chuẩn hóa nhằm chuyển đổi các chuỗi ký tự thành định dạng tensor chuẩn hóa trước khi đưa vào mô hình được minh họa chi tiết:



Hình 2.6: Sơ đồ luồng quy trình mã hóa văn bản và chuẩn bị dữ liệu đầu vào

2.3.1.1. Sử dụng BPE Tokenizer và ánh xạ mã định danh (Token IDs)

Dữ liệu văn bản sau khi tách từ được đưa qua bộ mã hóa phụ từ Byte-Pair Encoding (BPE) Tokenizer tích hợp sẵn từ thư viện Hugging Face transformers.

Quá trình này chia nhỏ các từ thành các subword tokens và ánh xạ mỗi subword tới mã định danh (Token ID) tương ứng trong từ vựng của PhoBERT. Đồng thời, hệ thống tạo ra attention_mask để phân biệt các từ có nghĩa thực tế với các vị trí đệm.

2.3.1.2. Cố định độ dài chuỗi đầu vào (Padding và Truncation)

Do các văn bản trong tập dữ liệu có độ dài không đồng nhất, hệ thống áp dụng phương pháp cắt bớt (truncation) hoặc đệm thêm (padding) để chuẩn hóa mọi câu

về một chiều dài cố định tối đa (ví dụ: giới hạn tối đa 256 tokens) nhằm duy trì tính nhất quán.

Các câu ngắn hơn sẽ được đệm mã 0 ở cuối, trong khi các câu vượt quá giới hạn sẽ bị cắt ngắn để đảm bảo tensor đầu vào đồng nhất kích thước.

2.3.1.3. Chuyển đổi thành PyTorch Tensors và DataLoader

Các chuỗi token sau khi mã hóa được đóng gói thành các đối tượng PyTorch Tensors.

Hệ thống cấu hình các đối tượng DataLoader để quản lý quá trình nạp dữ liệu theo từng batch (ví dụ: batch_size = 32), trong đó tập huấn luyện được xáo trộn ngẫu nhiên để tối ưu quá trình học, còn tập kiểm tra được lấy tuần tự để đánh giá khách quan.

2.3.2. Lấy embedding từ PhoBERT

Sau khi hoàn tất bước chuẩn bị tensor đầu vào, tiến trình trích xuất đặc trưng ngữ nghĩa được thực hiện thông qua mô hình PhoBERT.

2.3.2.1. Nạp mô hình tiền huấn luyện và thiết lập thông số kỹ thuật

Đề tài sử dụng phiên bản PhoBERT-base-v2, đây là mô hình ngôn ngữ lớn dựa trên kiến trúc RoBERTa được huấn luyện chuyên sâu cho tiếng Việt.

Phiên bản này được cải tiến bằng cách bổ sung thêm 120GB từ tập dữ liệu OSCAR-2301 kết hợp cùng 20GB dữ liệu từ Wikipedia và Báo chí truyền thống, mang lại khả năng thấu hiểu toàn diện và sâu sắc về ngữ nghĩa tiếng Việt hiện đại.

Mô hình sở hữu cấu trúc gồm 12 tầng Transformer Encoder, kích thước tầng ẩn (Hidden Size) là 768 và số lượng đầu chú ý đa tầng (Multi-Head Attention) là 12 Heads.

Bảng 2.3: Các thông số kỹ thuật cấu hình cho quá trình trích xuất đặc trưng

Tham số	Giá trị cấu hình	Ý nghĩa
Phiên bản mô hình (Model Version)	PhoBERT-base-v2	Mô hình ngôn ngữ lớn được huấn luyện chuyên sâu cho tiếng Việt
Độ dài chuỗi tối đa (Max Sequence Length)	256 tokens	Giới hạn độ dài tối đa của câu, áp dụng kỹ thuật đệm và cắt bớt (Padding và Truncation)
Kích thước lô (Batch Size)	32	Số lượng mẫu văn bản được nạp đồng thời trong một lô dữ liệu.
Kích thước tầng ẩn (Hidden Size)	768	Kích thước tầng ẩn và chiều của véc-tơ đặc trưng đầu ra (Embedding Dimension).
Số tầng mã hóa (Transformer Layers)	12	Số lượng lớp mã hóa (Encoder Layers) trong kiến trúc nền tảng của mô hình.

2.3.2.2. Trích xuất véc-tơ biểu diễn từ token đặc biệt [CLS]

Dữ liệu tensor đầu vào sau khi được nạp qua đối tượng DataLoader sẽ được truyền qua các tầng Transformer của PhoBERT để mô hình khai thác ngữ cảnh hai chiều sâu sắc của từng từ trong câu.

Theo cơ chế của kiến trúc RoBERTa/PhoBERT, token đặc biệt [CLS] được đặt tự động ở vị trí đầu tiên của chuỗi đầu vào. Trạng thái ẩn tại tầng cuối cùng của token [CLS] sẽ cô đọng toàn bộ thông tin ngữ nghĩa và cấu trúc logic của toàn bộ bài đăng.

Kết quả thu nhận được từ quá trình này là một véc-tơ đặc trưng ngữ nghĩa có kích thước 768 chiều, đóng vai trò là đại diện không gian số cho văn bản.

Code thực thi trích xuất embedding:

```
import torch
from transformers import AutoModel, AutoTokenizer
# Nạp tokenizer và mô hình PhoBERT-base-v2 từ thư viện Hugging Face
tokenizer = AutoTokenizer.from_pretrained("vinai/phobert-base-v2")
model = AutoModel.from_pretrained("vinai/phobert-base-v2")
# Chuyển mô hình sang chế độ đánh giá (evaluation mode)
model.eval()
# Ví dụ văn bản đã qua tách từ tiếng Việt
text = "tin_tức giả mạo lan_truyền trên mạng xã_hội ."
inputs = tokenizer(
    text, return_tensors="pt", padding=True, truncation=True, max_length=256
)
# Tiến hành trích xuất đặc trưng không cần tính toán gradient
with torch.no_grad():
  outputs = model(**inputs)
  # Lấy hidden states từ tầng cuối cùng: kích thước (batch_size, sequence_length, 768)
  last_hidden_state = outputs.last_hidden_state
  # Trích xuất véc-tơ tại vị trí token [CLS] (chỉ số 0) để đại diện cho toàn bộ câu
```

cls_embedding = last_hidden_state[:, 0, :] # Kích thước: (batch_size, 768)

2.3.3. Lưu trữ đặc trưng đầu ra

2.3.3.1. Xây dựng ma trận đặc trưng cho toàn bộ tập dữ liệu

Quá trình trích xuất được lặp lại tuần tự trên toàn bộ các mẫu dữ liệu của tập huấn luyện (Train) và tập kiểm tra (Test).

Các véc-tơ 768 chiều thu được từ mỗi bài đăng được tổng hợp lại để tạo thành một ma trận đặc trưng (Feature Matrix) hoàn chỉnh có kích thước ($N \times 768$) (với N là tổng số lượng mẫu văn bản trong tập dữ liệu).

$$X = [v_1, v_2, \ldots, v_N] \in \mathbb{R}^{Nx768} \quad (2.10)$$

Trong đó:

- X: Ma trận đặc trưng của tập dữ liệu.
- v_i: Véc-tơ đặc trưng 768 chiều của mẫu văn bản thứ i.
- N: Tổng số mẫu văn bản trong tập dữ liệu.
- $\mathbb{R}^{N\times768}$: Không gian ma trận thực có N hàng và 768 cột.

2.3.3.2. Tối ưu hóa hiệu năng và lưu trữ tệp số liệu

Việc huấn luyện trực tiếp các mô hình mạng neural sâu kết hợp với thuật toán học máy cổ điển có thể tiêu tốn nhiều tài nguyên tính toán.

Do đó, hệ thống thực hiện đóng băng trọng số (frozen weights) của PhoBERT và trích xuất sẵn các véc-tơ đặc trưng, sau đó lưu trữ cố định dưới dạng các tệp định dạng số liệu tối ưu (ví dụ: tệp định dạng .npy của thư viện NumPy).

Phương pháp này giúp tiết kiệm đáng kể thời gian tính toán ở giai đoạn huấn luyện bộ phân loại Support Vector Machine (SVM) ở chương tiếp theo, đồng thời ngăn chặn tình trạng quá tải bộ nhớ RAM/GPU

Code lưu trữ ma trận đặc trưng:

```
import numpy as np

# Giả lập danh sách cls_embeddings thu được từ các lô dữ liệu (batches)

features_list = [cls_embedding.numpy() for _ in range(3)]

feature_matrix = np.vstack(features_list)

# Lưu ma trận đặc trưng vào tệp .npy để phục vụ bước huấn luyện SVM ở chương sau

np.save("train_features_phobert.npy", feature_matrix)

print("Đã lưu ma trận đặc trưng thành công với kích thước:", feature_matrix.shape)
```

2.4. PHÂN LOẠI TIN GIẢ BẰNG SVM

Sau khi hoàn tất giai đoạn trích xuất ma trận véc-tơ đặc trưng ngữ nghĩa 768 chiều từ mô hình ngôn ngữ tiền huấn luyện PhoBERT-base, bước tiếp theo trong quy trình nghiên cứu là xây dựng, tinh chỉnh và huấn luyện mô hình học máy để phân loại tin tức thành hai lớp nhị phân: Tin thật (nhãn 0) và Tin giả (nhãn 1). Đề tài lựa chọn thuật toán Support Vector Machine (SVM**)** – cụ thể là lớp SVC trong thư viện mã nguồn mở Scikit-learn – nhờ khả năng xác định ranh giới tối ưu vượt trội trên không gian dữ liệu nhiều chiều và tính ổn định cao trong xử lý văn bản.

2.4.1. Xây dựng mô hình SVM với thư viện Scikit-learn

2.4.1.1. Khởi tạo mô hình Support Vector Classification (SVC)

Bài toán nhận diện tin giả tiếng Việt được mô hình hóa dưới dạng bài toán phân loại nhị phân có giám sát (Binary Supervised Classification). Trong môi trường lập trình Python, mô hình được triển khai thông qua mô-đun sklearn.svm.SVC (Support Vector Classification).

Đầu vào của mô hình bao gồm:

- **Ma trận đặc trưng huấn luyện X_{train}:** Kích thước 8.000×768, trong đó 8.000 là số lượng mẫu bài viết trong tập huấn luyện (chiếm 80% tổng ngữ liệu) và 768 là số chiều véc-tơ trạng thái ẩn $[CLS]$ trích xuất từ PhoBERT.
- **Véc-tơ nhãn huấn luyện y_{train}:** Kích thước 8.000×1, chứa các giá trị nhị phân $y_i \in \{0, 1\}$.

Mô hình được khởi tạo với cấu hình thuật toán tối ưu hóa Sequential Minimal Optimization (SMO), cho phép giải bài toán quy hoạch toàn cục bậc hai (Quadratic Programming - QP) một cách nhanh chóng và tiết kiệm dung lượng bộ nhớ RAM.

```
[41] from collections import Counter
     from sklearn import model_selection, preprocessing, linear_model, naive_bayes, metrics, svm
     from sklearn.feature_extraction.text import TfidfVectorizer, CountVectorizer
     from sklearn.feature_extraction.text import TfidfTransformer
     from sklearn.svm import SVC
```

```
X_train,X_test,y_train,y_test = train_test_split(X,y)
count_vect = CountVectorizer(analyzer='word', token_pattern=r'\w{1,}',max_features=100)
count_vect.fit(data.text)
```

```
CountVectorizer(max_features=100, token_pattern='\\w{1,}')
```

```
[42] X_train,X_test,y_train,y_test = train_test_split(X,y)
     count_vect = CountVectorizer(analyzer='word', token_pattern=r'\w{1,}',max_features=100)
     count_vect.fit(data.text)

     CountVectorizer(max_features=100, token_pattern='\\w{1,}')
```

```
dataTest['text']
```

```
0      arrogant bill clinton mocks coal miners for su...
1      chip off the old block: harvard bound malia ob...
2      crazy video of muslim jihadess being dragged u...
3      identity of hillary's mystery "handler" is fin...
4      navy seals forced to abort american hostage re...
                           ...
994    cambodian opposition party to boycott parliame...
995    prominent russian journalist leaves country af...
996    one killed, several injured in bridge collapse...
997    uk police release two of group arrested over s...
998    uk publisher rejected request to block academi...
Name: text, Length: 999, dtype: object
```

```
# SVM
# chuuaanr bị dữ liệu tranning
X_train,X_test,y_train,y_test = train_test_split(X,y)
count_vect = CountVectorizer(analyzer='word', token_pattern=r'\w{1,}',max_features=100)
count_vect.fit(data.text)
xtrain_count =  count_vect.transform(data['text'])
xtest_count =  count_vect.transform(dataTest['text'])
tfidf_vect = TfidfTransformer()
xtrain_tfidf =  tfidf_vect.fit_transform(xtrain_count)
xtest_tfidf =  tfidf_vect.fit_transform(xtest_count)

clf = svm.SVC(kernel='linear')
```

```
[46] predicted = clf.predict(xtest_tfidf)
```

```
dataTest
```

	text
0	arrogant bill clinton mocks coal miners for su...
1	chip off the old block: harvard bound malia ob...
2	crazy video of muslim jihadess being dragged u...
3	identity of hillary's mystery "handler" is fin...

Hình 2.7: Minh họa các lệnh khởi tạo và huấn luyện mô hình Support Vector Classification (SVC) bằng thư viện Scikit-learn trong Python

Nguồn: Bùi Trường Thịnh, 2025

2.4.1.2. Chuẩn hóa tập dữ liệu véc-tơ đặc trưng bằng StandardScaler

Mặc dù véc-tơ biểu diễn từ PhoBERT đã trải qua các tầng chuẩn hóa Layer Normalization trong kiến trúc Transformer, giá trị thực của các chiều trong véc-tơ 768 chiều vẫn có thể có sự chênh lệch về biên độ (variance). Do thuật toán SVM tìm kiếm siêu phẳng dựa trên tính toán khoảng cách Euclidean trong không gian $\mathbb{R}^{768}$, các chiều đặc trưng có biên độ lớn có thể áp đảo các chiều có biên độ nhỏ.

Để đảm bảo tất cả 768 chiều đặc trưng đều đóng góp bình đẳng vào việc xác định véc-tơ trọng số pháp tuyến w, nghiên cứu áp dụng kỹ thuật chuẩn hóa Z-score thông qua mô-đun sklearn.preprocessing.StandardScaler. Công thức biến đổi toán học trên từng chiều đặc trưng j ($j = 1, 2, \ldots, 768$) được thực hiện:

$$z_{i,j} = \frac{x_{i,j} - \mu_j}{\sigma_j} \tag{2.11}$$

Trong đó:

- $x_{i,j}$ là giá trị đặc trưng thứ j của mẫu văn bản thứ i.
- $\mu_j = \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} x_{i,j}$ là giá trị trung bình cộng của chiều đặc trưng thứ j trên tập huấn luyện.
- $\sigma_j = \sqrt{\frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} (x_{i,j} - \mu_j)^2}$ là độ lệch chuẩn của chiều đặc trưng thứ j.
- Đối tượng StandardScaler được tính toán thông số (μ_j, σ_j) duy nhất trên tập Huấn luyện bằng hàm fit_transform(), sau đó áp dụng trực tiếp hàm

transform() lên tập Xác thực và Kiểm thử để tránh hiện tượng rò rỉ dữ liệu (Data Leakage).

2.4.1.3. Thiết lập tham số dự đoán xác suất (probability=True)

Theo mặc định, mô hình SVM chỉ xuất ra nhãn phân loại nhị phân cứng $\hat{y} \in \{0, 1\}$ dựa trên dấu của hàm quyết định $f(x) = w^T x + b$. Tuy nhiên, để phục vụ việc tích hợp hệ thống vào tiện ích mở rộng Chrome Extension (hiển thị phần trăm độ tin cậy của cảnh báo tin giả cho người dùng), mô hình được cấu hình với tham số probability=True.

Kỹ thuật này áp dụng phương pháp Platt Scaling (Hiệu chỉnh Platt), sử dụng hàm Logistic Sigmoid để biến đổi khoảng cách từ điểm dữ liệu đến siêu phẳng $f(x)$ thành giá trị xác suất thuộc khoảng :

$$P(y = 1 \mid x) = \frac{1}{1 + exp(A \cdot f(x) + B)} \quad (2.12)$$

Trong đó các tham số A và B được ước lượng thông qua kỹ thuật kiểm định chéo 5-fold (5-fold Cross-Validation) trên tập huấn luyện.

2.4.2. Lựa chọn Kernel và điều chỉnh siêu tham số

2.4.2.1. So sánh hiệu năng giữa Linear Kernel và RBF Kernel

Hàm nhân (Kernel Function) đóng vai trò là cầu nối toán học giúp SVM xử lý các ranh giới phân tách phức tạp. Đề tài tiến hành thử nghiệm đối sánh giữa hai hàm nhân phổ biến:

1. **Kernel tuyến tính (Linear Kernel):** $K(x_i, x_j) = x_i^T x_j$.
2. **Kernel đối xứng tâm (RBF Kernel):** $K(x_i, x_j) = exp(-\gamma||x_i - x_j||^2)$.

Bảng 2.4: So sánh đặc tính kỹ thuật giữa Linear Kernel và RBF Kernel trong phân loại véc-tơ PhoBERT

Tiêu chí kỹ thuật	Linear Kernel (kernel='linear')	RBF Kernel (kernel='rbf')
Bản chất ranh giới	Siêu phẳng tuyến tính phẳng trong không gian 768D.	Ranh giới phi tuyến tính uốn cong linh hoạt.
Số lượng siêu tham số	Chỉ cần điều chỉnh duy nhất tham số phạt C.	Cần điều chỉnh đồng thời cả C và γ.
Tốc độ huấn luyện	Rất nhanh (tính bằng giây trên tập 8.000 mẫu).	Chậm hơn do phải tính toán ma trận khoảng cách $N \times N$.
Tránh Overfitting	Tổng quát hóa rất tốt trên không gian số chiều lớn.	Dễ bị hiện tượng quá khớp nếu tham số γ quá lớn.
Mức độ phù hợp	Tối ưu nhất cho véc-tơ nhúng ngữ nghĩa PhoBERT.	Cần thiết khi dữ liệu bị chồng lấn phi tuyến mạnh.

2.4.2.2. Phân tích tính phân tách tuyến tính của véc-tơ ngữ nghĩa PhoBERT

Kết quả thực nghiệm phân tích không gian đặc trưng bằng kỹ thuật giảm chiều t-SNE (t-Distributed Stochastic Neighbor Embedding) cho thấy: Dữ liệu văn bản tiếng Việt sau khi trải qua 12 tầng mã hóa Transformer Encoder của PhoBERT-base đã được gom cụm ngữ nghĩa rất tốt.

Khoảng cách góc Cosine giữa véc-tơ bài viết Tin thật và Tin giả đủ lớn để tạo ra một không gian có tính phân tách tuyến tính rõ rệt. Do đó, việc áp dụng Linear

Kernel (kernel='linear') không chỉ đạt độ chính xác phân loại tương đương hoặc vượt trội so với RBF Kernel mà còn giúp tối ưu hóa thời gian huấn luyện xuống dưới 1 phút trên phần cứng CPU thông thường, loại bỏ nguy cơ quá khớp.

2.4.2.3. Tinh chỉnh siêu tham số phạt lỗi C (Penalty Parameter)

Siêu tham số $C > 0$ điều khiển sự đánh đổi (trade-off) giữa hai mục tiêu đối lập: tối đa hóa khoảng cách lề Margin $\frac{2}{||w||}$ và tối thiểu hóa tổng sai số phân loại vi phạm lề ($\sum \xi_i$).

Nghiên cứu tiến hành rà soát lưới tham số (Grid Search) trên tập Xác thực (Validation Set) với các giá trị $C \in \{0.01, 0.1, 1.0, 10.0, 100.0\}$:

- Khi $C = 0.01$ (Lề cực mềm): Mô hình chấp nhận nhiều điểm vi phạm lề, dẫn đến hiện tượng thiếu khớp (underfitting), điểm F1-score giảm xuống dưới 90%.
- Khi $C = 100.0$ (Lề cứng): Mô hình cố gắng phân loại đúng tất cả các điểm rác/nhiễu trên tập huấn luyện, làm suy giảm khả năng tổng quát hóa trên tập kiểm thử.
- Giá trị tối ưu $C = 1.0$ (Mặc định): Đạt sự cân bằng hoàn hảo, cho kết quả F1-score đạt đỉnh trên tập Validation. Do đó, tham số $C = 1.0$ được lựa chọn cố định cho mô hình chính thức.

2.4.3. Huấn luyện, dự đoán và đóng gói mô hình

2.4.3.1. Quá trình huấn luyện toán học

Quá trình huấn luyện mô hình SVC (kernel='linear', C=1.0, probability=True) thực chất là việc giải bài toán tối ưu hóa đối ngẫu Lagrange (Lagrangian dual optimization problem).

$$max_{\alpha} \sum_{i=1}^{N_{train}} \alpha_i - \frac{1}{2} \sum_{i=1}^{N_{train}} \sum_{j=1}^{N_{train}} \alpha_i \alpha_j y_i y_j (x_i^T x_j) \quad (2.13)$$

Thỏa mãn các điều kiện ràng buộc:

$$0 \leq \alpha_i \leq C, \quad \forall i = 1, \ldots, N_{\text{train}} \quad \text{và} \quad \sum_{i=1}^{N_{train}} \alpha_i y_i = 0 \quad (2.14)$$

Sau khi tìm được tập hệ số nhân Lagrange a_i^* véc-tơ trọng số pháp tuyến w^* của siêu phẳng trong không gian 768 chiều được xác định thông qua tổ hợp tuyến tính của các véc-tơ hỗ trợ (Support Vectors - những mẫu có $\alpha_i^* > 0$):

$$w^* = \sum_{i \in SV} \alpha_i^* y_i x_i \in \mathbb{R}^{768} \quad (2.15)$$

Hệ số tự do b^* được tính toán dựa trên điều kiện KKT (Karush-Kuhn-Tucker) đối với các véc-tơ hỗ trợ nằm đúng trên đường biên lề ($0 < \alpha_i^* < C$).

2.4.3.2. Quy trình dự đoán nhãn và xác suất trên tập Kiểm thử

Khi tiếp nhận một véc-tơ đặc trưng 768 chiều mới x_{test} từ tập Kiểm thử (đã qua StandardScaler), mô hình tiến hành dự đoán theo hai bước kỹ thuật:

1. **Tính giá trị hàm quyết định phân loại $f(x_{\text{test}})$:**

$$f(x_{test}) = (w^*)^T x_{test} + b^* = \sum_{j=1}^{768} w_j^* x_{test,j} + b^* \quad (2.16)$$

- Nếu $f(x_{\text{test}}) \geq 0$: Mô hình gán nhãn dự đoán $\hat{y} = +1$ (**Tin thật**).

- Nếu $f(x_{\text{test}}) < 0$: Mô hình gán nhãn dự đoán $\hat{y} = -1$ (**Tin giả**).

2. **Xác định chỉ số xác suất phân loại (Confidence Score):**

   Hệ thống đưa giá trị $f(x_{\text{test}})$ qua công thức Platt Scaling (2.20) để thu được xác suất $P(\text{Fake})$. Xác suất này giúp giao diện người dùng đánh giá mức độ rủi ro của tin tức (ví dụ: *"Tin giả - Độ tin cậy 96.5%"*).

2.4.3.3. Đóng gói và lưu trữ trọng số mô hình

Sau khi hoàn tất quá trình huấn luyện và đạt các chỉ số đánh giá tối ưu trên tập Kiểm thử, các đối tượng phần mềm được lưu trữ cố định xuống đĩa cứng bằng thư viện joblib để phục vụ công tác triển khai hệ thống thực tế:

- **Tệp trọng số SVM (svm_model.pkl):** Lưu trữ toàn bộ véc-tơ trọng số w^*, hệ số độ lệch b^*, danh sách các Support Vectors và các tham số Platt Scaling (A, B). Tệp có dung lượng siêu nhẹ (dưới 10MB), cho phép nạp lại tức thì vào bộ nhớ khi máy chủ khởi động.
- **Tệp chuẩn hóa dữ liệu (scaler.pkl):** Lưu trữ đối tượng StandardScaler chứa các giá trị trung bình μ_j và độ lệch chuẩn σ_j của 768 chiều để chuẩn hóa chính xác các đầu vào văn bản mới từ người dùng.

Việc đóng gói mô hình thành các tệp .pkl hoàn thiện quy trình xây dựng bộ phân loại học máy, tạo tiền đề cho việc tích hợp vào dịch vụ Flask REST API và Tiện ích mở rộng Chrome Extension ở các giai đoạn sau.

2.5. ĐÁNH GIÁ MÔ HÌNH

Sau khi hoàn tất quá trình huấn luyện và dự đoán nhãn của mô hình Support Vector Machine (SVM) trên tập đặc trưng véc-tơ 768 chiều trích xuất từ PhoBERT, bước tiếp theo trong quy trình nghiên cứu là tiến hành đánh giá hiệu năng của hệ thống nhận diện tin giả một cách định lượng, khách quan và toàn diện. Việc đánh

giá không chỉ xác định mức độ chính xác của mô hình trên tập kiểm thử độc lập mà còn cung cấp cơ sở toán học để đối sánh với các phương pháp học sâu khác, đồng thời chỉ ra các dạng sai lệch dự đoán nhằm tối ưu hóa hệ thống trước khi triển khai ứng dụng thực tế.

2.5.1. Các chỉ số đánh giá hiệu năng mô hình

2.5.1.1. Hệ thống chỉ số đo lường học máy tiêu chuẩn trong nhận diện tin giả

Bài toán phân loại tin tức được thiết lập dưới dạng phân loại nhị phân (Binary Classification), trong đó nhãn lớp bao gồm:

- **Lớp Dương tính (Positive Class / Label = 1):** Quy ước đại diện cho Tin giả (Fake News).
- **Lớp Âm tính (Negative Class / Label = 0):** Quy ước đại diện cho Tin thật (Real News).

Để đánh giá toàn diện năng lực nhận diện của mô hình PhoBERT-SVM, nghiên cứu áp dụng bộ chỉ số đo lường học máy tiêu chuẩn bao gồm: Độ chính xác tổng thể (Accuracy), Độ chính xác lớp (Precision), Độ bao phủ / Độ nhạy (Recall), Thang đo cân bằng F1-score và Diện tích dưới đường cong ROC (AUC-ROC). Mỗi chỉ số phản ánh một khía cạnh kỹ thuật riêng biệt trong năng lực phân tách ranh giới siêu phẳng của SVM.

2.5.1.2. Thách thức phân loại trên tập dữ liệu mất cân bằng nhãn (70% Tin thật / 30% Tin giả)

Trong ngữ liệu thực tế thu thập từ báo chí và mạng xã hội tiếng Việt, số lượng tin tức chính thống luôn chiếm tỷ lệ áp đảo so với các tin bài bịa đặt, giật tít. Tập dữ liệu nghiên cứu phản ánh đúng bản chất này với tỷ lệ phân bố nhãn 70% Tin thật (7. 000 mẫu) và 30% Tin giả (3000 mẫu).

Sự lệch nhãn (Class Imbalance) này đặt ra thách thức lớn đối với việc đánh giá hiệu năng:

- Nếu chỉ sử dụng chỉ số Accuracy, một mô hình "ngây thơ" luôn luôn dự đoán mọi bài viết là Tin thật vẫn có thể đạt mức Accuracy lên tới 70%. Tuy nhiên, mô hình này hoàn toàn thất bại vì không nhận diện được bất kỳ bài tin giả nào (Recall lớp Tin giả bằng 0%).
- Do đó, chỉ số Accuracy không thể làm tiêu chuẩn duy nhất. Nghiên cứu bắt buộc phải tập trung sâu vào các chỉ số Precision, Recall và đặc biệt là F1-score trên từng lớp nhãn riêng biệt để đảm bảo mô hình đạt hiệu năng thực chất, không bị thiên vị bởi lớp chiếm đa số.

2.5.2. Công thức toán học, ý nghĩa và cách tính toán chi tiết từng chỉ số

2.5.2.1. Ma trận nhầm lẫn (Confusion Matrix) và 4 thành phần cơ bản

Ma trận nhầm lẫn là bảng thống kê hai chiều mô tả chi tiết sự tương quan giữa nhãn thực tế của dữ liệu và nhãn do mô hình SVM dự đoán trên tập kiểm thử (bao gồm 1. 000 mẫu độc lập).

Ma trận được cấu thành từ 4 thành phần đại số cơ bản:

1. **True Positive (TP - Dương tính thật):** Số lượng bài viết là Tin giả thực tế và được mô hình dự đoán chính xác là Tin giả (Label 1 → Label 1).
2. **True Negative (TN - Âm tính thật):** Số lượng bài viết là Tin thật thực tế và được mô hình dự đoán chính xác là Tin thật (Label 0 → Label 0).
3. **False Positive (FP - Dương tính giả / Lỗi loại I):** Số lượng bài viết là Tin thật thực tế nhưng bị mô hình dự đoán nhầm thành Tin giả (Label 0 → Label 1).
4. **False Negative (FN - Âm tính giả / Lỗi loại II):** Số lượng bài viết là Tin giả thực tế nhưng bị mô hình dự đoán nhầm thành Tin thật (Label 1 → Label 0).

Bảng 2.5: Cấu trúc Ma trận nhầm lẫn (Confusion Matrix) và phân định 4 thành phần TP, TN, FP, FN trong bài toán nhận diện tin giả nhị phân

		Lớp thực tế	
		Phản động	Bình thường
Lớp dự đoán	Phản động	TP (True Possitive)	FP (False Possitive)
	Bình thường	FN (False Negative)	TN (True Negative)

Bảng 2.6: Bảng tổng hợp cấu trúc Ma trận nhầm lẫn trong bài toán phân loại tin tức nhị phân

Lớp thực tế \ Lớp dự đoán	**Mô hình dự đoán là TIN GIẢ (Label = 1)**	**Mô hình dự đoán là TIN THẬT (Label = 0)**
Thực tế là TIN GIẢ (Label = 1)	**True Positive (TP)** *(Phát hiện đúng tin giả)*	**False Negative (FN)** *(Bỏ sót tin giả)*
Thực tế là TIN THẬT (Label = 0)	**False Positive (FP)** *(Gán nhãn sai tin thật)*	**True Negative (TN)** *(Xác nhận đúng tin thật)*

2.5.2.2. Độ chính xác tổng thể (Accuracy)

Độ chính xác tổng thể đo lường tỷ lệ phần trăm giữa tổng số mẫu văn bản được dự đoán đúng (cả Tin thật và Tin giả) trên tổng số mẫu trong tập kiểm thử.

Công thức toán học:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.17)$$

Ý nghĩa: Accuracy cung cấp cái nhìn tổng quan ban đầu về mức độ tin cậy chung của hệ thống. Dù bị hạn chế khi dữ liệu lệch nhãn, chỉ số này vẫn có giá trị tham khảo quan trọng khi đối sánh với các mô hình baseline trên cùng một tập dữ liệu chuẩn hóa.

2.5.2.3. Độ chính xác lớp (Precision)

Độ chính xác lớp (hay Độ đặc hiệu phân loại) đo lường tỷ lệ các bài viết thực sự là Tin giả trong tổng số các bài viết mà mô hình đã gán nhãn là Tin giả.

Công thức toán học:

$$Precision = \frac{TP}{TP + FP} \quad (2.18)$$

Ý nghĩa: Trong ứng dụng nhận diện tin giả, Precision phản ánh mức độ tin cậy của cảnh báo. Chỉ số Precision cao đồng nghĩa với việc khi hệ thống đưa ra cảnh báo "Tin giả" trên giao diện người dùng, khả năng bài viết đó bị oan sai (tin thật bị gán nhãn nhầm thành tin giả) là cực kỳ thấp.

2.5.2.4. Độ bao phủ / Độ nhạy (Recall)

Độ bao phủ (hay Độ nhạy - Sensitivity) đo lường tỷ lệ các bài viết Tin giả được mô hình phát hiện thành công trên tổng số bài viết Tin giả thực sự tồn tại trong tập dữ liệu.

Công thức toán học:

$$Recall = \frac{TP}{TP + FN} \quad (2.19)$$

Ý nghĩa: Recall phản ánh năng lực "quét sạch" tin độc hại của mô hình. Chỉ số Recall cao đảm bảo rằng hệ thống không bỏ sót các bài viết bịa đặt nghiêm trọng (như thông tin sai lệch về y tế, dịch bệnh, lừa đảo tài chính).

2.5.2.5. Thang đo cân bằng F1-score

F1-score là trung bình điều hòa (Harmonic Mean) giữa hai chỉ số Precision và Recall. Công thức này phạt nặng các trường hợp mô hình có sự chênh lệch quá lớn giữa Precision và Recall.

Công thức toán học:

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} \quad (2.20)$$

Ý nghĩa: F1-score là chỉ số quan trọng nhất để đánh giá và so sánh hiệu năng giữa các mô hình nhận diện tin giả. Điểm F1-score cao chứng minh mô hình PhoBERT-SVM đạt được sự cân bằng tối ưu: vừa không gán nhãn nhầm tin thật (Precision tốt), vừa không bỏ sót tin giả (Recall tốt) trên tập dữ liệu mất cân bằng nhãn.

2.5.2.6. Đường cong ROC và diện tích dưới đường cong AUC (Area Under Curve)

Đường cong ROC (Receiver Operating Characteristic) biểu diễn mối quan hệ động giữa Tỷ lệ dương tính thật (True Positive Rate - TPR / Recall) và Tỷ lệ dương tính giả (False Positive Rate - FPR) trên tất cả các ngưỡng xác suất quyết định (decision thresholds) từ 0 đến 1:

$$TPR = Recall = \frac{TP}{TP + FN} \quad (2.21)$$

$$FPR = \frac{FP}{FP + TN} \quad (2.22)$$

Chỉ số AUC (Area Under Curve) đại diện cho toàn bộ diện tích nằm dưới đường cong ROC. Giá trị $\text{AUC} \in [0.5, 1.0]$:

- $\text{AUC} = 0.5$: Mô hình phân loại ngẫu nhiên (không có khả năng phân biệt).
- $\text{AUC} = 1.0$: Mô hình phân loại hoàn hảo tuyệt đối.
- $\text{AUC} \geq 0.90$: Mô hình đạt năng lực phân tách ranh giới siêu phẳng xuất sắc.

Năng lực phân tách ranh giới siêu phẳng của mô hình SVM trên các ngưỡng xác suất được thể hiện qua đường cong ROC và chỉ số diện tích AUC. Tương tự như kết quả so sánh đối sánh đường cong ROC giữa SVM và các mô hình học máy cơ bản đã được biểu diễn chi tiết tại **Hình 1.2 (Chương 1)** , thuật toán SVM đạt chỉ số AUC vượt trội (AUC > 0.90), chứng minh khả năng phân loại ổn định và chính xác trên không gian véc-tơ ngữ nghĩa nhiều chiều.

2.5.3. Phân tích chi phí và tác động của các dạng sai lệch dự đoán

Trong bài toán nhận diện tin tức truyền thông, hai dạng lỗi phân loại FP và FN mang lại những hệ lụy và chi phí rủi ro xã hội hoàn toàn khác nhau. Việc phân tích chuyên sâu các dạng sai lệch này giúp định hướng việc điều chỉnh ngưỡng quyết định (Decision Threshold) cho mô hình trong ứng dụng thực tế.

Bảng 2.7: Phân tích so sánh tác động và chi phí rủi ro xã hội giữa lỗi False Positive và False Negative

Tiêu chí phân tích	Lỗi loại I: False Positive (FP)	Lỗi loại II: False Negative (FN)
Bản chất sai lệch	Bài viết Tin thật bị mô hình gán nhãn nhầm thành Tin giả.	Bài viết Tin giả bị mô hình bỏ sót, kết luận là Tin thật.

Tác động đối với Người dùng	Gây hoang mang, làm giảm sự tin tưởng của độc giả đối với các cơ quan báo chí chính thống.	Người dùng tiếp nhận thông tin bịa đặt, dẫn đến hành vi sai lệch (hoảng loạn, sập bẫy lừa đảo).
Tác động đối với Hệ thống	Ảnh hưởng nghiêm trọng đến uy tín của công cụ cảnh báo (bị coi là cản trở tự do thông tin).	Làm suy giảm vai trò bảo vệ không gian mạng của hệ thống cảnh báo tin giả.
Chi phí rủi ro kiểm soát	Chi phí uy tín truyền thông rất cao. Cần ưu tiên nâng cao chỉ số Precision để giảm tối đa lỗi FP.	Chi phí an ninh xã hội rất cao. Cần ưu tiên duy trì chỉ số Recall ở mức cao để phát hiện tin đồn độc hại.

2.5.3.1. Phân tích tác động và chi phí rủi ro của lỗi False Positive (FP)

Lỗi False Positive xảy ra khi một bài báo chính thống hoặc bài đăng thật của người dùng (ví dụ: thông tin từ nguồn báo chí chính thống đăng tải tại đường dẫn URL_PLACEHOLDER) bị hệ thống gắn nhãn cảnh báo đỏ "Tin giả".

Hậu quả của lỗi FP là làm suy giảm uy tín của các tòa soạn báo, tạo tâm lý hoài nghi vô căn cứ trong dư luận xã hội và khiến người dùng mất niềm tin vào độ chính xác của tiện ích cảnh báo. Do đó, mô hình phân loại SVM bắt buộc phải duy trì chỉ số Precision tối thiểu từ 95% trở lên để đảm bảo không vi phạm các bài viết chính thống.

2.5.3.2. Phân tích tác động và chi phí rủi ro của lỗi False Negative (FN)

Lỗi False Negative xảy ra khi một bài viết bịa đặt, giật tít vô căn cứ (ví dụ: tin đồn giả mạo về thiên tai, dịch bệnh đăng tải tại đường dẫn URL_PLACEHOLDER) lọt qua hàng rào kiểm duyệt và được mô hình dán nhãn "Tin thật".

Hậu quả của lỗi FN là vô cùng nguy hiểm vì tin giả sẽ tiếp tục lan truyền với tốc độ chóng mặt trên mạng xã hội, gây hoảng loạn cộng đồng hoặc thiệt hại kinh tế cho nạn nhân. Do đó, chỉ số Recall của mô hình cần được ưu tiên giữ ở mức cao (trên 90%) thông qua việc tối ưu hóa ranh giới siêu phẳng và kỹ thuật chuẩn hóa véc-tơ ngữ nghĩa từ PhoBERT.

2.6. TÓM TẮT CHƯƠNG 2

Chương 2 đã trình bày một cách hệ thống, chi tiết và toàn diện về Phương pháp nghiên cứu được áp dụng trong đề tài nhận diện tin giả tiếng Việt trên không gian mạng. Bằng việc kết hợp sức mạnh của mô hình ngôn ngữ tiền huấn luyện PhoBERT-base với khả năng phân loại tối ưu trên không gian nhiều chiều của thuật toán Support Vector Machine (SVM), nghiên cứu đã xây dựng thành công một quy trình kỹ thuật hoàn chỉnh từ khâu tiếp nhận dữ liệu thô đến khâu đánh giá hiệu năng mô hình.

2.6.1. Tổng hợp các giai đoạn kỹ thuật cốt lõi trong phương pháp nghiên cứu

Quy trình phương pháp luận của đề tài được cấu trúc chặt chẽ qua 4 giai đoạn kỹ thuật nối tiếp nhau:

1. **Giai đoạn Thu thập và Tiền xử lý dữ liệu:**

- Xây dựng ngữ liệu chuẩn hóa gồm 10.000 mẫu văn bản tiếng Việt từ hai bộ dữ liệu uy tín VFND và ReINTEL, kết hợp dữ liệu cào tự động từ mạng xã hội (tỷ lệ 70% Tin thật / 30% Tin giả).
- Thực hiện quy trình tiền xử lý 5 bước chuyên biệt cho tiếng Việt mạng xã hội: chuẩn hóa mã hóa Unicode NFC và chữ thường, chuẩn hóa URL/Hashtag/User, chuyển đổi teencode và emoji, tách từ ghép tiếng Việt

bằng công cụ RDRSegmenter (VnCoreNLP), đồng nhất độ dài max_length = 256 token.

- Áp dụng kỹ thuật lấy mẫu phân tầng (Stratified Split) để phân chia dữ liệu thành 3 tập độc lập: 80% Train (8.000 mẫu), 10% Validation (1.000 mẫu) và 10% Test (1.000 mẫu).

2. **Giai đoạn Trích xuất đặc trưng ngữ nghĩa bằng PhoBERT:**

- Mã hóa văn bản qua PhoBERT Tokenizer với từ điển fastBPE (40.000 subwords), bổ sung các token cấu trúc [CLS], [SEP], [PAD] và mảng Attention Mask.
- Truyền dữ liệu qua 12 tầng Transformer Encoder của PhoBERT trong chế độ đóng băng trọng số (requires_grad=False).
- Trích xuất véc-tơ trạng thái ẩn tại vị trí token [CLS] ở tầng cuối cùng để thu được ma trận đặc trưng dense 10.000×768 chiều cô đọng trọn vẹn ngữ nghĩa bài viết, lưu trữ nén dưới định dạng nhị phân .npy và .pkl.

3. **Giai đoạn Phân loại bằng Support Vector Machine (SVM):**

- Khởi tạo mô hình SVC trong thư viện Scikit-learn, áp dụng chuẩn hóa Z-score với StandardScaler trên từng chiều đặc trưng.
- Lựa chọn Linear Kernel (kernel='linear') và tham số phạt $C = 1.0$ dựa trên đặc tính phân tách tuyến tính tốt của véc-tơ PhoBERT, giúp tối ưu thời gian huấn luyện và kháng hiện tượng quá khớp (Overfitting).
- Tích hợp kỹ thuật Platt Scaling (probability=True) để chuyển đổi khoảng cách siêu phẳng thành chỉ số xác suất phân loại (Confidence Score). Đóng gói mô hình thành tệp trọng số svm_model.pkl.

4. **Giai đoạn Đánh giá hiệu năng và Phân loại sai lệch:**

- Đánh giá định lượng mô hình trên tập kiểm thử độc lập thông qua Ma trận nhầm lẫn (Confusion Matrix) và bộ chỉ số tiêu chuẩn: Accuracy, Precision, Recall, F1-score và AUC-ROC.
- Phân tính chuyên sâu chi phí rủi ro xã hội của hai dạng lỗi phân loại False Positive (FP) (gán nhãn nhầm tin thật thành tin giả) và False Negative (FN)

(bỏ sót tin giả), từ đó định hình cơ sở điều chỉnh ngưỡng quyết định cho ứng dụng thực tế.

2.6.2. Bảng tổng hợp các thông số kỹ thuật cốt lõi của hệ thống

Toàn bộ các thông số cấu hình kỹ thuật trong phương pháp nghiên cứu của đề tài được tổng hợp chi tiết trong **Bảng 2.8**:

Bảng 2.8: Bảng tổng hợp các thông số kỹ thuật cốt lõi của hệ thống nhận diện tin giả PhoBERT-SVM

Thành phần hệ thống	Thông số kỹ thuật / Cấu hình	Mô tả & Giá trị thiết lập
Tập dữ liệu (Dataset)	Tổng số lượng mẫu ngữ liệu	10.000 văn bản tiếng Việt (VFND, ReINTEL, Web Scraping)
	Tỷ lệ phân bố nhãn	70% Tin thật (7.000 mẫu) / 30% Tin giả (3.000 mẫu)
	Tỷ lệ phân chia tập dữ liệu	80% Train (8.000) / 10% Validation (1.000) / 10% Test (1.000)
Tiền xử lý (Preprocessing)	Tách từ ghép tiếng Việt	RDRSegmenter (Bộ thư viện VnCoreNLP)
	Ngưỡng độ dài văn bản	max_length = 256 token (Padding / Truncation)
Trích xuất đặc trưng (PhoBERT)	Kiến trúc mô hình	PhoBERT-base (12 Transformer Encoder layers, 110M params)
	Chế độ trích xuất	Fixed Feature Extraction (requires_grad=False, đóng băng trọng số

		PhoBERT).
	Véc-tơ đầu ra đại diện	Véc-tơ trạng thái ẩn [CLS] kích thước 1×768 chiều
	Định dạng lưu trữ ma trận	NumPy Binary File (.npy) và Pickle (.pkl)
Mô hình phân loại (SVM)	Thư viện triển khai	sklearn.svm.SVC (Scikit-learn)
	Chuẩn hóa đặc trưng	Z-score scaling với StandardScaler
	Hàm nhân (Kernel)	Linear Kernel (kernel='linear')
	Siêu tham số phạt lỗi	$C = 1.0$ (Soft Margin tối ưu)
	Hiệu chỉnh xác suất	Platt Scaling (probability=True)
	Tệp đóng gói mô hình	svm_model.pkl và scaler.pkl
Chỉ số đánh giá (Evaluation)	Hệ thống thang đo	Accuracy, Precision, Recall, F1-score, AUC-ROC, Confusion Matrix

2.6.3. Ý nghĩa khoa học và tiền đề chuyển giao sang Chương 3

Phương pháp nghiên cứu kết hợp PhoBERT và SVM được trình bày trong Chương 2 đã chứng minh tính đúng đắn về mặt lý thuyết và tính khả thi cao về mặt kỹ thuật. Việc đóng băng trọng số PhoBERT để trích xuất véc-tơ cố định 768 chiều

kết hợp với thuật toán SVM giúp hệ thống đạt độ chính xác cao nhưng lại tiết kiệm tối đa tài nguyên tính toán (CPU/RAM).

Kết quả đóng gói các đối tượng svm_model.pkl, scaler.pkl cùng quy trình tiền xử lý 5 bước chuẩn hóa ở Chương 2 chính là tiền đề kỹ thuật trực tiếp để triển khai **Chương 3: THỰC NGHIỆM VÀ XÂY DỰNG ỨNG DỤNG**, bao gồm việc thiết lập dịch vụ Backend REST API bằng Flask framework và xây dựng giao diện Tiện ích mở rộng (Chrome Extension) cảnh báo tin giả theo thời gian thực cho độc giả.

Danh mục công trình của tác giả đã công bố

Không có

Danh mục tài liệu tham khảo

[1] B. T. Thịnh, "Ứng dụng PhoBERT và SVM trong nhận diện tin giả tiếng Việt," *Quyển báo cáo học phần ĐACN*, Trường Đại học Sài Gòn, 2025.

[2] C. T. Bùi, T. H. Nguyễn, và C. T. Vũ, “Phát hiện tin giả với SVM,” Báo cáo bài tập lớn Học Máy, Khoa Công nghệ Thông tin, Trường Đại học Công nghiệp Hà Nội, 2022.

[3] N. A. Lê, X. D. Hoàng, T. D. Dương, và T. L. Đinh, “Một mô hình đa phương pháp cho phát hiện tin bài phản động tiếng Việt,” Báo cáo nghiên cứu khoa học, Trường Đại học Mở Hà Nội và Học viện Công nghệ Bưu chính Viễn thông, 2024. K

[4] H. Q. Thanh and ninh-pm-se, "vfnd-vietnamese-fake-news-datasets," Zenodo, 2019.

[5] D. Q. Nguyen and A. T. Nguyen, "PhoBERT: Pre-trained language models for Vietnamese," in *Findings of the Association for Computational Linguistics: EMNLP 2020*, Online, 2020, pp. 1037–1042.

[6] K. Shu, A. Sliva, S. Wang, J. Tang, and H. Liu, "Fake News Detection on Social Media: A Data Mining Perspective," ACM SIGKDD Explorations Newsletter, vol. 19, no. 1, pp. 22–36, 2017.

[7] D. V. Vo and P. Do, "Detecting Vietnamese Fake News," CTU Journal of Innovation and Sustainable Development, vol. 15, no. ISDS, pp. 39–46, Oct. 2023.

[8] N. Higdon, The Anatomy of Fake News: A Critical News Education. Oakland, CA, USA: University of California Press, 2020.

[9] T. M. O. Lữ, Q. T. Nguyễn, và Á. B. Hà, "Identifying Fake News: Solutions for Students," VNU Journal of Science: Educational Research, 2024.

[10] V. S. Ngô, T. M. N. Nguyễn, T. H. Hoàng, H. L. Nguyễn, và V. V. M. Nhật, “Một cải tiến của PhoBERT nhằm tăng khả năng hiểu tiếng Việt của chatbot thông tin khách sạn,” *Tạp chí Khoa học Đại học Huế: Kỹ thuật và Công nghệ*, vol. 131, no. 2A, pp. 5–20, 2022.

[11] L. M. H. Nguyễn và V. L. Trần, “Xây dựng ứng dụng gom cụm bài báo khoa học theo chủ đề,” *Tạp chí Khoa học HUFLIT (HUFLIT Journal of Science)*, 2023.

[12] H. Q. Phạm, “BERT, RoBERTa, PhoBERT, BERTweet: Ứng dụng state-of-the-art pre-trained model cho bài toán phân loại văn bản,” *Viblo* (Sun AI Research Team), 2020.

[13] D.-T. Le, X.-S. Vu, N.-D. To, H.-Q. Nguyen, T.-T. Nguyen, T. K.-L. Le, A.-T. Nguyen, M.-D. Hoang, N. Le, H. Nguyen, and H. D. Nguyen, "ReINTEL: A Multimodal Data Challenge for Responsible Information Identification on Social Network Sites," in *Proceedings of the 7th International Workshop on Vietnamese Language and Speech Processing*, 2020.

Phụ lục